

Forsvarsforberedelse — NautiCost

muntlig eksamen

LOG650 Forskningsprosjekt, juni 2026 — Gruppe 11, Jørgen Renè

Forberedelse til muntlig eksamen

2026-05-13

Table of Contents

Forsvarsforberedelse — NautiCost muntlig eksamen	2
1. Datagrunnlag og generaliserbarhet.....	2
Spørsmål 1.1 — “Hvor representativ er en flåte på 17 yachter?”	2
Spørsmål 1.2 — “Hvorfor er datasettet i EUR når brukerne er i Norge?”	3
Spørsmål 1.3 — “Hva hvis en yacht har vesentlig andre spesifikasjoner enn de 17?” ...	3
2. Modellvalg og evaluering.....	3
Spørsmål 2.1 — “Hvorfor velger dere ensemble når LightGBM-base presterer bedre på testsettet?”	3
Spørsmål 2.2 — “Hvorfor er Optuna-tunet modell dårligere enn base?”	3
Spørsmål 2.3 — “MAE på 19 000 EUR er nesten det dobbelte av medianfakturaen. Er det akseptabelt?”	4
Spørsmål 2.4 — “Modellen overpredikerer 18 % i log-rom. Hvorfor?”	4
Spørsmål 2.5 — “Hvordan vet dere modellen ikke er overtilpasset?”	4
Spørsmål 2.6 — “Hvorfor ikke nevralnett eller deep learning?”	4
3. Usikkerhet og konformprediksjon	5
Spørsmål 3.1 — “Hva betyr 80 % dekning egentlig?”	5
Spørsmål 3.2 — “CQR-korreksjonen er bare 3 EUR. Er det riktig?”	5
4. Kalibrering og operasjonalisering.....	5
Spørsmål 4.1 — “Hybrid kalibrering — er ikke det å snyte modellen?”	5
Spørsmål 4.2 — “Hvorfor er los modellert som sannsynlighet når det er obligatorisk for store yachter?”	5
Spørsmål 4.3 — “Hvorfor fjernet dere provisions-override?”	6
5. Validitet og forskningsdesign.....	6
Spørsmål 5.1 — “Hva er den viktigste begrensningen i prosjektet?”	6
Spørsmål 5.2 — “Generaliseres modellen til andre yacht-agenter?”	6

Spørsmål 5.3 — “Hva med konstruktvaliditet — er <code>final_charge</code> egentlig ‘kostnad’?”	6
Spørsmål 5.4 — “Produksjonsmodellen har ingen uavhengig holdout. Hvordan vet dere den fungerer?”	7
6. Pensum-justering.....	7
Spørsmål 6.1 — “Hvordan er prosjektet forankret i kompendiet?”	7
Spørsmål 6.2 — “Hvilke av kompendiets prosesssteg adresserer dere?”	7
7. Peer review og prosess	7
Spørsmål 7.1 — “Hvordan reagerte dere på peer review?”	7
Spørsmål 7.2 — “Hva har AI bidratt med, og hva har dere gjort selv?”	8
8. Etske og praktiske spørsmål.....	8
Spørsmål 8.1 — “Hva med personvern?”	8
Spørsmål 8.2 — “Hva er nettoverdien for Yachting Operations?”	8
9. Konklusjon-spørsmål	8
Spørsmål 9.1 — “Hva er studiens viktigste bidrag?”	8
Spørsmål 9.2 — “Hvis dere skulle starte på nytt, hva ville dere gjort annerledes?”	9
10. Stikkord-arsenal for åpne diskusjoner	9

Forsvarsforberedelse — NautiCost muntlig eksamen

Formål: Forberede konsise, dekkende svar på de mest sannsynlige sensor-spørsmålene basert på rapportens svakheter, peer review og kompendiet. Hvert spørsmål har stikkord-svar (30–60 sekunder muntlig), en lengre faglig begrunnelse, og referanse til rapportseksjonen der dette er dokumentert.

1. Datagrunnlag og generaliserbarhet

Spørsmål 1.1 — “Hvor representativ er en flåte på 17 yachter?”

Stikkord-svar (45 sek): Begrenset, og det er prosjektets viktigste enkeltsvakhet. Modellen kan ha lært yacht-spesifikke mønstre fremfor generaliserbare prinsipper. Vi har gjort tre ting for å håndtere dette: (a) eksplisitt avgrensning i § 1.3, (b) tidsbasert split som speiler reell prognosebruk, og (c) hybrid persentil-kalibrering som forankrer estimatene i empirisk virkelighet. Videre arbeid punkt 1 er å utvide flåten.

Faglig begrunnelse: Med $n = 17$ enheter har vi et rad-til-yacht-forhold på ca. 96 transaksjoner per yacht. Det er nok til å lære moderate kostnadsdrivere, men ikke til å

validere at en 18. yacht — særlig med ny motorkonfigurasjon eller bruksmønster — vil bli predikert nøyaktig. Ekstern validitet til andre yachter er den primære åpne kanten (§ 9.6).

Rapport-ref: § 1.3 avgrensninger, § 9.4 punkt 1, § 9.6 ekstern validitet, § 9.7.1 data-utfordringer.

Spørsmål 1.2 — “Hvorfor er datasettet i EUR når brukerne er i Norge?”

Stikkord-svar (30 sek): Yachting Operations registrerer fakturaer i EUR — cockpit-rapportenes egne kolonneoverskrifter sier “EUR”. Vi trener modellen i kildevaluta for å unngå dobbel valutakonvertering, og lar frontend gange opp med kurs ved API-grensa. En tidligere v0.2-feil hadde merket output NOK, noe brukertesten avdekket og v0.3 fikset.

Rapport-ref: § 1.3 valuta, § 9.5.1 enhetsfeil, § 9.4 punkt 6.

Spørsmål 1.3 — “Hva hvis en yacht har vesentlig andre spesifikasjoner enn de 17?”

Stikkord-svar (30 sek): Modellen vil predikere, men med større feil. Treensemblen ekstrapolerer ikke lineært — det binder seg til den nærmeste partisjonen. For yachter langt utenfor GT-spennet 52–2 407 er prediksjonen ikke validert. Vi rapporterer P25–P75-spennet som usikkerhetsindikator, slik at brukeren ser når estimatet er bredt og dermed usikkert.

Rapport-ref: § 9.4 punkt 1, § 9.6 ekstern validitet.

2. Modellvalg og evaluering

Spørsmål 2.1 — “Hvorfor velger dere ensemble når LightGBM-base presterer bedre på testsettet?”

Stikkord-svar (60 sek): Forskjellen er innenfor støy. Bootstrap-konfidensintervall på MAE-differansen er $\Delta = -33 \pm 870$ EUR — KI omslutter null, statistisk insignifikant. Vi velger ensemble på sekundære kriterier: (a) variansrobusthet ved drift i underliggende data, (b) Catboosts ordered boosting gir uavhengig induktiv bias som dekorrelerer feilene med LightGBMs leaf-wise vekst. Det er en forsikringsbegrunnelse, ikke en gevinstbegrunnelse — vi er ærlige om det.

Rapport-ref: § 8.1 (bootstrap-KI), § 9.2, § 9.4 punkt 9.

Spørsmål 2.2 — “Hvorfor er Optuna-tunet modell dårligere enn base?”

Stikkord-svar (45 sek): Sannsynligvis overtilpasning til foldstrukturen i 5-fold CV på et lite valideringssett ($n = 490$). Bayesoptimering finner en hyperparameter-kombinasjon som er optimal for de spesifikke foldene, men ikke for et uavhengig testsett. Dette er et empirisk argument for å beholde base-modellen som fallback ved re-trening — noe vi rapporterer i § 9.2 og § 9.4 punkt 8.

Rapport-ref: § 8.1 (test-tall), § 9.2, § 9.4 punkt 8.

Spørsmål 2.3 — “MAE på 19 000 EUR er nesten det dobbelte av medianfakturaen. Er det akseptabelt?”

Stikkord-svar (60 sek): Tre poenger. (a) MAE måles på transaksjonsnivå der enkelt-fakturaer varierer fra 2 000 til 91 000 EUR (P25–P95); en feil på 19 000 betyr at modellen treffer typiske store fakturaer godt, men bommer mer relativt på de små. (b) wMAPE = 74 % er volumvektet og mer rettferdig — der ligger vi i nedre ende av sammenlignbare studier (Jang et al. rapporterer 65–75 %, Çerçi et al. 60–80 %). (c) Anløpsnivå er den operasjonelle målestokken, og alle fem testede konfigurasjoner i § 8.3 ligger innenfor P25–P75.

Rapport-ref: § 8.3, § 9.1 kvantitativ litteratursammenligning, § 9.4 punkt 16.

Spørsmål 2.4 — “Modellen overpredikerer 18 % i log-rom. Hvorfor?”

Stikkord-svar (45 sek): Mean residual = -0,20 i log-rom betyr at modellen i snitt estimerer høyere enn faktisk. Bias-en er konsentrert i lave fakturabeløp (< 1 000 EUR) — typisk små Agency Services-fakturaer der modellen mangler tilstrekkelig signal til å predikere ned i dette beløpsspennet. På anløpsnivå dempes effekten fordi mange transaksjoner aggregeres og den hybride persentil-kalibreringen forankrer mot empirisk median. Bias-en er ærlig dokumentert i § 7.4 i stedet for skjult.

Rapport-ref: § 7.4 Figur 7.8.

Spørsmål 2.5 — “Hvordan vet dere modellen ikke er overtilpasset?”

Stikkord-svar (45 sek): Vi har et uavhengig testsett (2025, n = 649) som aldri ble brukt i seleksjon. Generaliseringen viser +10 % MAE på test mot val — det er konsistent med litteraturen for tilsvarende oppgaver (Jang et al. rapporterer 8–12 % degradering). En overtilpasset modell ville ha vist 30–50 % degradering, ikke 10 %. Vi rapporterer også at Ridge eksploderer på test (RMSE 6× høyere) som kontrast — den modellen er overtilpasset til treningsrangen.

Rapport-ref: § 8.1.1 Tabell 8.2.

Spørsmål 2.6 — “Hvorfor ikke nevralt nett eller deep learning?”

Stikkord-svar (45 sek): Tre grunner. (a) Grinsztajn et al. (2022) og Schwartz-Ziv & Armon (2022) viser i uavhengige benchmarks at treensemblar dominerer nevralt nett på heterogene tabulære data i mellomstørrelse. (b) Kompendiet (Pettersen & Rekdal, 2026, tabell 1.1) foreskriver eksplisitt LightGBM/XGBoost for problemer med “Mange forklaringsvariabler”. (c) Med n = 1 626 rader er datasettet for lite til at deep learning utnytter sin overlegne kapasitet — det er trebaserte modellens regime.

Rapport-ref: § 2.2, § 3.1, § 5.0.

3. Usikkerhet og konformprediksjon

Spørsmål 3.1 — “Hva betyr 80 % dekning egentlig?”

Stikkord-svar (60 sek): Det er marginal dekning — over hele populasjonen vil 80 % av faktiske kostnader ligge innenfor P10–P90-båndet. Det betyr ikke at hver enkelt yacht har 80 % dekning. For Mellomstor-gruppen er reell dekning 74 % — der er båndet for smalt. Dette er CQR-teoriens forskjell mellom marginal og betinget dekning (Vovk et al., 2005; Romano et al., 2019), og en sentral begrensning vi løfter frem som ett av studiens bidragspunkter (§ 1.5 punkt ii).

Rapport-ref: § 6.4, § 8.2, § 9.2, § 9.4 punkt 15.

Spørsmål 3.2 — “CQR-korreksjonen er bare 3 EUR. Er det riktig?”

Stikkord-svar (30 sek): Ja, og det er ikke fordi vi har valgt en triviell metode. Lavt korreksjonsbehov betyr at de underliggende kvantilmodellene allerede er godt kalibrert — empirisk dekning på 79,8 % rå mot nominelt 80 %. CQR-garantien er fortsatt verdifull fordi den er distribusjonsfri og holder selv hvis fremtidige data drifter.

Rapport-ref: § 6.4, § 8.2.

4. Kalibrering og operasjonalisering

Spørsmål 4.1 — “Hybrid kalibrering — er ikke det å snyte modellen?”

Stikkord-svar (60 sek): Nei, det er å forankre modellen i empirisk virkelighet. Rene transaksjonssummer kan produsere urealistisk lave totaler fordi få av P25-fakturaene følges av tilsvarende lave P25-er på andre transaksjoner. Vi ankrer mot empirisk medianpris per (havn, størrelse) og skalerer proporsjonalt med modellens forhold til en baseline-prediksjon. Dette gjør at totalen alltid har historisk basis. På anløpsnivå i § 8.3 plasserer alle fem eksempler seg innenfor P25–P75.

Rapport-ref: § 6.5 hybrid kalibrering, § 8.3 anløps-eksempler.

Spørsmål 4.2 — “Hvorfor er los modellert som sannsynlighet når det er obligatorisk for store yachter?”

Stikkord-svar (45 sek): Det er en strukturell modellfeil vi har erkjent. PORT_TEMPLATES lærte historisk frekvens (17–73 % på tvers av havner) uten å betinge på LOA. Vi løste det operasjonelt ved å gjøre `pilot_cost` til obligatorisk API-input når `loskrav` = “Ja”. Den fundamentale fixen — størrelse-betingede sannsynligheter — er flagget som videre arbeid punkt 8. Mønsteret er kjent fra havneeffektivitetslitteraturen (Garrido Albarracín et al., 2024) der regulatoriske inngrep krever eksplisitte features.

Rapport-ref: § 9.5.2, § 9.4 punkt 10.

Spørsmål 4.3 — “Hvorfor fjernet dere provisions-override?”

Stikkord-svar (45 sek): Metodisk konsistens. En override som *erstatter* modellens prediksjon med et magefølelsestall introduserer en parallel mental modell utenfor verktøyets formål. For bunkers er overridden forsvarlig fordi den substitueres med en *deterministisk fysisk formel* (distanse × forbruk × pris). For Provisions finnes ingen tilsvarende deterministisk substitutt før `guest_experience` er observerbar. Provisions-feilen er en ærlig dokumentert begrensning som skal lukkes via labels + re-trening, ikke maskeres via UI.

Rapport-ref: § 9.5.7, § 9.5.4, Vedlegg E.

5. Validitet og forskningsdesign

Spørsmål 5.1 — “Hva er den viktigste begrensningen i prosjektet?”

Stikkord-svar (45 sek): Dataen, ikke modellen. 17 yachter er strukturelt for få for sterk ekstern validitet, og `guest_experience` mangler som sentral kostnadsdriver for Provisions. Modellarkitekturen kan ikke kompensere for noen av disse — videre arbeid må gå i datainnsamlingsretning, ikke modellretning. Vi rapporterer det åpent i § 9.4 punkt 1 og § 9.4 punkt 4.

Rapport-ref: § 9.4, § 9.6, § 9.7.1.

Spørsmål 5.2 — “Generaliseres modellen til andre yacht-agenter?”

Stikkord-svar (30 sek): Nei, ikke validert. Modellen er trent kun på Yachting Operations sine fakturaer og lærer denne agentens spesifikke prismodeller. Vi anbefaler ikke bruk hos en annen agent uten re-trening — § 9.6 ekstern validitet på operatørnivå.

Rapport-ref: § 9.6.

Spørsmål 5.3 — “Hva med konstruktvaliditet — er `final_charge` egentlig ‘kostnad’?”

Stikkord-svar (45 sek): Bare delvis. `final_charge` er agentens fakturasum før moms — fanger agentens direkte tjenestekostnad + underleverandørene, men ikke (a) udokumenterte rabatter, (b) yachteierens skjulte kostnader (egen besetningslønn, valutarisiko), eller (c) opportunitetskostnad. Konstruktvaliditeten er en valid proxy for agentens fakturasum, men en partiell proxy for yachteierens totale anløpskostnad. Brukere må legge til egne kostnader på toppen.

Rapport-ref: § 9.6 konstruktvaliditet.

Spørsmål 5.4 — “Produksjonsmodellen har ingen uavhengig holdout. Hvordan vet dere den fungerer?”

Stikkord-svar (60 sek): Korrekt, og vi rapporterer det åpent. Vi har test-set-evaluering for *prefit-modellen* (trent på ≤ 2023) som proxy for modelklassens generaliseringsevne. Produksjonsmodellen (refittet på 2020–2025 inkludert test) har mer treningsdata, og forventes derfor å være minst like god, men ikke verifisert uavhengig. Dette er en strukturell konsekvens av tidsbasert split kombinert med ønske om å deploye på all tilgjengelig data (Hastie, Tibshirani & Friedman, 2009, § 7.10). Lukkes når 2026-data er tilstrekkelig — videre arbeid punkt 10.

Rapport-ref: § 8.1.1, § 9.7.6.

6. Pensum-justering

Spørsmål 6.1 — “Hvordan er prosjektet forankret i kompendiet?”

Stikkord-svar (45 sek): Kompendiet (Pettersen & Rekdal, 2026, tabell 1.1) klassifiserer problemer med “Mange forklaringsvariabler” under metodefamilien Random Forest / XGBoost / **LightGBM** med metodene gradient boosting, kryssvalidering, SHAP og hyperparametertuning. Vårt metodevalg — LightGBM + CatBoost ensemble, 5-fold CV ved Optuna, TreeSHAP, hyperparametertuning — er nøyaktig denne kombinasjonen. Vi følger også kompendiets femtrinns prosess (§ i.4) som er kallet ut eksplisitt i § 5.0.

Rapport-ref: § 2.2, § 5.0.

Spørsmål 6.2 — “Hvilke av kompendiets prosesssteg adresserer dere?”

Stikkord-svar (30 sek): Alle fem. § 5.2–5.3 er steg 1 (datainnsamling), § 5.7 + § 7.4 er steg 2 (antakelsessjekk), § 6.3–6.5 er steg 3 (løsning), § 8 er steg 4 (sjekk av løsning med val og test), og § 6.5 + § 8.4 + § 9.5 er steg 5 (anvendelse). Mappingen er tabellert i § 5.0.

Rapport-ref: § 5.0.

7. Peer review og prosess

Spørsmål 7.1 — “Hvordan reagerte dere på peer review?”

Stikkord-svar (45 sek): G10/Julie ga 2026-05-07 syv konkrete forbedringspunkter. Alle ble adressert i v0.4, og noen ble forsterket i v1.0. Eksempler: akademisk bidrag i § 1.5 omskrevet med tre eksplisitte hull; figurer henvist til notebooks ble eksportert som PNG og embedet; endelig testsett-evaluering (etterlyst som mangel) ble gjennomført med eget skript `eval_test_2025.py`. Hele responsen er tabellert i § 9.7.5.

Rapport-ref: § 9.7.5.

Spørsmål 7.2 — “Hva har AI bidratt med, og hva har dere gjort selv?”

Stikkord-svar (60 sek): AI har bidratt med kodegenerering, draft-skriving av prosa-avsnitt, litteratursøk, og figurproduksjon. Vi har gjort: valg av problemstilling, vurdert hvilke metoder som er pensumforankret, sparret iterativt om struktur, kritisk vurdert AI-genererte forslag (f.eks. avvist provisions-override og forkastet uvalidert Shadish, Cook & Campbell-referanse), kvalitetssikret hver referanse mot Google Scholar, og foretatt alle metodiske avveininger (CQR vs. standard konform, hybrid kalibrering vs. rene transaksjonssummer, ensemblervalg). AI gjorde grovarbeidet; vi gjorde de faglige vurderingene. Dette samsvarer med kompendiets rollefordeling (§ iii.1).

8. Etske og praktiske spørsmål

Spørsmål 8.1 — “Hva med personvern?”

Stikkord-svar (30 sek): Ingen direkte personopplysninger i datasettet. Yacht-ID-er er anonymisert (yacht_1, ..., yacht_19). Kontornavn beholdt fordi de er offentlig kjente lokasjoner. Fakturabeløp i rapporten er aggregert per persentil eller havn.

Rapport-ref: § 9.9 etiske hensyn.

Spørsmål 8.2 — “Hva er nettoverdien for Yachting Operations?”

Stikkord-svar (45 sek): Verktøyet gjør at en agentkoordinator kan gi yachteier et estimat på sekunder med kommunisert spenn — i stedet for et magefølelsesanslag som tar minutter og er inkonsistent mellom koordinatorene. På sikt kan logging av faktura mot estimat drive automatisk re-trening. Forecast-funksjonen svarer på forretnings spørsmål som “30 yachter neste år, hvilken inntekt?”. Krav er at brukeren forstår at det er estimater, ikke pristilbud.

Rapport-ref: § 9.8.

9. Konklusjon-spørsmål

Spørsmål 9.1 — “Hva er studiens viktigste bidrag?”

Stikkord-svar (45 sek): Tre bidrag (jf. § 1.5). (a) En **transaksjonsnivå-ensemblemodell med trafikkvektet aggregering og hybrid persentilkalibrering** som fungerer i et lite, høyt-skjevt regime ($n \approx 1\,600$, 17 enheter) — utvider litteraturen ned i datasparsomme størrelsesordener. (b) En **empirisk dokumentasjon av forskjellen mellom marginal og betinget CQR-dekning** når en sentral kostnadsdriver er uobservert. (c) Et **metodisk mønster** for hvordan tabulære ML-modeller møter operasjonell virkelighet i regulerte

bransjer (kombinasjon av lærte features, obligatoriske brukerinputs, og deterministiske formler).

Rapport-ref: § 1.5, § 9.7.7, § 10.

Spørsmål 9.2 — “Hvis dere skulle starte på nytt, hva ville dere gjort annerledes?”

Stikkord-svar (60 sek): Tre ting. (a) **Starte med guest_experience-rubrikken**, ikke vente til brukertesten avdekket gapet. (b) **Logge distance_nm per leg** fra dag én, slik at bunkers kunne vært feature i stedet for override-formel. (c) **Skille mellom Norge/Sverige/Danmark i aggregat-features** fra start (jf. § 9.5.5), slik at landsignalet ikke gikk tapt i size_svc_*-statistikkene. Tilstanden er nå at vi har et fungerende verktøy med ærlig dokumenterte begrensninger — fremtidig arbeid vet nøyaktig hvor de skal grave.

Rapport-ref: § 9.5, § 9.7.

10. Stikkord-arsenal for åpne diskusjoner

Forsvarspunkter du sannsynligvis vil trekke fram uansett spørsmål:

- **Pensum-forankret:** Pettersen & Rekdal (2026) tabell 1.1 foreskriver eksplisitt LightGBM + gradient boosting + CV + SHAP + tuning. Vi følger dette nøyaktig.
- **Ærlighet om svakheter:** 16-punkts § 9.4 og § 9.7-refleksjon viser kritisk modenhet. Sjeldent at masterrapporter er så åpne om hva som *ikke* ble løst.
- **Operasjonelt verifisert:** § 8.4 — backend < 200 ms kald, < 50 ms varm; dashboard < 2 sek.
- **Test-sett-verifisert:** Endelig generalisering på 649 transaksjoner fra 2025 viser +10 % MAE (forventet etter modellseleksjon), ikke katastrofalt fall.
- **Peer review-respons:** Alle syv punkter fra G10/Julie er adressert.
- **Reproduserbarhet:** eval_test_2025.py, generate_figures.py, convert_to_word.py gjør rapportens tall og figurer reproduserbare fra git.
- **Litteratur-sammenligning:** Våre wMAPE-tall (71–74 %) ligger i nedre ende av Jang et al. (2023) og Çerçi et al. (2024).

Versjon: 2026-05-13. Skrevet som forberedelse til muntlig eksamen juni 2026.