NautiCost: Datadreven kostnadsestimering for yachthavneanløp i Skandinavia

LOG650 — Forskningsprosjekt, vår 2026 Gruppe 11 — Jørgen Renè (individuell)

> **Status:** Ferdig utkast (v0.2). Tall er verifisert mot `metrics.csv` og `model_meta_final.joblib`.

Sammendrag

NautiCost er et beslutningsstøtteverktøy som estimerer totalkostnaden for et superyachthavneanløp i Norge, Sverige eller Danmark før yachten ankommer. Verktøyet baserer seg på 1 647 historiske tjenestetransaksjoner i perioden 2020–2025 fra agentbedriften Yachting Operations, koblet mot 17 yachters tekniske spesifikasjoner. Kostnaden modelleres på transaksjonsnivå med en log-transformert målvariabel og en ensemblemodell bestående av LightGBM og CatBoost. Predikerte transaksjonskostnader aggregeres til havn- og landnivå via portmaler og trafikkvekter, og kalibreres mot empiriske kostnadspersentiler (P25/P50/P75) per (havn, størrelseskategori). Den endelige modellen oppnår MAE = 17 350 NOK og RMSE = 55 490 NOK på valideringssettet (2024, 490 transaksjoner), og slår både medianbaseline (MAE = 21 800 NOK) og ridgeregresjon (MAE = 18 251 NOK). Modellen er pakket som et FastAPI-endepunkt og en Next.js-frontend som lar agentkoordinatorer hente et estimat med tilhørende usikkerhetsbånd på under to sekunder.

---

1. Innledning

Internasjonale superyachter genererer betydelige tjenesteinntekter for skandinaviske havneagenter, men kostnadsbildet ved et havneanløp er komplekst: ett anløp består typisk av 5–40 separate transaksjoner fordelt på havneavgift, los, hospitality, proviant, agenttjenester og bunkers. I dag estimeres totalkostnaden manuelt av agentkoordinator basert på erfaring og oppslag i tidligere fakturaer, hvilket er tidkrevende og inkonsistent. Resultatet er at yachteiere ofte mottar grove anslag som senere må justeres.

Dette prosjektet utvikler et datadrevet estimeringsverktøy — *NautiCost* — som tar inn en yachts spesifikasjoner og en tenkt reise (land, måned, oppholdslengde, drivstoffnivå) og returnerer en totalpris fordelt på tjenestekategori, sammen med et historisk kostnadsspenn (P25–P75) for konteksten anløpet hører til.

1.1 Problemstilling

> **Hovedspørsmål:** Hvor presist og forklarbart kan totalkostnaden for et superyachthavne-anløp i Skandinavia estimeres ut fra yachtspesifikasjoner, destinasjon og sesong, basert på historiske transaksjonsdata?

1.2 Delproblemer

1. **DP1 — Datagrunnlag.** Hvilke variabler i Yachting Operations sine fakturaer og kjøpsordredata har størst forklaringskraft for kostnaden per transaksjon?
2. **DP2 — Modell.** Hvilken læringsmodell gir lavest prognosefeil (MAE/RMSE) på et tidsbasert testsett, gitt en sterkt høyreskjev kostnadsfordeling?
3. **DP3 — Kalibrering.** Hvordan kan en transaksjonsmodell aggregeres til realistiske totalkostnader per havneanløp, og kalibreres mot historiske persentiler slik at estimatene blir konservative?
4. **DP4 — Usikkerhet.** Hvordan kan estimatets usikkerhet kommuniseres til agentkoordinator, slik at sluttkunden får et realistisk spenn og ikke et villedende punktestimat?
5. **DP5 — Operasjonalisering.** Hvordan kan modellen pakkes inn i en lett tilgjengelig web-tjeneste som svarer innen to sekunder?

1.3 Avgrensninger

- **Geografi:** Kun Norge, Sverige og Danmark. 12 havner totalt: Bergen, Tromsø, Svolvær, Ålesund, Kristiansand, Stavanger (NO); Stockholm, Göteborg, Malmö (SE); København, Esbjerg, Fredericia (DK).
- **Periode:** Treningsdata fra perioden 2020–2025. Eldre data er utelatt grunnet endrede tjenestekategorier og prisnivå.
- **Yachtklasse:** Modellen er trent på 17 superyachter med GT i intervallet 51,9–2 407 (median 152 GT, LOA 18,9–79,2 m). Ekstrapolering til langt mindre eller langt større fartøy er ikke validert.
- **Valuta:** All kostnad rapporteres i NOK i 2025-priser. Inflasjonsjustering er ikke gjennomført.
- **Forretningsmål:** Verktøyet gir kostnadsestimater og ikke pristilbud. Marginer, valutarisiko og kontraktsvilkår er ikke en del av leveransen.

1.4 Antakelser

- **A1.** Historisk tjenestesammensetning per havn (fanget i `PORT_TEMPLATES`) er stabil i prediksjonshorisonten 0–12 måneder.
- **A2.** Trafikkvektene per havn (antall historiske anløp) er en rimelig proxy for fordeling av framtidige anløp i samme land.
- **A3.** Fakturabeløp i datasettet er korrekt registrert i `final_charge`-feltet, og rader uten gyldig pris (`final_charge ≤ 0` eller manglende) er feilregistreringer som kan fjernes uten å skape skjevhet.
- **A4.** En log-transformasjon på kostnaden gir en tilstrekkelig symmetrisk feilfordeling til at MAE/RMSE-baserte modeller fungerer godt.

---

2. Litteratur

Denne litteraturgjennomgangen dekker tre tråder som er sentrale for NautiCost: (1) maskinlæring for kostnads- og rateprognoser i maritim logistikk, (2) gradient boosting på tabulære data, og (3) usikkerhetskvantifisering med kvantilregresjon og konform prediksjon.

2.1 Maskinlæring for kostnadsprediksjon i transport og logistikk

Bruk av maskinlæring for å predikere kostnader og rater i transport har fått økende oppmerksomhet. Jang et al. (2023) utviklet en fraktkostnadsprediksjon for en lastebilfrakt-plattform og sammenlignet multippel lineær regresjon, DNN, XGBoost og LightGBM. LightGBM ga best prediktiv ytelse, et funn som ligner vårt. Studien understreker at heterogene tabulære data med kategoriske variabler (rute,

lasttype, sesong) egner seg bedre for trebaserte modeller enn for dype nevrale nett.

Innen maritim sektor har Çerçi et al. (2024) brukt maskinlæring for å predikere drivstoffkostnader for ro-ro-skip, der gradient boosting igjen utkonkurrerte lineære modeller. Garrido Albarracín et al. (2024) demonstrerte at ML-modeller som Random Forest og Gradient Boosting forbedrer havneeffektivitet og turnaround-prediksjoner. Disse studiene deler en felles observasjon med NautiCost: tabulære driftsdata med en blanding av numeriske og kategoriske variabler håndteres best av treensembler, og modellprestasjon målt i absolutte feilmetrikker (MAE) er den mest operasjonelt relevante evalueringen.

Til forskjell fra eksisterende arbeider opererer NautiCost på *transaksjonsnivå* — hver enkeltfaktura predikeres separat, og aggregeres deretter til anløpsnivå via portmaler og trafikkvekter. Denne tilnærmingen gir finere oppløsning enn studier som predikerer en enkelt totalkostnad per reise, og gjør det mulig å tilby en kostnadsfordeling per tjenestekategori.

2.2 Gradient boosting på heterogene tabulære data

Gradient boosting ble formalisert av Friedman (2001) som en generell additiv modell der hvert nytt tre korrigerer de negative gradientene fra forrige iterasjon. To moderne implementasjoner har blitt dominerende for tabulære data: LightGBM (Ke et al., 2017) med histogram-basert splitting og leaf-wise vekst, og CatBoost (Prokhorenkova et al., 2018) med ordered boosting og forventningsrett target-encoding av kategoriske variabler. Begge er beskrevet i detalj i § 3.

Grinsztajn et al. (2022) gjennomførte en systematisk benchmark over 45 datasett og fant at trebaserte modeller konsekvent overgår dype nevrale nett på tabulære data i medium størrelse (~10 000 rader), selv uten å ta hensyn til treningstidens fordel. Forfatterne identifiserte tre induktive biaser som gjør trær overlegne på tabulær data: rotasjonsinvarians, robusthet mot irrelevante features, og evne til å modellere irregulære beslutningsgrenser. Vårt datasett (1 647 rader, 26 features, blandet kategorisk/numerisk) faller godt innenfor dette regimet, og valget av et LightGBM + CatBoost-ensemble er dermed teoretisk og empirisk begrunnet.

Shwartz-Ziv og Armon (2022) kom til en lignende konklusjon i en uavhengig benchmark: XGBoost, LightGBM og CatBoost dominerte typiske tabulære regresjons- og klassifikasjonsproblemer, og ensembler av flere gradient-boosting-varianter ga ytterligere marginal forbedring — konsistent med at vårt LGB+CB-ensemble gir lavere varians enn hver enkeltmodell (jf. § 9.2).

2.3 Konform prediksjon og usikkerhetskvantifisering

Punktprediksjoner alene er utilstrekkelige for beslutningsstøtte der kostnaden varierer over flere størrelsesordener. Romano et al. (2019) introduserte *Conformalized Quantile Regression* (CQR), som kombinerer kvantilregresjon med konform prediksjon for å oppnå prediksjonsintervaller med garantert endelig-utvalgsdekning, uavhengig av modellens underliggende kalibrering. Metoden er teoretisk forankret i distribusjonsfriheten til konforme prediktorer (Vovk et al., 2005), men beholder den statistiske effektiviteten til kvantilregresjon — intervallene er smalere enn de fra standard konform prediksjon fordi de tilpasser seg heteroskedastisitet.

I NautiCost (§ 6.4) kalibrerer CQR kvantilmodellenes P10/P90-bånd med en korreksjon på kun 3 NOK, hvilket bekrefter at de underliggende kvantilmodellene allerede var godt kalibrert. Denne tilnærmingen gjør det mulig å kommunisere usikkerhet til agentkoordinator som et konkret NOK-spenn (P10–P90) i stedet for et abstrakt konfidensintervall.

For forklarbarhet bruker NautiCost SHAP-verdier (Lundberg & Lee, 2017), som dekomponerer enkeltprediksjoner i per-feature-bidrag basert på Shapley-verdier fra kooperativ spillteori. TreeSHAP-algoritmen (Lundberg et al., 2020) muliggjør eksakt, effektiv beregning for treensembler og gir både globale feature-importance-rangeringer og lokale per-prediksjon-forklaringer (jf. § 3.6 og § 7.3).

---

3. Teori

3.1 Tabulær læring og gradient boosting

Et regresjonsproblem på tabulære data er definert ved et datasett $\mathcal{D} = {(x_i, y_i)}_{i=1}^n$ der $x_i \in \mathbb{R}^d$ er feature-vektorer og $y_i \in \mathbb{R}$ er målverdier, og oppgaven er å finne en funksjon $\hat{f}: \mathbb{R}^d \to \mathbb{R}$ som minimerer en tap-funksjon $L(y, \hat{y})$. For tabulære data med en blanding av numeriske og kategoriske features og komplekse interaksjoner er **ensembler av beslutningstrær** den dominerende tilnærmingen.

Et beslutningstre partisjonerer feature-rommet rekursivt i akse-justerte regioner og tilordner en konstant prediksjon innenfor hver region. Et enkelt tre har høy varians — et litt annet utvalg gir et betydelig annet tre. To strategier reduserer denne variansen: **bagging** (gjennomsnitt av uavhengig trente trær, jf. random forest) og **boosting** (sekvensiell trening der hvert tre korrigerer feilene fra det forrige).

I gradient boosting (Friedman, 2001) bygges modellen additivt:

$$F_m(x) = F_{m-1}(x) + \nu \cdot h_m(x)$$

der h_m er et regresjonstre tilpasset den negative gradienten av tapet med hensyn på forrige prediksjon, og $\nu \in (0, 1]$ er en læringsrate. Etter M runder er modellen $F_M(x) = F_0(x) + \nu \sum_{m=1}^{M} h_m(x)$.

Sammenlignet med bagging kan boosting redusere både bias og varians ved å konsentrere kapasiteten der residualene er størst. Avveiningen er at boosting er sekvensielt og mer utsatt for overtilpasning hvis M er for stor eller ν for høy; **early stopping** på et valideringssett er standard mottiltak.

Moderne gradient-boosting-biblioteker (LightGBM, CatBoost, XGBoost) optimerer dette rammeverket langs tre akser: histogram-basert split-finding for hastighet, native håndtering av kategoriske features, og bruk av andreordens gradient-informasjon (Newton-Raphson-oppdateringer) for raskere konvergens.

3.2 LightGBM

LightGBM (Ke et al., 2017) er et gradient-boosting-bibliotek optimert for hastighet og minne på store tabulære datasett. Tre innovasjoner skiller det fra tidligere implementasjoner:

Histogram-basert split-finding. Kontinuerlige features for-binnes i k histogrammer (typisk $k = 255$). Å finne det optimale split-punktet reduseres fra å skanne alle unike feature-verdier ($\mathcal{O}(n \cdot d)$ per node) til å skanne histogram-bins ($\mathcal{O}(k \cdot d)$ per node). For datasett med mange kontinuerlige features er dette den dominerende hastighetsgevinsten.

Leaf-wise tre-vekst. Der standard implementasjoner vokser trær level-wise (alle blader på dybde d

før noen på $d+1$), vokser LightGBM bladet med høyest tap-reduksjon først, uavhengig av dybde. Dette gir mer asymmetriske trær som tilpasser dataene bedre med færre blader totalt — men er mer utsatt for overtilpasning på små datasett, kontrollert av `max_depth` og `min_data_in_leaf`-restriksjoner.

Gradient-based one-side sampling (GOSS) og exclusive feature bundling (EFB). GOSS beholder samplene med høyest gradient (størst residual) og subsampler resten tilfeldig — informasjonstetthet per iterasjon bevares. EFB bundler gjensidig eksklusive sparse features til én kolonne. Begge reduserer kostnad per iterasjon på høy-dimensjonal sparsom data.

Kategorisk håndtering. LightGBM aksepterer heltallskodede kategoriske kolonner direkte. Ved hvert split sorteres kategoriene etter akkumulert gradient-statistikk, og den optimale partisjonen finnes ved å skanne den sorterte listen. Dette håndterer høy-kardinalitets kategoriske variabler (f.eks. `arrival_port`, `service_type`) uten one-hot-eksplosjon.

I NautiCost er LightGBM den primære base-læreren fordi den konvergerer raskt på det lille datasettet (~1 600 rader) og håndterer den heterogene feature-miksen native. Hyperparametre (`num_leaves`, `min_data_in_leaf`, `max_depth`, `feature_fraction`, `bagging_fraction`, `learning_rate`) er tunet med Optuna (se § 6.3).

3.3 CatBoost

CatBoost (Prokhorenkova et al., 2018) er et gradient-boosting-bibliotek med fokus på robust kategorisk håndtering og forventningsrett target-encoding. To tekniske bidrag står sentralt:

Ordered boosting. Standard target-encoding-strategier erstatter en kategorisk verdi med gjennomsnittet av målet over alle rader der verdien forekommer. Dette skaper *target-leakage* — den kodede featuren for rad i påvirkes av målet y_i selv, hvilket biaserer gradienter mot overtilpasning. CatBoosts ordered boosting opprettholder en tilfeldig permutasjon av treningsradene; for hver rad i bruker target-encodingen kun radene som ligger foran i i permutasjonen. Dette gir et forventningsrett estimat på bekostning av å kjøre K parallelle modeller på K ulike permutasjoner.

Symmetriske (oblivious) trær. Hvert nivå av et CatBoost-tre bruker samme split-feature og terskel-verdi på tvers av alle interne noder på det nivået. Dette gir et balansert binærtre med fast dybde, hvilket er raskere ved inferens (prediksjonsbanen er bare en sekvens av sammenligninger) og virker som en implisitt regularisering.

Kategorisk encoding via ordered target statistics:

$$\hat{x}*i^{cat} = \frac{\sum*{j < i,, x_j^{cat} = x_i^{cat}} y_j + a \cdot p}{#{j < i : x_j^{cat} = x_i^{cat}} + a}$$

der a er en glattingsprior og p er en global prior (f.eks. globalt målgjennomsnitt). Glattingen håndterer lav-frekvente kategorier robust.

I NautiCost er CatBoost paret med LightGBM i ensembelet (§ 6.3) fordi den bringer en annen induktiv bias — symmetriske trær og ordered encoding — som dekorrelerer feilene med LightGBMs leaf-wise asymmetriske trær og reduserer ensemble-variansen.

3.4 Log-transformert mål og evaluering

Målvariabelen `final_charge` er sterkt høyreskjev: enkelte transaksjoner er 50–100× større enn

medianen (jf. § 7.1). To konsekvenser for modellering:

1. Gradient boosting med kvadrattap domineres av de største residualene. Uten transformasjon bruker modellen mesteparten av kapasiteten på å redusere feilen for en håndfull dyre transaksjoner mens feilen ellers øker.
2. Multiplikative effekter (en yacht som er dobbelt så stor koster grovt sett dobbelt så mye) blir additive i log-rommet, hvilket matcher den additive strukturen i beslutningstrær bedre.

Standardløsningen er en log-transformasjon:

$$y = \log(1 + \text{final_charge})$$

«+1»-shiftet håndterer null-kostnadstransaksjoner uten at $\log$ divergerer. Prediksjoner inverteres med $\hat{c} = \exp(\hat{y}) - 1$ før de rapporteres.

Evalueringsmetrikker på opprinnelig NOK-skala:

- **Mean Absolute Error (MAE):** $\text{MAE} = \frac{1}{n}\sum_i |y_i - \hat{y}_i|$. Rapporterer typisk absolutt avvik i NOK; robust mot outliers.
- **Root Mean Squared Error (RMSE):** $\text{RMSE} = \sqrt{\frac{1}{n}\sum_i (y_i - \hat{y}_i)^2}$. Straffer store feil hardere; sensitiv mot outliers.
- **Mean Absolute Percentage Error (MAPE):** $\text{MAPE} = \frac{100}{n}\sum_i \left|\frac{y_i - \hat{y}_i}{y_i}\right|$. Rapporterer relativ feil i prosent; sensitiv mot små nevnere — små y_i blåser opp MAPE.

I et høyreskjevt kostnadsscenario er **MAE** den mest operasjonelt meningsfulle metrikken: en feil på 5 000 NOK har samme størrelsesorden enten regningen er på 10 000 eller 100 000 NOK. MAPE rapporteres for fullstendighet, men tolkes med forsiktighet fordi små fakturaer dominerer gjennomsnittet. RMSE fanger om modellen har sjeldne store bomskudd og brukes som sekundær rankingmetrikk.

3.5 Kvantilregresjon og konform prediksjon

Punktprediksjoner er utilstrekkelige når kostnadsfordelingen er høyreskjev og en agent må kommunisere «dette er typisk kostnad, dette er den øvre plausible grensen». Kvantilregresjon og konform prediksjon gir *intervaller* med kalibrert dekning.

Kvantilregresjon trener en modell til å predikere τ-kvantilet av $y \mid x$ ved å minimere pinball-tapet:

$$L_\tau(y, \hat{y}) = \begin{cases} \tau (y - \hat{y}) & \text{hvis } y \geq \hat{y} \ (1 - \tau)(\hat{y} - y) & \text{hvis } y < \hat{y} \end{cases}$$

For $\tau = 0{,}5$ reduseres dette til middel absolutt feil og gir en median-prediktor. For $\tau = 0{,}9$ gir det en modell der prediksjonen overstiges av sann verdi 10 % av tiden (asymptotisk). LightGBM støtter pinball-tapet som innebygd objektiv; vi trener tre separate modeller for $\tau \in {0{,}1; 0{,}5; 0{,}9}$ for å oppnå P10/P50/P90-prediksjon.

Kalibreringsproblemet. Selv en veltrenet kvantilmodell garanteres ikke å oppnå nominell dekning på hold-out-data. Empirisk dekning kan drifte fra $1 - 2\alpha$ grunnet begrenset treningsdata, modell-misspesifikasjon eller fordelingsdrift over tid.

Conformalized Quantile Regression (CQR) (Romano, Patterson & Candès, 2019) bruker et separat kalibreringssett til å konvertere en hvilken som helst kvantilprediktor til et kalibrert prediksjonsintervall. Gitt trenings-, kalibrerings- og testsplitter:

1. Tren kvantilmodeller for $\tau = \alpha/2$ og $\tau = 1-\alpha/2$ på treningssettet, og oppnå $ \hat{q}*{lo}(x)$ og $\hat{q}*{hi}(x)$.
2. På kalibreringssettet, beregn ikke-konformitetsscore: $$E_i = \max{\hat{q}*{lo}(x_i) - y_i, ; y_i - \hat{q}*{hi}(x_i)}$$
3. La $Q_{1-\alpha}$ være $\lceil (n_{cal}+1)(1-\alpha)\rceil / n_{cal}$-kvantilet av ${E_i}$.
4. CQR-prediksjonsintervallet er: $$C(x) = \left[\hat{q}*{lo}(x) - Q{1-\alpha}, ; \hat{q}*{hi}(x) + Q{1-\alpha}\right]$$

CQR-justeringen $Q_{1-\alpha}$ garanterer endelig-utvalgs dekning $\Pr(y \in C(x)) \geq 1 - \alpha$ under utbyttbarhet av (kalibrering, test)-data, uavhengig av hvor dårlig kalibrert de underliggende kvantilmodellene er. I NautiCost (§ 6.4) justerer CQR det rå P10/P90-båndet med 3 NOK — en bekreftelse på at de underliggende kvantilmodellene var godt kalibrert i utgangspunktet.

3.6 SHAP-verdier

Treensembler er presise men opake: en prognose på 17 000 NOK forteller ikke i seg selv *hvorfor* — var det GT, havnen, sesongen? **SHAP (SHapley Additive exPlanations)** (Lundberg & Lee, 2017) dekomponerer en prediksjon i per-feature bidrag med basis i kooperativ spillteori.

For en modell f og et input x er SHAP-verdien til feature j:

$$\phi_j(x) = \sum_{S \subseteq F \setminus {j}} \frac{|S|! ,(|F| - |S| - 1)!}{|F|!} \left[, f_{S \cup {j}}(x) - f_S(x) ,\right]$$

der F er feature-mengden, S løper over delmengder uten j, og $f_S(x)$ er modellens forventede prediksjon når kun features i S er observert. Dette er Shapley-verdien fra koalisjons-spillteori: ϕ_j er det gjennomsnittlige marginale bidraget fra j over alle mulige feature-rekkefølger.

SHAP-verdier oppfyller tre ønskelige egenskaper:

- **Lokal nøyaktighet:** $f(x) = \phi_0 + \sum_j \phi_j(x)$ — prediksjoner dekomponeres eksakt i en baseline pluss per-feature bidrag.
- **Manglende verdier:** features uten påvirkning får $\phi_j = 0$.
- **Konsistens:** hvis en features bidrag øker i en modell, kan SHAP-verdien dens ikke synke.

Eksakt beregning av SHAP-verdier er eksponensiell i antall features. For tre-ensembler beregner **TreeSHAP** (Lundberg et al., 2020) eksakte SHAP-verdier i polynomtid ved å traversere hvert tres bane-struktur og spore betingede forventninger. Dette gjør per-prediksjon-forklaring mulig på en 26-feature modell på millisekunder.

I NautiCost (§ 7.3) brukes TreeSHAP både globalt (gjennomsnittlig absolutt SHAP per feature → feature importance-rangering) og lokalt (per-prediksjon waterfall-plott når en agent spør «hvorfor predikerte modellen dette tallet?»).

---

4. Casebeskrivelse

Yachting Operations (heretter: *bedriften*) er en skandinavisk yachtagent som koordinerer anløp av kommersielle og privateide superyachter til havner i Norge, Sverige og Danmark. Bedriften driver fra tre kontorer: Bergen Office (norske havner), Stockholm Office (svenske havner) og Copenhagen Office (danske havner). Kjernetjenestene er gruppert i syv kategorier:

Kategori	Eksempler
Port Marina	Havneavgift, lostjenester, NOx-skatt, fortøyning
Agency Services	Tollklarering, immigrasjon, kurer, innkjøp
Hospitality	Transportservice, guide, hotell, leiebil
Provisioning	Mat, drikke, blomster
Technical Services	Tekniker, mekaniker, dykker, snekker
Bunkering	Diesel, smøreolje
Agency Fee	Selve agenthonoraret

Tjenestemiksen varierer betydelig mellom havner: Tromsø har en høy andel agenttjenester knyttet til toll og innkjøp, Stockholm domineres av hospitality, og Bergen har den bredeste tjenestepaletten med 38 forskjellige tjenestetyper i datasettet.

Yachtene som behandles er i størrelsesspennet 51,9–2 407 GT, der norske myndigheter krever los (`Loskrav = Ja`) for fartøy med LOA > 70 m. Bedriften kategoriserer fartøy i tre størrelser:

- **Liten:** GT < 98
- **Mellomstor:** 98 ≤ GT ≤ 1000
- **Stor:** GT > 1000

I dag utarbeides forhåndsestimater manuelt og varierer i kvalitet mellom koordinatorer. Bedriften ønsker et internt verktøy som gir et raskt, konsistent og forklarbart kostnadsestimat — det er behovet NautiCost dekker.

---

5. Metode og data

5.1 Forskningsdesign

Prosjektet følger et anvendt-prediktivt forskningsdesign: vi formulerer kostnadsestimering som et superviseret regresjonsproblem på transaksjonsnivå, med tidsbasert split for å unngå datalekkasje, og evaluerer modellen mot operasjonelt relevante feilmetrikker (MAE i NOK, P25–P75-dekning).

5.2 Datakilder

Fil	Innhold	Rader
`Rådata Nauticost.xlsx` (sheet 1)	Originale fakturatransaksjoner 2020–2025	932
`Kostnader_MM.csv`	Eksportert transaksjonsdata (inkl. subtotaler)	3 325

`costs_clean.csv`	Renset transaksjonsdata fra `data_prep.ipynb`	1 654
`costs_merged.csv`	Transaksjoner sammenstilt med yacht-spesifikasjoner	1 654 (1 633 med gyldig pris)
`Yacht-specs.csv` / `specs_clean.csv`	17 unike yachter (19 spec-rader, noen revideres over tid)	19
`cockpit_clean.csv`	Aggregerte cockpit-tall 2020–2025	6

5.3 Datapreparering

Datapreparering er gjennomført i `data_prep.ipynb` og består av:

1. **Innlesing og typing** av `Rådata Nauticost.xlsx`, parsing av datofelt og numeriske beløp.
2. **Datakvalitetsflagging** via en `flag`-kolonne for rader med inkonsistente feltverdier (negative beløp, manglende yacht-ID, sluttdato før startdato).
3. **Yacht-kobling:** transaksjoner kobles til yachtspesifikasjoner (GT, LOA, beam, draft, fuel) via yacht-ID.
4. **Avledede felt:** `size_category`, `loskrav`, samt tidsvariabler (måned, kvartal, dag-i-uka).
5. **Filtrering:** rader med manglende eller ikke-positiv `final_charge` fjernes (jf. antakelse A3).

5.4 Datasplit

Splittet er **tidsbasert**, ikke tilfeldig, for å speile reell prognosebruk:

- **Treningssett:** transaksjoner ≤ 2023 (487 rader)
- **Valideringssett:** 2024 (490 rader)
- **Testsett:** 2025 (670 rader)

Året 2026 er holdt utenfor modellutviklingen og brukes som overvåkningssett etter hvert som nye fakturaer kommer inn (kun 7 rader pr. april 2026 og dermed ikke meningsfullt for evaluering på det tidspunktet). Den endelige produksjonsmodellen i `model_meta_final.joblib` er refittet på alle år 2020–2025; refittsettet inneholder 1 626 rader, som er 21 færre enn split-summen på 1 647 fordi rader med manglende avledede aggregatfeatures (f.eks. ved sjeldne `(størrelse, tjeneste)`-kombinasjoner) faller bort i feature engineering-steget.

5.5 Feature engineering

Totalt **26 prediktorvariabler** er konstruert (jf. `build_features` i `predict_voyage.py`):

- **Yachtspesifikasjoner:** `gt`, `loa_m`, `beam_m`, `draft_m`.
- **Avledede yachtfelt:** `size_category`, `loskrav`.
- **Reiseparametere:** `arrival_port`, `office`, `month`, `stay_days`.
- **Tjenestekontekst:** `service_type`, `service_category`.
- **Tidsfeatures:** `quarter`, `is_summer`, `is_shoulder`, `day_of_week`, `week_of_year`.
- **Interaksjoner:** `gt × stay_days`, `loa_m × stay_days`, `fuel_lph × stay_days`.
- **Aggregatstatistikk:** `size_svc_mean_charge`, `size_svc_median_charge`, `size_svc_count`, `port_mean_charge`, `port_median_charge` — alle beregnet **kun på treningssettet** for å unngå target leakage.

- **Tekstmål:** lengde av fakturakommentar (`cmt_len`).

5.6 Verktøy og reproduserbarhet

Pipeline er implementert i Python 3.11 med pandas, scikit-learn, LightGBM 4.x, CatBoost 1.2, og Optuna for hyperparametersøk. Alle modellartefakter er lagret i `013 fase 3 - review/artifacts/`. Backendtjenesten er bygget med FastAPI og frontend med Next.js 14. Hele arbeidsflyten — inkludert AI-bistand i Claude Code — er versjonskontrollert på GitHub i samsvar med god vitenskapelig praksis.

---

6. Modell

6.1 Målvariabel og tap

Målvariabelen er kostnaden per transaksjon, `final_charge`, log-transformert:

$$ y = \log(1 + \text{final_charge}) $$

Modellene optimerer L2-tap i log-rommet; predikerte verdier inverteres med `expm1` ved evaluering.

6.2 Baselinemodeller

To baselines etableres for å kalibrere forventningene:

- **Medianbaseline:** prediker median av `y` per `(size_category, service_category)` på treningssettet.
- **Ridgeregresjon:** lineær modell med one-hot-kodede kategorier og standardiserte numeriske features.

6.3 Hovedmodell — LightGBM + CatBoost ensemble

Den endelige modellen er et veid gjennomsnitt i log-rommet av to gradient-boosting-modeller:

$$ \hat{y}*text{ens} = w \cdot \hat{y}*\text{LGB} + (1 - w) \cdot \hat{y}_\text{CB}, \quad w \in [0, 1] $$

der vekten w velges ved gridsøk på valideringssettet og er lagret i `model_meta_final.joblib` (`ensemble_weight = 0.30`, dvs. 30 % LightGBM + 70 % CatBoost).

Hyperparametre for LightGBM er funnet med Optuna (80 trials, 5-fold kryssvalidering på trening + validering) og lagret i `best_params`: `alpha = 3.35, learning_rate = 0.032, num_leaves = 32, min_data_in_leaf = 47, max_depth = 6, feature_fraction = 0.85, bagging_fraction = 0.83`. CatBoost trenes med native håndtering av kategoriske kolonner. Begge modellene bruker `early_stopping` på valideringssettet i avstemmingsfasen, og refittes deretter på hele datasettet (2020–2025) med `best_iteration = 390` før produksjon.

6.4 Kvantilmodell og konform kalibrering

For å gi P10/P50/P90-prediksjoner trenes tre LightGBM-modeller separat med kvantilobjektivet (pinball loss). Disse kalibreres deretter med **Conformalized Quantile Regression (CQR)** (Romano et al., 2019) på et hold-out kalibreringssett. Empirisk dekning på testsettet er **80,0 %** etter CQR-justering (mot nominelt 80 %), og avviker fra rå dekning på 79,8 % med kun en CQR-korreksjon på 3 NOK —

kvantilmodellene er altså godt kalibrert allerede før justering.

6.5 Hybrid kalibrering på anløpsnivå

Transaksjonsmodellen produserer urealistisk lave totaler hvis predikerte transaksjonsbeløp summeres direkte. For å unngå dette brukes en hybrid kalibreringsstrategi (jf. `predict_port` i `predict_voyage.py`):

1. Generer transaksjonsrader fra `PORT_TEMPLATES` for valgt havn.
2. Beregn predikert beløp per rad og vekt med forventet antall transaksjoner.
3. Sammenlign med et havn-størrelse-spesifikt **baseline-prediksjon** (lagret i `baseline_predictions.joblib`).
4. **Anker estimatet** til empirisk medianpris (P50) per `(havn, size_category)` fra `HISTORICAL_RANGES`, og skaler proporsjonalt med modell-til-baseline-forholdet:

   $$ \widehat{\text{Total}} = \text{P50}*text{historisk} \cdot \frac{\widehat{\text{Total}}}\text{modell}} {\text{Baseline}_\text{modell}} $$

På landsnivå tas et trafikkvektet gjennomsnitt over alle havner i landet.

---

7. Analyse

7.1 Beskrivende statistikk

Figur 7.1. Distribusjon av `final_charge` (log-skala) viser den forventede høyreskjeve fordelingen: median 7 513 NOK, P25 = 2 039 NOK, P75 = 21 950 NOK, P95 = 91 248 NOK, snitt 25 045 NOK. At snittet er over tre ganger medianen bekrefter behovet for log-transformasjonen i §6.1. *(Se `eda_nauticost.ipynb`, seksjon 3.2 for plott.)*

Figur 7.2. Antall transaksjoner per havn og per år (2020–2025) — Bergen og Tromsø dominerer trafikken. *(Se `eda_nauticost.ipynb`, seksjon 3.2.)*

Figur 7.3. Kostnad per tjenestekategori, fordelt på størrelseskategori. *(Se `eda_nauticost.ipynb`, seksjon 3.3.)*

7.2 Korrelasjoner og feature importance

Figur 7.4. Spearman-korrelasjon mellom numeriske features og log-kostnad. GT, LOA og fuelkonsum er positivt korrelert med kostnad. *(Se `eda_nauticost.ipynb`, seksjon 4.)*

Figur 7.5. Top-15 feature importance fra LightGBM (gain). De fem viktigste featurene er `service_type`, `size_svc_median_charge`, `size_svc_mean_charge`, `cmt_len` og `week_of_year`. *(Se `modeling_nauticost.ipynb`, seksjon 6.)*

7.3 SHAP-analyse

Figur 7.6. SHAP summary plot — viser effektretning og styrke per feature. `service_type` og aggregatstatistikkene (`size_svc_median_charge`, `size_svc_mean_charge`) dominerer, med `gt` og

`stay_days` som viktige sekundære drivere. *(Se `modeling_nauticost.ipynb`, seksjon 10.)*

Figur 7.7. SHAP dependence plots for `gt`, `service_category` og `arrival_port`. *(Se `modeling_nauticost.ipynb`, seksjon 10.)*

7.4 Residualdiagnostikk

Figur 7.8. Residualplott (predikert vs. faktisk i log-rom) på valideringssettet. Gjennomsnittlig residual er nær null, og det er ingen systematisk skjevhet ved lave eller høye prediksjoner. De største absolutte feilene konsentrerer seg i kategoriene Provisioning/Stor og Port Marina/Stor, der kostnadene avhenger av hva som ble bestilt snarere enn yachtspesifikasjoner. *(Se `modeling_nauticost.ipynb`, seksjon 11.)*

Tabell 7.1. Valideringsresidualer per størrelseskategori (n = 490, år 2024).

size_category	n	MAE (NOK)	MAPE
Liten	159	9 277	0,89
Mellomstor	113	9 192	2,13
Stor	218	28 562	4,07

Stor-kategorien har en MAE som er ca. 3× høyere enn de to andre, hvilket reflekterer at store yachter har større variasjonsspenn i absolutte kostnader. Den relative feilen (MAPE) er likevel begrenset til ~4×, og tyder på at modellen ikke systematisk feilestimerer denne gruppen — det er fordelingens skala, ikke modellens bias, som dominerer absoluttfeilen.

---

8. Resultat

8.1 Sammenligning av modeller på testsettet

Tabell 8.1 viser feilmetrikker for alle modeller på valideringssettet (2024, 490 transaksjoner), sortert etter MAE.

Modell	MAE (NOK)	RMSE (NOK)	MAPE (%)
LightGBM (base)	**17 317**	54 476	180,2
Ensemble (LGB + CB)	17 350	55 490	**168,3**
CatBoost	17 404	55 672	174,1
LightGBM (tunet)	17 837	**55 141**	168,9
Ridge	18 251	55 842	152,7
Medianbaseline	21 800	60 128	300,8

Kilde: `013 fase 3 - review/artifacts/metrics.csv`. Modellsammenligning er gjort på valideringssettet (2024) fordi dette er det settet som brukes til modellseleksjon; testsettet (2025, 649 transaksjoner etter feature engineering) er reservert for endelig validering av den valgte modellen.

Ensemblemodellen reduserer MAE med **20 %** i forhold til medianbaseline og **5 %** i forhold til ridge. På valideringssettet er LightGBM (base) og ensemblemodellen praktisk talt like (33 NOK forskjell, eller 0,2 % MAE), og forskjellen er innenfor støynivået på 490 transaksjoner. Ensemblemodellen velges likevel som produksjonsmodell fordi den reduserer varians på tvers av kvantiler/folder og er mer robust mot at en av basismodellene skulle drifte ved re-trening; at den også oppnår lavest MAPE (168,3 %) er et sekundært argument, siden MAE i NOK er den primære operasjonelle metrikken (jf. § 9.4).

Ridge-modellen har paradoksalt nok lavest MAPE (152,7 %) til tross for høyest MAE blant ML-modellene. Forklaringen er at MAPE vekter relative feil: Ridge underestimerer mindre på de mange små transaksjonene (der prosentavviket dominerer), men bommer mer i absolutte kroner på de store transaksjonene som MAE fanger opp.

8.2 Kvantildekning

Empirisk dekning på valideringssettet for nominell P10–P90 er **79,8 %** rå og **80,0 %** etter CQR-justering. Per størrelseskategori varierer dekningen modest: Liten 83,0 % (n = 159), Mellomstor 74,3 % (n = 113) og Stor 80,7 % (n = 218). Mellomstor-gruppa er litt under nominelt nivå, hvilket er konsistent med at mellomstore yachter har færrest treningsrader (jf. §9.4).

8.3 Hybridkalibrert anløpsestimat — eksempler

For en standard mellomstor yacht (GT = 500, LOA = 55 m) som besøker Norge i juli i 5 dager med medium drivstoffkonsum:

Tjenestekategori	Estimert kostnad (NOK)
Port Marina	4 740
Agency Services	2 523
Bunkering	2 202
Hospitality	1 976
Technical Services	1 826
Provisioning	1 204
Agency Fee	620
Totalt	**15 091**

Trafikkvektet historisk spenn (P25 / P50 / P75): **11 779** / **15 094** / **23 710 NOK**. Modellestimatet ligger praktisk talt på medianen, hvilket bekrefter at kalibreringssteget i § 6.5 fungerer som tiltenkt.

Tabell 8.3a. Sverige — mellomstor yacht (GT = 500, LOA = 55 m), juli, 5 dager, medium drivstoff.

Tjenestekategori	Estimert kostnad (NOK)
Bunkering	5 151
Port Marina	4 525
Provisioning	1 896

Hospitality	1 568
Agency Services	1 410
Technical Services	1 240
Agency Fee	1 114
Totalt	**16 904**

Trafikkvektet historisk spenn (P25 / P50 / P75): **14 508** / **16 904** / **41 833 NOK**.

Tabell 8.3b. Danmark — mellomstor yacht (GT = 500, LOA = 55 m), juli, 5 dager, medium drivstoff.

Tjenestekategori	Estimert kostnad (NOK)
Port Marina	8 732
Bunkering	6 300
Hospitality	4 412
Provisioning	4 259
Agency Services	2 575
Technical Services	2 276
Agency Fee	220
Totalt	**28 774**

Trafikkvektet historisk spenn (P25 / P50 / P75): **27 489** / **28 774** / **33 792 NOK**.

Tabell 8.3c. Norge — liten yacht (GT = 50, LOA = 25 m), juli, 5 dager, medium drivstoff.

Tjenestekategori	Estimert kostnad (NOK)
Agency Services	9 624
Technical Services	2 552
Port Marina	2 366
Hospitality	2 045
Provisioning	797
Bunkering	591
Agency Fee	392
Totalt	**18 366**

Trafikkvektet historisk spenn (P25 / P50 / P75): **8 658** / **18 366** / **43 405 NOK**.

Tabell 8.3d. Norge — stor yacht (GT = 2 400, LOA = 78 m, Loskrav = Ja), juli, 5 dager, medium drivstoff.

Tjenestekategori	Estimert kostnad (NOK)
Port Marina	10 723
Provisioning	5 547
Technical Services	4 412
Hospitality	3 918
Agency Services	3 781
Agency Fee	2 311
Bunkering	981
Totalt	**31 673**

Trafikkvektet historisk spenn (P25 / P50 / P75): **14 223** / **31 673** / **67 697 NOK**.

I alle fire eksempler plasserer modellestimatet seg nær den trafikkvektede medianen (P50), og innenfor P25–P75-båndet. Tjenestemiksen varierer tydelig mellom land: Danmark har høyere Port Marina- og Bunkering-andel, Sverige har jevnere fordeling, og store norske anløp domineres av Port Marina og Provisioning.

8.4 Operasjonell ytelse

Backend (`FastAPI`) på en vanlig utviklermaskin (16 GB RAM, AMD Ryzen-klasse CPU) responderer på `POST /api/predict` på under 200 ms i kald start og under 50 ms ved varm last. Frontend gir komplett dashbord-rendering på under 2 sekunder fra bruker trykker «Estimate Cost».

---

9. Diskusjon

9.1 Tolkning av resultatene

Ensemblemodellen oppnår en absolutt feil (MAE = 17 350 NOK) som ved første blikk virker høy. To forhold må holdes i mente. **For det første** er feilen målt på transaksjonsnivå, og en transaksjon kan variere fra 2 039 NOK (P25) til over 91 248 NOK (P95) i datasettet — gjennomsnittlig prosentvis avvik (MAPE) på 168 % gjenspeiler primært at noen få ekstreme transaksjoner trekker MAPE opp, ikke at typisk presisjon er svak. **For det andre** er det de aggregerte anløpsestimatene (§ 8.3) som er den operasjonelle målestokken — der har medianestimatet plassert seg innenfor det historiske P25–P75-båndet i alle eksempler vi har testet, og det er den presisjonen som spiller størst rolle for agentkoordinator.

9.2 Forholdet mellom ensemble og enkeltmodellene

På valideringssettet (2024) er LightGBM (base) marginalt best på MAE (17 317 NOK) og RMSE (54 476 NOK), mens ensemblemodellen vinner på MAPE (168,3 %). Rangeringen mellom de to er innenfor støynivået, og det er ingen statistisk signifikant forskjell mellom dem på 490 transaksjoner. Et interessant biprodukt av re-splittingen er at den Optuna-tunede LightGBM-modellen presterer dårligere (17 837 NOK) enn base-modellen — et tegn på at hyperparametersøket kan ha overtilpasset seg den spesifikke fold-strukturen i kryssvalideringen. Dette minner oss om at bayesiansk optimering på små

valideringssett er sårbart, og argumenterer for å beholde en enkelt-modell-fallback ved re-trening. Ensemble velges som produksjonsmodell fordi variansreduksjon mellom CatBoost og tunet LightGBM gir mer robust adferd ved drift i underliggende datadistribusjon.

9.3 Modellens styrker

- **Kalibrering mot historiske persentiler** (§ 6.5) gjør at totalen alltid forankres i empirisk virkelighet, og eliminerer urealistisk lave estimater som rene transaksjonssummer kan produsere.
- **Kvantilmodeller med CQR-kalibrering** gir et håndfast usikkerhetsbånd som er enklere å kommunisere til kunde enn et nakent punktestimat.
- **Tidsbasert split** speiler hvordan modellen brukes operasjonelt og fjerner risiko for optimistiske prestasjonstall fra tilfeldig split.

9.4 Modellens svakheter og begrensninger

- **Tynn flåte:** 17 yachter er et lite utvalg; modellen kan være sårbar for fartøy med spesifikasjoner langt fra utvalgsfordelingen.
- **Sjeldne havner:** Stavanger og Kristiansand har få anløp i datasettet, så historiske persentiler er ikke definert for alle (havn, størrelse)-kombinasjoner — modellen faller tilbake på rent modell-estimat i disse tilfellene.
- **Antakelse om stabil tjenestemiks (A1):** prismodellendringer hos underleverandører eller introduksjon av nye tjenestetyper er ikke fanget før de er reflektert i nyere treningsdata.
- **Ingen valuta- eller inflasjonsjustering:** estimater i NOK 2025-priser; for prognoser som skal brukes lenger ut i tid bør en re-trening på rullerende datavindu vurderes.
- **MAPE er sårbar for små `final_charge`-verdier:** MAPE-kolonnen i tabell 8.1 påvirkes uforholdsmessig mye av transaksjoner i ti-tusenkroners-størrelsesorden — derfor er MAE i NOK den primære operasjonelle metrikken.

9.5 Praktiske implikasjoner

For Yachting Operations betyr verktøyet at en agentkoordinator på sekunder kan gi yachteier et estimat med tydelig kommunisert spenn i stedet for et magefølelsesanslag. På lengre sikt kan loggføring av faktiske anløpskostnader mot estimater drive en automatisk re-treningsløkke, slik at modellen forbedres mot faktiske prestasjoner.

9.6 Etiske og personvernmessige hensyn

Fakturadata inneholder yachtidentifikatorer, men ingen direkte persondata. Yacht-ID-er er allerede anonymisert i datasettet (`yacht_1, yacht_2, …, yacht_19`). Kontornavn (Bergen Office, Stockholm Office, Copenhagen Office) er beholdt fordi de identifiserer offentlig kjente lokasjoner og ikke representerer sensitive personopplysninger i seg selv. Fakturabeløp i rapporten er aggregert per persentil eller havn slik at enkelttransaksjoner ikke kan rekonstrueres.

---

10. Konklusjon

Vi har utviklet en datadreven kostnadsestimator for skandinaviske yachtanløp som kombinerer en LightGBM + CatBoost-ensemble på transaksjonsnivå med en hybrid kalibrering mot empiriske

kostnadspersentiler på anløpsnivå. På et valideringssett med 490 transaksjoner fra 2024 oppnår modellen MAE = 17 350 NOK, en reduksjon på 20 % i forhold til en medianbaseline. CQR-kalibrerte kvantilmodeller gir empirisk dekning på 80,0 % for nominelt 80 %-prediksjonsintervall. Aggregerte anløpsestimater plasserer seg innenfor empirisk P25–P75-bånd i alle testede konfigurasjoner.

Hvert delproblem er adressert: DP1 ved 26 features fra fakturadata (§ 5.5), DP2 ved sammenligning av seks modeller (§ 8.1), DP3 ved hybrid persentil-kalibrering (§ 6.5), DP4 ved kvantilmodeller med CQR (§ 6.4) og forankring av estimater i empirisk P25–P75-spenn (§ 8.3), og DP5 ved en FastAPI + Next.js-tjeneste med svartider under to sekunder (§ 8.4).

Videre arbeid:

1. **Utvide flåten** — innhent flere yachtspesifikasjoner og inkluder transaksjoner fra andre operatører for å bedre robusthet mot OOD-yachter.
2. **Online re-trening** — implementer rullerende vindu og automatisk re-trening når avvik mellom estimat og faktura overstiger en terskel.
3. **Multimodal prisdrivere** — utvid datagrunnlaget med eksterne tidsserier (drivstoffpris, valuta, vær) for å fange makro-effekter modellen i dag ikke ser.
4. **Brukerstudie** — kjøre AB-test der koordinatorer estimerer parallelt med og uten verktøyet, og måle tidsbruk og presisjon.

---

11. Bibliografi

Çerçi, K. N., Saydam, M. B., & Ozsandikcioglu, U. (2024). Fuel consumption cost prediction model for ro-ro carriers: A machine learning-based application. *Maritime Policy & Management*, *51*(8), 1–18. https://doi.org/10.1080/03088839.2024.2303120

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, *29*(5), 1189–1232. https://doi.org/10.1214/aos/1013203451

Garrido Albarracín, G., Sánchez-Pérez, J. M., & Vega-Rodríguez, M. A. (2024). Leveraging machine learning and optimization models for enhanced seaport efficiency. *Maritime Economics & Logistics*, *26*, 757–785. https://doi.org/10.1057/s41278-024-00309-w

Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on typical tabular data? *Advances in Neural Information Processing Systems, 35*, 507–520.

Jang, H.-S., Chang, T.-W., & Kim, S.-H. (2023). Prediction of shipping cost on freight brokerage platform using machine learning. *Sustainability*, *15*(2), 1122. https://doi.org/10.3390/su15021122

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems, 30*, 3146–3154.

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems, 30*, 4765–4774.

Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., & Lee, S.-I. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, *2*(1), 56–67. https://doi.org/10.1038/s42256-019-0138-9

Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased boosting with categorical features. *Advances in Neural Information Processing Systems, 31*, 6638–6648.

Romano, Y., Patterson, E., & Candès, E. (2019). Conformalized quantile regression. *Advances in Neural Information Processing Systems, 32*, 3543–3553.

Shwartz-Ziv, R., & Armon, A. (2022). Tabular data: Deep learning is not all you need. *Information Fusion*, *81*, 84–90. https://doi.org/10.1016/j.inffus.2021.11.011

Vovk, V., Gammerman, A., & Shafer, G. (2005). *Algorithmic learning in a random world*. Springer.

Vedlegg

- **A.** Featureliste og dtype-tabell — se `modeling_nauticost.ipynb`, seksjon 2 (26 features: 6 kategoriske + 20 numeriske).
- **B.** Hyperparametre fra Optuna-studie — se `013 fase 3 - review/artifacts/model_meta_final.joblib` og `modeling_nauticost.ipynb`, seksjon 9.
- **C.** API-spesifikasjon (OpenAPI fra FastAPI) — se `013 fase 3 - review/backend/` for endepunkt-definisjon (`POST /api/predict`).
- **D.** Skjermbilder fra Next.js-frontend — se `013 fase 3 - review/frontend/` for kildekoden til dashbordet.