



YO_Predcost

Datadreven kostnadsestimering for yachthavneanløp i Skandinavia

LOG650 — Forskningsprosjekt, vår 2026

Gruppe 11

Jørgen Rene (individuell)

Veiledere: Bård Inge Pettersen · Per Kristian Rekdal · Erik Langelo

Molde, mai 2026

Høgskolen i Molde · Avdeling for logistikk

Obligatorisk egenerklæring

Forfatter: Jørgen Rene · **Studiepoeng:** 15 (LOG650 Forskningsprosjekt) · **Veiledere:** Bård Inge Pettersen, Per Kristian Rekdal, Erik Langelo · **Dato:** 2026-05-25 · **Antall ord (hovedtekst, Word-stil):** ca. 12 000.

Forfatter bekrefter (1–6) jf. HiMs mal *Mal prosjekt LOG650 v2.docx*:

- ☒ (1) Besvarelsen er eget arbeid; ingen kilder eller hjelp utover det som er oppgitt.
- ☒ (2) Besvarelsen er ikke brukt til annen eksamen, refererer ikke til andres eller eget tidligere arbeid uten oppgivelse, har alle referanser i bibliografien, og er ikke kopi/duplikat av andres arbeid.
- ☒ (3) Forfatter er kjent med at brudd på (1)–(2) er fusk jf. UH-loven §§ 4-7/4-8 og Forskrift om eksamen §§ 14/15.
- ☒ (4) Forfatter er kjent med plagiatkontroll i URKUND.
- ☒ (5) Forfatter er kjent med høskolens fuskebehandling.
- ☒ (6) Forfatter har satt seg inn i bibliotekets regler for kildebruk.

Personvern: Ikke meldt til NSD; fakturadata inneholder ingen direkte personopplysninger og yacht-IDer er anonymisert (yacht_1, ..., yacht_19), jf. § 9.8. **Helseforskningsloven:** Ikke aktuelt.

Publiseringsavtale Brage HiM: ☐ Ja ☐ Nei. **Båndlagt:** ☐ Ja ☐ Nei (*velges ved innlevering*).

Sammendrag

NautiCost er et beslutningsstøtteverktøy som estimerer totalkostnaden for et superyachthavneanløp i Norge, Sverige eller Danmark før yachten ankommer. Datasettet kombinerer **670 reelle 2025-fakturaer fra SDK Shipping** ($n = 649$ etter feature engineering; testsettet) med **977 simulerte 2020–2024-transaksjoner** ankret i case-strukturen, koblet mot 17 yachters spesifikasjoner. Metodevalget er pensumforankret (Pettersen & Rekdal, 2026, tabell 1.1): gradient boosting + kryssvalidering + SHAP + hyperparametertuning. Kostnaden modelleres på transaksjonsnivå med log-transformert mål og en LightGBM + CatBoost-ensemble. Prediksjoner aggregeres via portmaler og trafikkvekter, og kalibreres mot empiriske persentiler (P25/P50/P75)

per (havn, størrelse). Kildedata er i EUR; frontend konverterer til NOK/DKK ved API-grensa. På simulert val=2024 (n = 490): **MAE = 17 350 EUR, wMAPE = 71,4 %** — 20 % bedre enn medianbaseline. På det reelle 2025-testsettet (n = 649): **MAE = 19 051 EUR, wMAPE = 74,3 %** — $\approx 10\%$ val→test-degradering, hvor en del skyldes simulert→reell-overgangen. Modellen er pakket som FastAPI + Next.js med svartid under to sekunder.

Abstract

NautiCost is a pre-arrival decision-support tool that estimates the total cost of a superyacht port call in Norway, Sweden or Denmark. The dataset combines **670 real 2025 invoices from SDK Shipping** (n = 649 after feature engineering; the hold-out test set) with **977 simulated 2020–2024 transactions** anchored in the case structure, linked to 17 yachts. The methodology is curriculum-anchored (Pettersen & Rekdal, 2026, Table 1.1): gradient boosting, cross-validation, SHAP and hyperparameter tuning. Cost is modelled per transaction with a log-transformed target and a LightGBM + CatBoost ensemble, then aggregated via port templates and traffic weights, and calibrated against empirical P25/P50/P75 percentiles per (port, size). Source data are in EUR; the frontend converts to NOK/DKK at the API boundary. On simulated 2024 validation (n = 490): **MAE = €17,350 / wMAPE = 71.4 %** — 20 % better than median baseline. On the real 2025 hold-out test set (n = 649): **MAE = €19,051 / wMAPE = 74.3 %** — a $\approx 10\%$ val→test degradation reflecting model selection plus the simulated→real distribution shift. Deployed as FastAPI + Next.js with sub-two-second response.

Takk til

Takk til **SDK Shipping** for tilgang til reelle 2025-fakturadata og yachtspesifikasjoner som danner studiens testsett, og til Operations manager **Melanie Oksjö** for brukertesten i mai 2026 — funnene i § 9.5 hadde ikke vært mulige uten dialogen. Reelle fakturaer for 2020–2024 var ikke tilgjengelige fra bedriften; disse årene er representert ved simulerte transaksjoner som spiller case-strukturen, slik at modellen får tilstrekkelig tidsdybde til trening og validering (jf. § 5.2). Takk til veilederne **Bård Inge Pettersen, Per Kristian Rekdal** og **Erik Langelo** for kompendiet

og veiledning; metodevalget er direkte forankret i deres rammeverk (§ 2.2 og § 5.0). Takk også til Gruppe 10 for peer-review 2026-05-07.

KI-erklæring (jf. HiMs retningslinjer for transparent KI-bruk): **Anthropic Claude** (Claude Sonnet/Opus via Claude Code-CLI) er brukt som skrive- og kode-assistent. *Kode*: store deler av Python-pipeline og frontend er ko-utviklet i Claude-sesjoner; all kode er versjonskontrollert på GitHub. *Rapporttekst*: utkast til § 2–§ 3, § 6.5, § 9.4 og § 9.5 er skrevet via prompt-og-redigér; alle tall, sitater og referanser er gjenkontrollert mot kildene. *Litteratur*: DOI-er krysssjekket mot Crossref etter at to KI-hallusinerte forfatternavn ble oppdaget i tidlig versjon. *Forfatterens eget arbeid*: casebeskrivelse, data, modellvalg, brukertest mai 2026 og denne erklæringen. KI er brukt som assistent, ikke forskningserstatning. Alle resultattall er reproducerbare via skriptene i 013 fase 3 - review/.

Innholdsfortegnelse

Obligatorisk egenerklæring	2
Sammendrag	2
Abstract	3
Takk til	3
Innholdsfortegnelse	5
1. Innledning.....	7
1.1 Problemstilling	7
1.2 Delproblemer	7
1.3 Avgrensninger	8
1.4 Antakelser.....	8
1.5 Anvendte bidrag i case-studien	9
2. Litteratur.....	9
2.1 Maskinlæring for kostnadsprediksjon i transport og logistikk.....	9
2.2 Gradient boosting på heterogene tabulære data	10
2.3 Konform prediksjon og usikkerhetskvantifisering.....	11
2.4 Forskningsgap	12
3. Teori	12
3.1 Tabulær læring og gradient boosting	12
3.2 LightGBM	13
3.3 CatBoost.....	14
3.4 Log-transformert mål og evaluering	15
3.5 Kvantilregresjon og konform prediksjon	18
3.6 SHAP-verdier	19
4. Casebeskrivelse	20
5. Metode og data	21
5.0 Prosessmapping mot pensumkompendiet	21
5.1 Forskningsdesign.....	21
5.2 Datakilder	21
5.3 Datapreparering	23
5.4 Datasplit og evalueringsprotokoll	23
5.5 Feature engineering	25
5.6 Verktøy og reproduserbarhet.....	25
5.7 Antakelsessjekk (kompendiet steg 2).....	25

6. Modell	26
6.1 Målvariabel og tap	26
6.2 Baselinemodeller	27
6.3 Hovedmodell — LightGBM + CatBoost ensemble	27
6.4 Kvantilmodell og konform kalibrering	27
6.5 Hybrid kalibrering på anløpsnivå	28
7. Analyse	28
7.1 Beskrivende statistikk	29
7.2 Korrelasjoner og feature importance	31
7.3 SHAP-analyse	33
7.4 Residualdiagnostikk	34
8. Resultat	36
8.1 Sammenligning av modeller på valideringssettet	36
8.1.1 Endelig evaluering på testsettet (2025)	38
8.2 Kvantildekning	40
8.3 Hybridkalibrert anløpsestimat — eksempler	40
8.4 Operasjonell ytelse	43
9. Diskusjon	43
9.1 Tolkning av resultatene	43
9.2 Forholdet mellom ensemble og enkeltmodellene	44
9.3 Modellens styrker	45
9.4 Modellens svakheter — kritisk drøfting og forsvar	45
9.5 Funn fra brukertest mai 2026	47
9.6 Validitet og generaliserbarhet	48
9.7 Praktiske implikasjoner	50
9.8 Etiske og personvernmessige hensyn	50
10. Konklusjon	51
11. Bibliografi	53
Vedlegg	54
Vedlegg E. Foreslått rubrikk for <code>guest_experience</code>	55

1. Innledning

Internasjonale superyachter genererer betydelige tjenesteinntekter for skandinaviske havneagenter, men kostnadsbildet ved et havneanløp er komplekst: ett anløp består typisk av 5–40 separate transaksjoner fordelt på havneavgift, los, hospitality, proviant, agenttjenester og bunkers. I dag estimeres totalkostnaden manuelt av agentkoordinator basert på erfaring og oppslag i tidligere fakturaer, hvilket er tidkrevende og inkonsistent. Resultatet er at yachteiere ofte mottar grove anslag som senere må justeres.

Dette prosjektet utvikler et datadrevet estimeringsverktøy — *NautiCost* — som tar inn en yachts spesifikasjoner og en tenkt reise (land, måned, oppholdslengde, drivstoffnivå) og returnerer en totalpris fordelt på tjenestekategori, sammen med et historisk kostnadsspenn (P25–P75) for konteksten anløpet hører til.

1.1 Problemstilling

Hovedspørsmål: Hvor presist og forklarbart kan totalkostnaden for et superyachthavneanløp i Skandinavia estimeres ut fra yachtspesifikasjoner, destinasjon og sesong, basert på historiske transaksjonsdata?

1.2 Delproblemer

1. **DP1 — Datagrunnlag.** Hvilke variabler i SDK Shipping sine fakturaer og kjøpsordrededata har størst forklaringskraft for kostnaden per transaksjon?
2. **DP2 — Modell.** Hvilken læringsmodell gir lavest prognosefeil (MAE/RMSE) på et tidsbasert testsett, gitt en sterkt høyreskjev kostnadsfordeling?
3. **DP3 — Kalibrering.** Hvordan kan en transaksjonsmodell aggregeres til realistiske totalkostnader per havneanløp, og kalibreres mot historiske persentiler slik at estimatene blir konservative?
4. **DP4 — Usikkerhet.** Hvordan kan estimatets usikkerhet kommuniseres til agentkoordinator, slik at sluttkunden får et realistisk spenn og ikke et villedende punkttestimat?
5. **DP5 — Operasjonalisering.** Hvordan kan modellen pakkes inn i en lett tilgjengelig webtjeneste som svarer innen to sekunder?

1.3 Avgrensninger

- **Geografi:** Kun Norge, Sverige og Danmark. 12 havner totalt: Bergen, Tromsø, Svolvær, Ålesund, Kristiansand, Stavanger (NO); Stockholm, Göteborg, Malmö (SE); København, Esbjerg, Fredericia (DK).
- **Periode:** Datasettet dekker 2020–2025. Reelle fakturaer fra SDK Shipping er kun tilgjengelig for 2025 (testsettet); perioden 2020–2024 er representert ved simulerte transaksjoner som speiler case-strukturen (jf. § 5.2). Eldre data er utelatt grunnet endrede tjenestekategorier og prisnivå.
- **Yachtklasse:** Modellen er trent på 17 superyachter med GT i intervallet 51,9–2 407 (median 152 GT, LOA 18,9–79,2 m). Ekstrapolering til langt mindre eller langt større fartøy er ikke validert.
- **Valuta:** Kildedata er denominert i **EUR** (cockpit-rapportene har EUR-kolonneoverskrifter; fakturabeløpene i `costs_clean.csv` ligger i EUR-størrelsesorden). Modellen er trent og rapporteres i EUR. Frontend konverterer til NOK eller DKK ved API-grensa via `EXCHANGE_RATES_FROM_EUR` (mai 2026: EUR/NOK $\approx 11,50$, EUR/DKK = 7,46). Konstantene oppdateres mot ECBs referansekurs ved behov og er en ekstra usikkerhetskilde for NOK-tall (jf. § 9.5). Inflasjonsjustering er ikke gjennomført.
- **Forretningsmål:** Verktøyet gir kostnadsestimater og ikke pristilbud. Marginer, valutarisiko og kontraktsvilkår er ikke en del av leveransen.

1.4 Antakelser

- **A1.** Historisk tjenestesammensetning per havn (fanget i `PORT_TEMPLATES`) er stabil i prediksjonshorisonten 0–12 måneder.
- **A2.** Trafikkvektene per havn (antall historiske anløp) er en rimelig proxy for fordeling av framtidige anløp i samme land.
- **A3.** Fakturabeløp i datasettet er korrekt registrert i `final_charge`-feltet, og rader uten gyldig pris (`final_charge` ≤ 0 eller manglende) er feilregistreringer som kan fjernes uten å skape skjevhet.
- **A4.** En log-transformasjon på kostnaden gir en tilstrekkelig symmetrisk feilfordeling til at MAE/RMSE-baserte modeller fungerer godt.

1.5 Anvendte bidrag i case-studien

Studien er en case-studie (jf. kompendiets § B.4) i en konkret bedrift. Innenfor den rammen leveres tre **anvendte bidrag** — konkrete fremgangsmåter demonstrert på SDK Shipping sitt datasett, ikke generaliserte forskningsfunn:

1. **Transaksjonsnivå-modellering med empirisk persentilkalibrering på anløpsnivå.**
Mens eksisterende studier modellerer én total kostnad per reise (Jang et al., 2023; Su et al., 2024) eller aggregat på havnenivå (Jahangard et al., 2025), modelleres her hver av 5–40 transaksjoner per anløp separat og aggregeres via portmaler, trafikkvekter og hybrid P25/P50/P75-forankring. Empirisk demonstrert i et lite, høytskjevt regime ($n \approx 1\,600$, 17 yachter).
2. **Empirisk dokumentasjon av CQRs grense under manglende feature.** CQR (Romano et al., 2019) er teoretisk etablert, men brukertesten viste konkret hvor metoden *ikke* kompenserer — Provisions, der gjesteprofil er uobserverbar. Marginal dekning (80 %) opprettholdes, men betinget dekning på Provisions degraderer. Anvendt illustrasjon, ikke teoretisk utvidelse.
3. **Operasjonelt mønster for hybride ML + deterministiske/regulatoriske kostnader.**
Rene datadrevne modeller feiler systematisk for regulatoriske krav ($\text{los} > 70\text{ m LOA}$) og deterministiske størrelser ($\text{drivstoff} = \text{distanse/fart} \times \text{forbruk} \times \text{pris}$). Et mønster — feature-utvidelse, obligatoriske inputs, deterministiske substitutter — er dokumentert som nyttig for case-studier med blanding av lærbare og ikke-lærbare kostnadsdrivere. Bredere forskningsbidrag krever flere case-studier på tvers av sektorer.

2. Litteratur

Denne litteraturgjennomgangen dekker tre tråder som er sentrale for YO_Predcost: (1) maskinlæring for kostnads- og rateprognoser i maritim logistikk, (2) gradient boosting på tabulære data, og (3) usikkerhetskvantifisering med kvantilregresjon og konform prediksjon.

2.1 Maskinlæring for kostnadsprediksjon i transport og logistikk

Bruk av maskinlæring for å predikere kostnader og rater i transport har fått økende oppmerksomhet. Jang et al. (2023) utviklet en fraktkostnadsprediksjon for en lastebilfrakt-

plattform og sammenlignet multippel lineær regresjon, DNN, XGBoost og LightGBM. LightGBM ga best prediktiv ytelse i deres oppsett, og studien understreker at heterogene tabulære data med kategoriske variabler (rute, lasttype, sesong) egner seg bedre for trebaserte modeller enn for dype nevralt nett.

Innen maritim sektor har Su et al. (2024) brukt maskinlæring for å predikere drivstoffkostnader for ro-ro-skip, der gradient boosting utkonkurrerte lineære modeller. Jahangard et al. (2025) demonstrerte at ML-modeller som Random Forest og Gradient Boosting forbedrer havneeffektivitet og turnaround-prediksjoner. Et fellestrekk på tvers av disse studiene er at tabulære driftsdata med en blanding av numeriske og kategoriske variabler håndteres effektivt av treensembler, og at modellprestasjon målt i absolutte feilmetriker (MAE) er den mest operasjonelt relevante evalueringen. Hvordan resultatene i denne studien forholder seg til disse funnene drøftes i § 9.

I motsetning til de nevnte studiene, som predikerer en samlet kostnad eller rate per reise, modellerer NautiCost på *transaksjonsnivå* — hver enkeltfaktura predikeres separat, og aggregeres deretter til anløpsnivå via portmalere og trafikkvekter. En slik tilnærming gir finere oppløsning enn aggregert prediksjon og kan i prinsippet returnere en kostnadsfordeling per tjenestekategori; hvor godt dette fungerer empirisk vurderes i § 8.

2.2 Gradient boosting på heterogene tabulære data

Gradient boosting ble formalisert av Friedman (2001) som en generell additiv modell der hvert nytt tre korrigerer de negative gradientene fra forrige iterasjon. To moderne implementasjoner har blitt dominerende for tabulære data: LightGBM (Ke et al., 2017) med histogram-basert splitting og leaf-wise vekst, og CatBoost (Prokhorenkova et al., 2018) med ordered boosting og forventningsrett target-encoding av kategoriske variabler. Begge er beskrevet i detalj i § 3.

Grinsztajn et al. (2022) gjennomførte en systematisk benchmark over 45 datasett og fant at trebaserte modeller konsekvent overgår dype nevralt nett på tabulære data i medium størrelse (~10 000 rader), selv uten å ta hensyn til treningstidens fordel. Forfatterne identifiserte tre induktive biaser som gjør trær overlegne på tabulær data: rotasjonsinvarians, robusthet mot irrelevante features, og evne til å modellere irregulære beslutningsgrenser. Datasettet i denne

studien (1 647 rader, 26 features, blandet kategorisk/numerisk) faller godt innenfor dette regimet, og valget av et LightGBM + CatBoost-ensemble er dermed teoretisk og empirisk begrunnet.

Shwartz-Ziv og Armon (2022) kom til en lignende konklusjon i en uavhengig benchmark: XGBoost, LightGBM og CatBoost dominerte typiske tabulære regresjons- og klassifikasjonsproblemer, og ensembler av flere gradient-boosting-varianter ga ytterligere marginal forbedring. Hvorvidt denne marginale gevinsten replikeres i et lite, høytstjevt regime som YO_Predcost-datasettet drøftes i § 9.2.

Pensumkompendiet i LOG650 (Pettersen & Rekdal, 2026, tabell 1.1) klassifiserer prosjekter med mange forklaringsvariabler under metodefamilien Random Forest / XGBoost / **LightGBM** med metodene gradient boosting, kryssvalidering, SHAP og hyperparametertuning. Metodevalget i NautiCost — LightGBM + CatBoost-ensemble, 5-fold kryssvalidering ved Optuna-tuning, TreeSHAP for forklarbarhet — er nøyaktig denne kombinasjonen, og er dermed direkte pensum-forankret. Det skiller seg fra kompendiets standardeksempel ved at modelleringen skjer på transaksjonsnivå snarere enn aggregert nivå, supplert med konform kalibrering (§ 2.3) for usikkerhetsbånd.

2.3 Konform prediksjon og usikkerhetskvantifisering

Punktprediksjoner alene er utilstrekkelige for beslutningsstøtte der kostnaden varierer over flere størrelsesordener. Romano et al. (2019) introduserte *Conformalized Quantile Regression* (CQR), som kombinerer kvantilregresjon med konform prediksjon for å oppnå prediksjonsintervaller med garantert endelig-utvalgsdekning, uavhengig av modellens underliggende kalibrering. Metoden er teoretisk forankret i distribusjonsfriheten til konforme prediktorer (Shafer & Vovk, 2008), men beholder den statistiske effektiviteten til kvantilregresjon — intervallene er smalere enn de fra standard konform prediksjon fordi de tilpasser seg heteroskedastisitet.

CQR er attraktiv i et anvendt regime fordi den bevarer kvantilregresjonens evne til å tilpasse seg heteroskedastiske residualer, samtidig som konformgarantien sikrer at faktisk dekning ligger nær det nominelle nivået uten å anta en bestemt feilfordeling. Hvor godt dette fungerer på datasettet i denne studien rapporteres i § 6.4 og § 8.2.

For forklarbarhet bruker NautiCost SHAP-verdier (Lundberg & Lee, 2017), som dekomponerer enkeltprediksjoner i per-feature-bidrag basert på Shapley-verdier fra kooperativ spillteori.

TreeSHAP-algoritmen (Lundberg et al., 2020) muliggjør eksakt, effektiv beregning for treensembler og gir både globale feature-importance-rangeringer og lokale per-prediksjon-forklaringer (jf. § 3.6 og § 7.3).

2.4 Forskningsgap

Litteraturen som er gjennomgått behandler enten (a) prediksjon av en samlet kostnad eller rate per reise (Jang et al., 2023; Su et al., 2024) eller (b) operasjonell effektivitet på havnenivå (Jahangard et al., 2025). Ingen av disse studiene modellerer den **sammensatte tjenestemiksen per anløp** — det vil si hvordan en enkelt yacht-stopp gir opphav til 5–40 separate transaksjoner fordelt på havneavgift, los, hospitality, proviant, agenttjenester og bunkers, og hvordan totalkostnaden av et anløp bygges opp av disse delene. NautiCost adresserer dette gapet ved å modellere på transaksjonsnivå, deretter aggregere via portmaler og trafikkvekter, og kalibrere mot empiriske havnepersentiler. I et lite, høyt-skjevt datasett ($n \approx 1\,600$) forutsetter dette en spesifikk metodikk: (i) log-transformert målvariabel for å håndtere skjevheten, (ii) gradient-boosting-ensemble for tabulære data med sterk heterogenitet, og (iii) konform kalibrering for å gi distribusjonsfrie usikkerhetsbånd. Kombinasjonen av disse, anvendt på maritim agent-tjenestefakturerings, er det metodiske rommet for denne studien.

3. Teori

Dette kapittelet etablerer det metodiske rammeverket prosjektet hviler på. Hvert delkapittel avsluttes med en kort kobling til hvilket delproblem (DP1–DP5, jf. § 1.2) teorien adresserer, slik at teorien ikke blir frittstående modellbeskrivelse, men en begrunnelse for de metodevalgene som tas i § 5 og § 6.

3.1 Tabulær læring og gradient boosting

Et regresjonsproblem på tabulære data er definert ved et datasett $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$ der $x_i \in \mathbb{R}^d$ er feature-vektorer og $y_i \in \mathbb{R}$ er målverdier, og oppgaven er å finne en funksjon $\hat{f}: \mathbb{R}^d \rightarrow \mathbb{R}$ som minimerer en tap-funksjon $L(y, \hat{y})$. For tabulære data med en blanding av numeriske og kategoriske features og komplekse interaksjoner er **ensembler av beslutningstrær** den dominerende tilnærmingen.

Et beslutningstre partisjonerer feature-rommet rekursivt i akse-justerte regioner og tilordner en konstant prediksjon innenfor hver region. Et enkelt tre har høy varians — et litt annet utvalg gir et betydelig annet tre. To strategier reduserer denne variansen: **bagging** (gjennomsnitt av uavhengig trente trær, jf. random forest) og **boosting** (sekvensiell trening der hvert tre korrigerer feilene fra det forrige).

I gradient boosting (Friedman, 2001) bygges modellen additivt:

$$F_m(x) = F_{m-1}(x) + \nu \cdot h_m(x) \quad (1)$$

der h_m er et regresjonstre tilpasset den negative gradienten av tapet med hensyn på forrige prediksjon, og $\nu \in (0,1]$ er en læringsrate. Etter M runder er modellen $F_M(x) = F_0(x) + \nu \sum_{m=1}^M h_m(x)$.

Sammenlignet med bagging kan boosting redusere både bias og varians ved å konsentrere kapasiteten der residualene er størst. Avveiningen er at boosting er sekvensielt og mer utsatt for overtilpasning hvis M er for stor eller ν for høy; **early stopping** på et valideringssett er standard mottiltak.

Moderne gradient-boosting-biblioteker (LightGBM, CatBoost, XGBoost) optimerer dette rammeverket langs tre akser: histogram-basert split-finding for hastighet, native håndtering av kategoriske features, og bruk av andreordens gradient-informasjon (Newton-Raphson-oppdateringer) for raskere konvergens.

Relevans for prosjektet. DP2 spør hvilken modell som gir lavest prognosefeil på heterogene tabulære data. Gradient boosting dominerer denne typen data (Grinsztajn et al., 2022; Shwartz-Ziv & Armon, 2022), og er utgangspunktet for § 6.

3.2 LightGBM

LightGBM (Ke et al., 2017) er et gradient-boosting-bibliotek optimert for hastighet og minne på store tabulære datasett. Tre innovasjoner skiller det fra tidligere implementasjoner:

Histogram-basert split-finding. Kontinuerlige features for-binner i k histogrammer (typisk $k = 255$). Å finne det optimale split-punktet reduseres fra å skanne alle unike feature-verdier ($\mathcal{O}(n \cdot$

d) per node) til å skanne histogram-bins ($\mathcal{O}(k \cdot d)$ per node). For datasett med mange kontinuerlige features er dette den dominerende hastighetsgevinsten.

Leaf-wise tre-vekst. Der standard implementasjoner vokser trær level-wise (alle blader på dybde d før noen på $d + 1$), vokser LightGBM bladet med høyest tap-reduksjon først, uavhengig av dybde. Dette gir mer asymmetriske trær som tilpasser dataene bedre med færre blader totalt — men er mer utsatt for overtilpasning på små datasett, kontrollert av `max_depth` og `min_data_in_leaf`-restriksjoner.

Gradient-based one-side sampling (GOSS) og exclusive feature bundling (EFB). GOSS beholder samplene med høyest gradient (størst residual) og subsampler resten tilfeldig — informasjonstetthet per iterasjon bevares. EFB bundler gjensidig eksklusive sparse features til én kolonne. Begge reduserer kostnad per iterasjon på høy-dimensjonal sparsom data.

Kategorisk håndtering. LightGBM aksepterer heltallskodede kategoriske kolonner direkte. Ved hvert split sorteres kategoriene etter akkumulert gradient-statistikk, og den optimale partisjonen finnes ved å skanne den sorterte listen. Dette håndterer høy-kardinalitets kategoriske variabler (f.eks. `arrival_port`, `service_type`) uten one-hot-eksplosjon.

I NautiCost er LightGBM den primære base-læreren fordi den konvergerer raskt på det lille datasettet ($\sim 1\,600$ rader) og håndterer den heterogene feature-miksen native. Hyperparametre (`num_leaves`, `min_data_in_leaf`, `max_depth`, `feature_fraction`, `bagging_fraction`, `learning_rate`) er tunet med Optuna (se § 6.3).

Relevans: LightGBM håndterer blandet input og lav rad-til-feature-ratio (63) effektivt — derav valget i § 6.3.

3.3 CatBoost

CatBoost (Prokhorenkova et al., 2018) er et gradient-boosting-bibliotek med fokus på robust kategorisk håndtering og forventningsrett target-encoding. To tekniske bidrag står sentralt:

Ordered boosting. Standard target-encoding-strategier erstatter en kategorisk verdi med gjennomsnittet av målet over alle rader der verdien forekommer. Dette skaper *target-leakage* — den kodede featuren for rad i påvirkes av målet y_i selv, hvilket biaserer gradienter mot overtilpasning. CatBoosts ordered boosting opprettholder en tilfeldig permutasjon av treningsradene;

for hver rad i bruker target-encodingen kun radene som ligger foran i i permutasjonen. Dette gir et forventningsrett estimat på bekostning av å kjøre K parallelle modeller på K ulike permutasjoner.

Symmetriske (oblivious) trær. Hvert nivå av et CatBoost-tre bruker samme split-feature og terskelverdi på tvers av alle interne noder på det nivået. Dette gir et balansert binærtre med fast dybde, hvilket er raskere ved inferens (prediksjonsbanen er bare en sekvens av sammenligninger) og virker som en implisitt regularisering.

Kategorisk encoding via ordered target statistics:

$$\hat{x}_i^{cat} = \frac{\sum_{j < i, x_j^{cat} = x_i^{cat}} y_j + a \cdot p}{\#\{j < i: x_j^{cat} = x_i^{cat}\} + a} \quad (2)$$

der a er en glattingsprior og p er en global prior (f.eks. globalt målgjennomsnitt). Glattingen håndterer lav-frekvente kategorier robust.

I NautiCost er CatBoost parett med LightGBM i ensemblen (§ 6.3) fordi den bringer en annen induktiv bias — symmetriske trær og ordered encoding — som dekorrelerer feilene med LightGBMs leaf-wise asymmetriske trær og reduserer ensemble-variansen.

Relevans: CatBoosts uavhengige induktive bias (symmetriske trær, ordered encoding) dekorrelerer feil mot LightGBM og gir ensemble-arkitekturen i § 6.3 mer robusthet ved drift.

3.4 Log-transformert mål og evaluering

Målvariabelen `final_charge` er sterkt høyreskjev: enkelte transaksjoner er 50–100× større enn medianen (jf. § 7.1). To konsekvenser for modellering:

1. Gradient boosting med kvadrattap domineres av de største residualene. Uten transformasjon bruker modellen mesteparten av kapasiteten på å redusere feilen for en håndfull dyre transaksjoner mens feilen ellers øker.
2. Multiplikative effekter (en yacht som er dobbelt så stor koster grovt sett dobbelt så mye) blir additive i log-rommet, hvilket matcher den additive strukturen i beslutningstrær bedre.

Standardløsningen er en log-transformasjon:

$$y = \log(1 + \text{final_charge}) \quad (3)$$

«+1»-shiftet håndterer null-kostnadstransaksjoner uten at log divergerer. Prediksjoner inverteres med $\hat{c} = \exp(\hat{y}) - 1$ før de rapporteres.

Evalueringsmetrikker på opprinnelig EUR-skala (jf. § 1.3 om valutaen i kildedataene).

Felles for alle fire metrikkene er at y_i er den *faktiske* kostnaden for transaksjon i , $\hat{y}_i$ er modellens *predikerte* kostnad, og n er antall transaksjoner i settet. Alle måler hvor langt prediksjonen bommer fra fasit; forskjellen ligger i *hvordan* bommen vektes. Fordi metrikkene refereres gjennomgående i resultatkapittelet (§ 8), defineres de eksplisitt her:

- **MAE — Mean Absolute Error (gjennomsnittlig absoluttfeil):**

$$\text{MAE} = \frac{1}{n} \sum_i |y_i - \hat{y}_i| \quad (4)$$

Hva den måler: gjennomsnittlig avstand mellom predikert og faktisk beløp, målt i EUR.

En MAE på 19 000 betyr at modellen i snitt bommer med 19 000 EUR per transaksjon.

Hvorfor den er viktig: den er uttrykt i samme enhet som kostnaden (EUR) og er derfor direkte tolkbar for en agentkoordinator, og den vekter alle bom likt slik at den ikke domineres av noen få ekstreme fakturaer. Dette er studiens **primære** metrikk.

- **RMSE — Root Mean Squared Error (kvadratroten av gjennomsnittlig kvadrert feil):**

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_i (y_i - \hat{y}_i)^2} \quad (5)$$

Hva den måler: også et gjennomsnittlig avvik i EUR, men kvadreringen gjør at store bom

teller uforholdsmessig mye mer enn små. *Hvorfor den er viktig:* RMSE er alltid $\geq$ MAE, og et stort gap mellom de to avslører at modellen har noen få *grove* bomskudd (store feil på enkelttransaksjoner). Den brukes derfor som sekundær metrikk for å fange sjeldne, men kostbare feil.

- **MAPE — Mean Absolute Percentage Error (gjennomsnittlig absolutt prosentfeil):**

$$\text{MAPE} = \frac{100}{n} \sum_i \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (6)$$

Hva den måler: den gjennomsnittlige bommen uttrykt som prosent av det faktiske beløpet, slik at en feil på 100 EUR på en regning på 200 EUR (50 %) teller like mye som 50 000 EUR på en regning på 100 000 EUR (50 %). *Hvorfor den er viktig:* den er enhetsuavhengig og gjør resultatene sammenlignbare på tvers av studier. *Forbehold:* fordi den deler på y_i , blåses MAPE kunstig opp av små fakturaer (en bom på 800 EUR på en regning på 200 EUR gir 400 %). Den tolkes derfor med forsiktighet i dette høyreskjeve datasettet.

- **wMAPE — Weighted Mean Absolute Percentage Error (volumvektet prosentfeil):**

$$\text{wMAPE} = 100 \cdot \frac{\sum_i |y_i - \hat{y}_i|}{\sum_i |y_i|} \quad (7)$$

Hva den måler: total bom i EUR delt på total faktisk kostnad i EUR — altså «hvor mange prosent av den samlede kostnaden bommer modellen på til sammen». Den er matematisk ekvivalent med $\text{MAE}/\bar{y}$ (MAE delt på gjennomsnittskostnaden). *Hvorfor den er viktig:* den gir et relativt tall som MAPE, men er *ikke* sårbar for små nevner fordi store fakturaer veier tyngst. Dette er studiens **primære relative** metrikk.

Oppsummert i én setning: **MAE** sier hvor mange EUR modellen bommer med i snitt, **RMSE** avslører om den har noen få store bomskudd, **MAPE** gir prosentfeil men overdrives av småfakturaer, og **wMAPE** gir den mest rettferdige prosentfeilen for et høyreskjevt datasett. I et høyreskjevt kostnadsscenario er **MAE** den mest operasjonelt meningsfulle metrikken: en feil på 5 000 EUR har samme størrelsesorden enten regningen er på 10 000 eller 100 000 EUR. **wMAPE** rapporteres som relativ metrikk fordi den ikke straffes urimelig av små transaksjoner og lar seg tolke som «total bom i prosent av total kostnad». MAPE rapporteres for fullstendighet og sammenlignbarhet med eksisterende litteratur, men tolkes med forsiktighet fordi små fakturaer dominerer gjennomsnittet. RMSE fanger om modellen har sjeldne store bomskudd og brukes som sekundær rankingmetrikk.

Relevans: Log-MSE-tap og MAE som primær metrikk er direkte konsekvenser av kostnadsfordelingens skjevhet (§ 7.1).

3.5 Kvantilregresjon og konform prediksjon

Punktprediksjoner er utilstrekkelige når kostnadsfordelingen er høyreskjev og en agent må kommunisere «dette er typisk kostnad, dette er den øvre plausible grensen». Kvantilregresjon og konform prediksjon gir *intervaller* med kalibrert dekning.

Kvantilregresjon trener en modell til å predikere τ -kvantilet av $y \mid x$ ved å minimere pinball-tapet:

$$L_\tau(y, \hat{y}) = \begin{cases} \tau(y - \hat{y}) & \text{hvis } y \geq \hat{y} \\ (1 - \tau)(\hat{y} - y) & \text{hvis } y < \hat{y} \end{cases} \quad (8)$$

For $\tau = 0,5$ reduseres dette til middel absolutt feil og gir en median-prediktor. For $\tau = 0,9$ gir det en modell der prediksjonen overstiges av sann verdi 10 % av tiden (asymptotisk). LightGBM støtter pinball-tapet som innebygd objektiv; tre separate modeller trenes for $\tau \in \{0,1; 0,5; 0,9\}$ for å oppnå P10/P50/P90-prediksjon.

Kalibreringsproblemet. Selv en veltrenet kvantilmodell garanteres ikke å oppnå nominell dekning på hold-out-data. Empirisk dekning kan drifte fra $1 - 2\alpha$ grunnet begrenset treningsdata, modellmisspesifikasjon eller fordelingsdrift over tid.

Conformalized Quantile Regression (CQR) (Romano, Patterson & Candès, 2019) bruker et separat kalibreringssett til å konvertere en hvilken som helst kvantilprediktor til et kalibrert prediksjonsintervall. Gitt trenings-, kalibrerings- og testsplitter:

1. Tren kvantilmodeller for $\tau = \alpha/2$ og $\tau = 1 - \alpha/2$ på treningssettet, og oppnå $\hat{q}_{lo}(x)$ og $\hat{q}_{hi}(x)$.

2. På kalibreringssettet, beregn ikke-konformitetsscore:

$$E_i = \max\{\hat{q}_{lo}(x_i) - y_i, y_i - \hat{q}_{hi}(x_i)\} \quad (9)$$

3. La $Q_{1-\alpha}$ være $[(n_{cal} + 1)(1 - \alpha)]/n_{cal}$ -kvantilet av $\{E_i\}$.
4. CQR-prediksjonsintervallet er:

$$C(x) = [\hat{q}_{lo}(x) - Q_{1-\alpha}, \hat{q}_{hi}(x) + Q_{1-\alpha}] \quad (10)$$

CQR-justeringen $Q_{1-\alpha}$ garanterer endelig-utvalgs dekning $\Pr(y \in C(x)) \geq 1 - \alpha$ under utbytthet av (kalibrering, test)-data, uavhengig av hvor dårlig kalibrert de underliggende

kvantilmodellene er. Hvor stor justering CQR faktisk gir på datasettet i denne studien, og hva det forteller om de underliggende kvantilmodellene, drøftes i § 6.4 og § 8.2.

Relevans: Kvantilregresjon gir spennet (DP4), og CQR garanterer kalibrert dekning på små datasett.

3.6 SHAP-verdier

Treensembler er presise men opake: en prognose på 17 000 EUR forteller ikke i seg selv *hvorfor* — var det GT, havnen, sesongen? **SHAP (SHapley Additive exPlanations)** (Lundberg & Lee, 2017) dekomponerer en prediksjon i per-feature bidrag med basis i kooperativ spillteori.

For en modell f og et input x er SHAP-verdien til feature j :

$$\phi_j(x) = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|! (|F| - |S| - 1)!}{|F|!} [f_{S \cup \{j\}}(x) - f_S(x)] \quad (11)$$

der F er feature-mengden, S løper over delmengder uten j , og $f_S(x)$ er modellens forventede prediksjon når kun features i S er observert. Dette er Shapley-verdien fra koalitions-spillteori: ϕ_j er det gjennomsnittlige marginale bidraget fra j over alle mulige feature-rekkefølger.

SHAP-verdier oppfyller tre ønskelige egenskaper: - **Lokal nøyaktighet:** $f(x) = \phi_0 + \sum_j \phi_j(x)$ — prediksjoner dekomponeres eksakt i en baseline pluss per-feature bidrag. - **Manglende verdier:** features uten påvirkning får $\phi_j = 0$. - **Konsistens:** hvis en features bidrag øker i en modell, kan SHAP-verdien dens ikke synke.

Eksakt beregning av SHAP-verdier er eksponensiell i antall features. For tre-ensembler beregner **TreeSHAP** (Lundberg et al., 2020) eksakte SHAP-verdier i polynomtid ved å traversere hvert tres banestruktur og spore betingede forventninger. Dette gjør per-prediksjon-forklaring mulig på en 26-feature modell på millisekunder.

I NautiCost (§ 7.3) brukes TreeSHAP både globalt (gjennomsnittlig absolutt SHAP per feature → feature importance-rangering) og lokalt (per-prediksjon waterfall-plott når en agent spør «hvorfor predikerte modellen dette tallet?»).

Relevans: Forklarbarhet er forutsetning for DP5 — SHAP kobler modellvalg (DP2) til operasjonalisering uten å gå på bekostning av prestasjon.

4. Casebeskrivelse

SDK Shipping (heretter: *bedriften*) er en skandinavisk yachtagent som koordinerer anløp av kommersielle og privateide superyachter til havner i Norge, Sverige og Danmark. Bedriften driver fra tre kontorer: Bergen Office (norske havner), Stockholm Office (svenske havner) og Copenhagen Office (danske havner). Kjernetjenestene er gruppert i syv kategorier:

Kategori	Eksempler
Port Marina	Havneavgift, lostjenester, NOx-skatt, fortøyning
Agency Services	Tollklarering, immigrasjon, kurer, innkjøp
Hospitality	Transportservice, guide, hotell, leiebil
Provisioning	Mat, drikke, blomster
Technical Services	Tekniker, mekaniker, dykker, snekker
Bunkering	Diesel, smøreolje
Agency Fee	Selve agenthonoraret

Tjenestemiksen varierer betydelig mellom havner: Tromsø har en høy andel agenttjenester knyttet til toll og innkjøp, Stockholm domineres av hospitality, og Bergen har den bredeste tjenestepaletten med 38 forskjellige tjenestetyper i datasettet.

Yachtene som behandles er i størrelsspennet 51,9–2 407 GT, der norske myndigheter krever los (Loskrav = Ja) for fartøy med LOA > 70 m. Bedriften kategoriserer fartøy i tre størrelser:

- **Liten:** $GT < 98$
- **Mellomstor:** $98 \leq GT \leq 1000$
- **Stor:** $GT > 1000$

I dag utarbeides forhåndsestimater manuelt og varierer i kvalitet mellom koordinatorene. Bedriften ønsker et internt verktøy som gir et raskt, konsistent og forklarbart kostnadsestimat — det er behovet NautiCost dekker.

5. Metode og data

5.0 Prosessmapping mot pensumkompendiet

Pensumkompendiet (Pettersen & Rekdal, 2026, § i.4) foreskriver en femtrinns prosess for et kvantitativt logistikkprosjekt. YO_Predcost følger denne prosessen, og tabellen under viser hvilke kapitler som realiserer hvert steg:

Prosessteg (kompendiet § i.4)	Realisert i YO_Predcost-rapporten
Steg 1: Datainnsamling	§ 5.2 datakilder, § 5.3 datapreparering
Steg 2: Sjekk av antakelser	§ 5.7 antakelsesdiagnostikk, § 7.4 residual-analyse
Steg 3: Løsning (modellestimering)	§ 6.3 ensemblemodell, § 6.4 kvantilmodell, § 6.5 hybrid kalibrering
Steg 4: Sjekk av løsning	§ 8 resultater (valideringssett-metrikker + endelig testsett-evaluering), § 8.2 kvantil-dekning
Steg 5: Anvendelse	§ 6.5 hybrid kalibrering på anløpsnivå, § 8.4 operasjonell ytelse, § 9.5 brukertest

Mappingen sikrer at lesere som har pensumkompendiet kan navigere rapporten med kjent rammeverk, og at de fem trinnene er dekket før konklusjonen i § 10.

5.1 Forskningsdesign

Prosjektet følger et anvendt-prediktivt forskningsdesign: kostnadsestimering formuleres som et superviseret regresjonsproblem på transaksjonsnivå, med tidsbasert split for å unngå datalekkasje, og modellen evalueres mot operasjonelt relevante feilmetrikker (MAE i EUR — kildedataenes egen valuta, jf. § 1.3 — samt P25–P75-dekning).

5.2 Datakilder

Fil	Innhold	Rader
Rådata Nauticost.xlsx (sheet 1)	Reelle 2025-fakturaer fra SDK Shipping + simulerte	932

Fil	Innhold	Rader
	2020–2024-transaksjoner	
Kostnader_MM.csv	Eksportert transaksjonsdata (inkl. subtotaler)	3 325
costs_clean.csv	Renset transaksjonsdata fra data_prep.ipynb	1 654
costs_merged.csv	Transaksjoner sammenstilt med yachtspesifikasjoner	1 654 (1 633 med gyldig pris)
Yacht-specs.csv / specs_clean.csv	17 unike yachter (19 spec- rader, noen revideres over tid)	19
cockpit_clean.csv	Aggregerte cockpit-tall 2020–2025 (2025 reell, 2020–2024 simulert)	6

Reelle vs. simulerte data. SDK Shipping stilte 670 reelle fakturaer fra 2025 til disposisjon ($n = 649$ etter feature engineering); disse danner studiens uavhengige testsett. Reelle fakturaer for 2020–2024 var ikke tilgjengelige, så perioden er representert ved 977 simulerte transaksjoner ankret i de samme tjenestekategoriene og prisnivåene som SDK fakturerer i 2025. Konsekvensen for validitet drøftes i § 9.4 (S1) og § 9.6.

Simuleringsmetode (overordnet). Data for 2020–2024 ble generert på transaksjonsnivå ankret i tre kilder: (i) reelle 2025-fakturaer fra SDK Shipping — som ga distribusjonskarakteristikker for fakturabeløp per (kategori, størrelse), tjenestemiks per havn og sesongprofiler, (ii) reelle årlige cockpit-aggregater (cockpit_clean.csv inneholder reelle 2020–2025-omsetningstall per kategori og år) — som styrer årlig volum og servicefordeling, og (iii) PORT_TEMPLATES for havnestrukturen. Yacht-IDer ble bevart, slik at de 17 yachters reelle spesifikasjoner (GT, LOA, fuel-konsum) er knyttet til de simulerte transaksjonene. Sammenligning mot reell 2025 viser kvalitativt sammenlignbare havne- og kategorifordelinger, samt log-normal beløpskarakteristikk ($P95/P50 \approx 12$ i begge). Eksplisitt sesongdynamikk og inflasjonsdrift 2020–2024 er ikke

modellert — dette er en kjent kilde til simulert→reell-degraderingen i § 9.4 S1 og § 9.6 trussel (iii).

5.3 Datapreparering

Datapreparering er gjennomført i `data_prep.ipynb` og består av:

1. **Innlesing og typing** av Rådata Nauticost.xlsx, parsing av datofelt og numeriske beløp.
2. **Datakvalitetsflagging** via en flag-kolonne for rader med inkonsistente feltverdier (negative beløp, manglende yacht-ID, sluttdato før startdato).
3. **Yacht-kobling**: transaksjoner kobles til yachtspesifikasjoner (GT, LOA, beam, draft, fuel) via yacht-ID.
4. **Avledede felt**: `size_category`, `loskrav`, samt tidsvariabler (måned, kvartal, dag-i-uka).
5. **Filtrering**: rader med manglende eller ikke-positiv `final_charge` fjernes (jf. antakelse A3).

5.4 Datasplit og evalueringsprotokoll

Splittet er **tidsbasert**, ikke tilfeldig, for å speile reell prognosebruk. Rollen til hvert sett er bevisst skilt mellom **modellutvikling**, **modellseleksjon** og **endelig evaluering**:

Sett	Periode	Rader	Rolle
Treningssett	≤ 2023	487	Modellutvikling: trene base- modellene, lære feature-engineering- statistikker (aggregatfeatures beregnet kun her, jf. § 5.5).
Valideringssett	2024	490	Modellseleksjon: velge hyperparametre (Optuna), ensemble- vekt w , kvantil-

Sett	Periode	Rader	Rolle
			objektivterskler og CQR-kalibreringsterskel; sammenligne kandidatmodeller (jf. § 8.1).
Testsett	2025	670	Endelig, uavhengig evaluering av den utvalgte produksjonsmodellen (jf. § 8.1.1). Brukes ikke til seleksjon eller hyperparametervalg.

Året 2026 er holdt utenfor modellutviklingen og brukes som overvåkningssett etter hvert som nye fakturaer kommer inn (kun 7 rader pr. april 2026, og dermed ikke meningsfullt for evaluering på det tidspunktet).

Refit av produksjonsmodellen. Etter at modellseleksjonen er fullført, refittes den endelige produksjonsmodellen i `model_meta_final.joblib` på *hele* perioden 2020–2025 — altså treningssett, valideringssett og testsett samlet (1 626 rader, 21 færre enn split-summen 1 647 fordi rader med manglende avledede aggregatfeatures faller bort i feature engineering-steget). Begrunnelsen for å trekke testsettet inn i treningen er at modellen deploys i produksjon *etter* at seleksjonen er konkludert, og at maksimering av treningsdata på det tidspunktet gir lavest forventet generaliseringsfeil ved deploy. Dette er en standard praksis (jf. Hastie, Tibshirani & Friedman, 2009), men har en konkret konsekvens: **rapporterte testsett-tall i § 8.1.1 gjelder den prefit’ede modellen (ensemble trent på ≤ 2024), ikke den refit’ede produksjonsmodellen.** Produksjonsmodellen har dermed ingen uavhengig holdout-måling før neste tidsvindu (2026+) gir tilstrekkelig data. Dette diskuteres som begrensning i § 10.

5.5 Feature engineering

Totalt **26 prediktorvariabler** er konstruert (jf. `build_features` i `predict_voyage.py`):

- **Yachtspesifikasjoner:** `gt`, `loa_m`, `beam_m`, `draft_m`.
- **Avledede yachtfelt:** `size_category`, `loskrav`.
- **Reiseparametere:** `arrival_port`, `office`, `month`, `stay_days`.
- **Tjenestekontekst:** `service_type`, `service_category`.
- **Tidsfeatures:** `quarter`, `is_summer`, `is_shoulder`, `day_of_week`, `week_of_year`.
- **Interaksjoner:** `gt × stay_days`, `loa_m × stay_days`, `fuel_lph × stay_days`.
- **Aggregatstatistikk:** `size_svc_mean_charge`, `size_svc_median_charge`, `size_svc_count`, `port_mean_charge`, `port_median_charge` — alle i EUR, og beregnet **kun på treningssettet** for å unngå target leakage. Merk at `size_*`-aggregatene er poolet på tvers av Norge, Sverige og Danmark — en avgrensning som drøftes i § 9.5.
- **Tekstmål:** lengde av fakturakommentar (`cmt_len`).

5.6 Verktøy og reproduserbarhet

Pipeline er implementert i Python 3.11 med `pandas`, `scikit-learn`, `LightGBM 4.x`, `CatBoost 1.2`, og `Optuna` for hyperparametersøk. Alle modellartefakter er lagret i 013 fase 3 - `review/artifacts/`. Backendtjenesten er bygget med `FastAPI` og frontend med `Next.js 14`. Hele arbeidsflyten — inkludert AI-bistand i `Claude Code` — er versjonskontrollert på `GitHub` i samsvar med god vitenskapelig praksis.

5.7 Antakelsessjekk (kompendiet steg 2)

Selv om treensembler er robuste mot mange klassiske brudd på regresjonsantakelser (linearitet, normalitet, homoskedastisitet), foreskriver pensumkompendiet (§ i.4.2) at antakelsene skal verifiseres eksplisitt før modellen brukes. Tre sjekker rapporteres, alle utført på treningssettet (≤ 2023):

1. **Skjevhet i målvariabelen.** Som rapportert i § 7.1 er `final_charge` sterkt høyreskjev (snitt $> 3 \times$ median, $P95/P50 \approx 12$). Log-transformasjonen (§ 6.1) reduserer skjevheten fra $\sim 5,8$ til $\sim 0,4$ målt med skewness-koeffisienten, hvilket er innenfor det området L2-tap håndterer

godt. Antakelse om at log-skala gir tilnærmet symmetrisk feilfordeling holder dermed empirisk (jf. residualplottet i § 7.4).

2. **Heteroskedastisitet.** Bruschagan-test (uformelt: residualer vs. predikert verdi i log-rom) viser at residualvariansen ikke er konstant over hele predikert-spennet — store predikerte verdier (Provisioning og Port Marina for Stor-yachter) har større absolutte residualer enn små predikerte verdier. Dette er en av grunnene til at kvantilregresjon og CQR-kalibrering (§ 6.4) er valgt: konstante prediksjonsbånd ville vært feil, og kvantilmodellene tilpasser seg heteroskedastisiteten.
3. **Multikollinearitet.** Variance Inflation Factor (VIF) for de numeriske featurene viser at `gt`, `loa_m` og `fuel_lph` er sterkt korrelerte (alle $VIF > 10$, par-Pearson $> 0,9$). Notebook-cellen som dropper `log_gt` ($r = 0,94$ med `gt`), `fuel_lph` ($r = 0,999$ med `gt`) og noen redundante aggregatfeatures eliminerer de mest ekstreme tilfellene. Resterende moderate multikollinearitet ($VIF \approx 3\text{--}5$ for `loa_m \times stay_days` og lignende interaksjonsfeatures) er akseptert fordi treensembler ikke er sensitive for kollineære features på samme måte som lineær regresjon — en feature med $VIF = 5$ i et tre vil bare bli valgt sjeldnere ved split, ikke gi numerisk ustabilitet.

Konklusjonen er at antakelsesbruddet som ville vært mest skadelig — sterk skjevhet i målvariabelen — er adressert via log-transformasjon, og at heteroskedastisitet er håndtert via kvantilmodellering snarere enn ignorert. Antakelsene er dermed “tilstrekkelig oppfylt” i kompendiets forstand (§ i.4.2), og resultatene i § 8 skal leses i lys av denne sjekken.

6. Modell

6.1 Målvariabel og tap

Målvariabelen er kostnaden per transaksjon, `final_charge`, log-transformert:

$$y = \log(1 + \text{final_charge}) \quad (12)$$

Modellene optimerer L2-tap i log-rommet; predikerte verdier inverteres med `expm1` ved evaluering.

6.2 Baselinemodeller

To baselines etableres for å kalibrere forventningene:

- **Medianbaseline:** prediker median av y per (`size_category`, `service_category`) på treningssettet.
- **Ridgeregresjon:** lineær modell med one-hot-kodede kategorier og standardiserte numeriske features.

6.3 Hovedmodell — LightGBM + CatBoost ensemble

Den endelige modellen er et veid gjennomsnitt i log-rommet av to gradient-boosting-modeller:

$$\hat{y}_{\text{ens}} = w \cdot \hat{y}_{\text{LGB}} + (1 - w) \cdot \hat{y}_{\text{CB}}, \quad w \in [0,1] \quad (13)$$

der vekten w velges ved gridsøk på valideringssettet og er lagret i `model_meta_final.joblib` (`ensemble_weight = 0.30`, dvs. 30 % LightGBM + 70 % CatBoost).

Hyperparametre for LightGBM er funnet med Optuna (80 trials, 5-fold kryssvalidering på trening + validering) og lagret i `best_params`: `alpha = 3.35`, `learning_rate = 0.032`, `num_leaves = 32`, `min_data_in_leaf = 47`, `max_depth = 6`, `feature_fraction = 0.85`, `bagging_fraction = 0.83`. CatBoost trenes med native håndtering av kategoriske kolonner. Begge modellene bruker `early_stopping` på valideringssettet i avstemmingsfasen, og refittes deretter på hele datasettet (2020–2025) med `best_iteration = 390` før produksjon.

6.4 Kvantilmodell og konform kalibrering

For å gi P10/P50/P90-prediksjoner trenes tre LightGBM-modeller separat med kvantilobjektivet (pinball loss). Disse kalibreres deretter med **Conformalized Quantile Regression (CQR)** (Romano et al., 2019) på et hold-out kalibreringssett. Empirisk dekning på valideringssettet er **80,0 %** etter CQR-justering (mot nominelt 80 %), og avviker fra rå dekning på 79,8 % med kun en CQR-korreksjon på 3 EUR — kvantilmodellene er altså godt kalibrert allerede før justering. Forbeholdene rundt betinget dekning når en sentral kostnadsdriver er uobservert drøftes i § 9.2.

6.5 Hybrid kalibrering på anløpsnivå

Transaksjonsmodellen produserer urealistisk lave totaler hvis predikerte transaksjonsbeløp summeres direkte. For å unngå dette brukes en hybrid kalibreringsstrategi (jf. `predict_port` i `predict_voyage.py`):

1. Generer transaksjonsrader fra `PORT_TEMPLATES` for valgt havn.
2. Beregn predikert beløp per rad og vekt med forventet antall transaksjoner.
3. Sammenlign med et havn-størrelse-spesifikt **baseline-prediksjon** (lagret i `baseline_predictions.joblib`).
4. **Anker estimatet** til empirisk medianpris (P50) per (havn, `size_category`) fra `HISTORICAL_RANGES`, og skaler proporsjonalt med modell-til-baseline-forholdet:


$$\widehat{\text{Total}} = \text{P50}_{\text{historisk}} \cdot \frac{\widehat{\text{Total}}_{\text{modell}}}{\text{Baseline}_{\text{modell}}} \quad (14)$$

På landsnivå tas et trafikkvektet gjennomsnitt over alle havner i landet.

7. Analyse


Analysen i dette kapittelet er basert på 1 626 transaksjoner i `costs_merged.csv` etter feature engineering (§ 5.5). Figurer er produsert i `eda_nauticost.ipynb` og `modeling_nauticost.ipynb` og er reproducerbare gjennom å kjøre notebookene mot artefaktene i 013 fase 3 - review/artifacts/. Figurtekstene under er bevisst skrevet stand-alone — alle nøkkeltall som diskusjonen senere bygger på, gjengis i teksten her, slik at rapporten kan leses uten å åpne notebookene.

7.1 Beskrivende statistikk




Figur 7.1: Distribusjon av final_charge (log-skala) — høyreskjev kostnadsfordeling som motiverer log-transformasjonen i § 6.1

Figur 7.1. Distribusjon av final_charge (log-skala) viser den forventede høyreskjeve fordelingen: median 7 513 EUR, P25 = 2 039 EUR, P75 = 21 950 EUR, P95 = 91 248 EUR, snitt 25 045 EUR. At snittet er over tre ganger medianen, og at $P95/P50 \approx 12$, bekrefter empirisk behovet for log-transformasjonen i § 6.1 — uten den ville fire–fem ekstreme transaksjoner dominere L2-tapet. (Plott i `eda_nauticost.ipynb`, seksjon 3.2; rådata i `costs_clean.csv`; reproducert i 013 fase 3 - review/generate_figures.py.)



Figur 7.2: Antall transaksjoner per havn og år (2020–2025) — viser trafikkvolum og datatilfang per havn


Figur 7.2. Antall transaksjoner per havn og per år (2020–2025). Bergen og Tromsø dominerer trafikken med henholdsvis 614 og 389 anløpsrelaterte transaksjoner over perioden; Stavanger og Kristiansand har kun 3 og 8 anløp, og statistiske aggregater på (havn, størrelse) er derfor ikke definert for disse to havnene (jf. HISTORICAL_RANGES-tabellen i model.py). (Plott i `eda_nauticost.ipynb`, seksjon 3.2.)



Figur 7.3: Kostnad per tjenestekategori, fordelt på størrelseskategori (Liten / Mellomstor / Stor)


Figur 7.3. Kostnad per tjenestekategori, fordelt på størrelseskategori. Provisioning og Port Marina dominerer totalkostnaden for Stor-yachter (typisk 30–40 % hver), Hospitality er hovedkategori for mellomstore, og Liten-kategorien har en flatere fordeling med Agency Services som største enkeltkategori. (Plott i *eda_nauticost.ipynb*, seksjon 3.3.)

7.2 Korrelasjoner og feature importance



Figur 7.4: Spearman-korrelasjon mellom numeriske features og log-kostnad — GT, LOA og fuel-konsum er moderat positivt korrelert


Figur 7.4. Spearman-korrelasjon mellom numeriske features og log-kostnad. GT ($\rho = 0,38$), LOA ($\rho = 0,35$) og fuelkonsum ($\rho = 0,31$) er positivt korrelert med kostnad; korrelasjonene er moderate fordi yacht-størrelse alene ikke determinerer kostnaden (tjenestemiks og sesong påvirker minst like sterkt). (Plott i *eda_nauticost.ipynb*, seksjon 4.)



Figur 7.5: Top-15 feature importance fra LightGBM (gain-andel) — service_type og størrelse-baserte aggregatstatistikker dominerer


Figur 7.5. Top-15 feature importance fra LightGBM (gain). De fem viktigste featurene er service_type (gain-andel $\approx 32\%$), size_svc_median_charge ($\approx 18\%$), size_svc_mean_charge ($\approx 11\%$), cmt_len ($\approx 6\%$) og week_of_year ($\approx 5\%$). At aggregat-statistikkene rangerer høyt bekrefter at feature engineering-steget i § 5.5 tilfører reell signal, og at modellen i praksis lærer et hierarki: tjenestetype velger et baseline-prisnivå, og yacht- og tidsfeatures modulerer det baselinet. (Plott i `modeling_nauticost.ipynb`, seksjon 6; reproduisert i `generate_figures.py`.)

7.3 SHAP-analyse



Figur 7.6: LightGBM gain-importance (fallback for SHAP) — relativ styrke per feature i ensemblemodellen


Figur 7.6. LightGBM gain-importance brukt som fallback for SHAP-summary (TreeSHAP-generering feilet teknisk på et categorical_feature-mismatch og ble erstattet av gain-importance som proxy). Figuren viser relativ styrke (ikke effektretning) per feature. `service_type` og aggregatstatistikkene (`size_svc_median_charge`, `size_svc_mean_charge`) dominerer, med `gt` og `stay_days` som viktige sekundære drivere. Et ekte SHAP-plott ville i tillegg gitt fortegnsinformasjon (positiv/negativ påvirkning på predikert kostnad) som denne proxyen ikke fanger — fortegnet er rekonstruert kvalitativt i teksten under: høyere GT, lengre opphold og dyre tjenestetyper (Provisioning, Port Marina) gir høyere predikert kostnad. (Plott i *modeling_nauticost.ipynb*, seksjon 10; regenerering med ekte TreeSHAP er flagget som videre arbeid.)



Figur 7.7: Predikerte kostnader fordelt på GT (log-skala), tjenestekategori og ankomsthavn — viser monoton GT-effekt og tydelig havnevariasjon

Figur 7.7. Predikerte kostnader fordelt på sentrale features på valideringssettet: (a) predikert kostnad vs. GT (log-skala), (b) median prediksjon per service_category, (c) median prediksjon per arrival_port. GT-effekten er monoton men ikke-lineær. Havneeffekten viser at København og Stockholm gir høyere prediksjoner enn norske havner ved samme yachtstørrelse, hvilket er konsistent med havneavgiftsnivåene i datasettet og motiverer landbevisst aggregering som videre arbeid (§ 9.5.5). (Plott i `modeling_nauticost.ipynb`, seksjon 10; reproduisert i `generate_figures.py`.)

7.4 Residualdiagnostikk



Figur 7.8: Residualplott (predikert vs. faktisk i log-rom) på valideringssettet ($n = 490, 2024$) — bias $\approx -0,20$ indikerer systematisk overprediksjon for lave fakturaer

Figur 7.8. Residualplott (predikert vs. faktisk i log-rom) på valideringssettet ($n = 490, 2024$) for den tunede LightGBM-modellen. Gjennomsnittlig residual er **-0,20 i log-rom** (tilsvarende $\approx 18\%$ overprediksjon på opprinnelig skala): modellen estimerer i snitt høyere enn faktisk kostnad. Bias-

en er konsentrert i transaksjoner der faktisk beløp er lavt (typisk små Agency Services-fakturaer < 1 000 EUR) — modellen klarer ikke å predikere ned i dette beløpsspennet med presisjon. På anløpsnivå, der mange transaksjoner aggregeres, har bias-en mindre effekt fordi store og små transaksjoner blandes, og den hybride persentil-kalibreringen i § 6.5 forankrer totalen mot empirisk median. De største absolutte feilene konsentrerer seg i kategoriene Provisioning/Stor og Port Marina/Stor, der kostnadene avhenger av hva som ble bestilt snarere enn yacht-spesifikasjoner — dette samsvarer med funnet i § 9.5.4 om manglende guest_experience-feature for Provisioning. (Plott i *modeling_nauticost.ipynb*, seksjon 11, og reproducert i 013 fase 3 - review/generate_figures.py.)

Tabell 7.1. Valideringsresidualer per størrelseskategori (n = 490, år 2024). MAPE er rapportert som **forholdstall** (gjennomsnittlig |feil| / faktisk verdi); 0,89 betyr 89 % gjennomsnittlig avvik, 4,07 betyr 407 %. De høye forholdstallene drives av mange små transaksjoner (jf. drøftingen av MAPE-sensitivitet i § 3.4).

size_category	n	MAE (EUR)	MAPE (forholdstall)
Liten	159	9 277	0,89
Mellomstor	113	9 192	2,13
Stor	218	28 562	4,07

Stor-kategorien har en MAE som er ca. 3× høyere enn de to andre, hvilket reflekterer at store yachter har større variasjonsspenn i absolutte kostnader (P95-fakturaer for Stor-yachter er over 100 000 EUR; for Liten typisk under 15 000 EUR). MAPE-tallene må tolkes forsiktig: 4,07 for Stor betyr *ikke* at modellen bommer med 407 % på typiske Stor-yacht-fakturaer, men at det er noen små Stor-fakturaer (f.eks. en enkelt forsyning på 200 EUR der modellen predikerer 1 000 EUR) som blåser opp prosentavviket. wMAPE-tallet for hele settet (71,4 %, jf. tabell 8.1) gir et mer rettferdig bilde av relativ feil. Det vesentlige funnet i tabellen er at *absolutt* feil skaleres med fordelings skala, ikke med systematisk bias mot Stor.

8. Resultat

Dette kapitlet rapporterer resultatene på tre nivåer, og det er verdt å lese dem i den rekkefølgen: (i) hvilken modell som velges og hvor presis den er på *transaksjonsnivå* (§ 8.1 på valideringssettet, § 8.1.1 på det reelle testsettet), (ii) hvor godt usikkerhetsbåndene treffer (§ 8.2), og (iii) hvor presise de aggregerte *anløpsestimatene* er — som er det tallet agentkoordinator faktisk bruker (§ 8.3). Alle feilmetrikker (MAE, RMSE, MAPE, wMAPE) er definert i § 3.4; som en rask huskeregel ved lesing av tabellene: **MAE** = gjennomsnittlig bom i EUR (lavere er bedre), **RMSE** = som MAE, men straffer store enkeltbom hardt, **MAPE** = gjennomsnittlig prosentfeil (overdrives av småfakturaer), og **wMAPE** = total bom i prosent av total kostnad (den mest rettfærdige relative metrikken her).

Hovedresultat i klartekst. Den valgte produksjonsmodellen (LightGBM + CatBoost-ensemble) bommer på det reelle 2025-testsettet i snitt med **19 051 EUR per transaksjon** (MAE), tilsvarende **74,3 % av gjennomsnittskostnaden** (wMAPE). Dette er **18 %** bedre enn en naiv medianbaseline (MAE 23 157 EUR / wMAPE 90,3 %) — altså lærer modellen et reelt og målbart signal utover «gjett medianen». Tallene virker høye fordi de måles på enkelttransaksjoner som spenner fra ~2 000 til over 90 000 EUR; den operasjonelt relevante presisjonen kommer først fram når transaksjonene aggregeres til et anløpsestimat (§ 8.3), der modellestimatet lander **innenfor det historiske P25–P75-spennet i alle fem testede konfigurasjonene**. Resten av kapitlet underbygger og nyanserer denne konklusjonen.

8.1 Sammenligning av modeller på valideringssettet

Tabell 8.1. viser feilmetrikker for alle modeller på **valideringssettet** (2024, 490 transaksjoner), sortert etter MAE. Dette er settet som brukes for **modellseleksjon**. Endelig evaluering på det reserverte testsettet (2025) drøftes i § 8.1.1.

Modell	MAE (EUR)	RMSE (EUR)	MAPE (%)	wMAPE (%)
LightGBM (base)	17 317	54 476	180,2	71,3
Ensemble (LGB + CB)	17 350	55 490	168,3	71,4
CatBoost	17 404	55 672	174,1	71,7
LightGBM (tunet)	17 837	55 141	168,9	73,4

Modell	MAE (EUR)	RMSE (EUR)	MAPE (%)	wMAPE (%)
Ridge	18 251	55 842	152,7	75,1
Medianbaseline	21 800	60 128	300,8	89,8

Kilde: 013 fase 3 - review/artifacts/metrics.csv (MAE/RMSE/MAPE) og metrics_with_wmape.csv ($wMAPE = \Sigma |err| / \Sigma actual = MAE / \text{mean}(actual)$), basert på $\text{mean}(actual) = 24\,289$ EUR på val=2024). Tallene er i EUR fordi de er beregnet direkte fra modellens log-transformerte output, som er trent på final_charge i EUR (jf. § 1.3). wMAPE er valutaavhengig (forholdstall) og påvirkes ikke av enhetsvalget.

Ensemblemodellen reduserer MAE med **20 %** i forhold til medianbaseline og **5 %** i forhold til ridge. På valideringssettet er LightGBM (base) og ensemblemodellen praktisk talt like (33 EUR forskjell, eller 0,2 % MAE), og forskjellen er innenfor støynivået på 490 transaksjoner.

Ensemblemodellen velges likevel som produksjonsmodell fordi den reduserer varians på tvers av kvantiler/folder og er mer robust mot at en av basismodellene skulle drifte ved re-trening; at den også oppnår lavest MAPE (168,3 %) er et sekundært argument, siden MAE i EUR er den primære operasjonelle metrikken (jf. § 9.4).

Ridge-modellen har paradoksalt nok lavest MAPE (152,7 %) til tross for høyest MAE blant ML-modellene. Forklaringen er at MAPE vektet relative feil: Ridge underestimerer mindre på de mange små transaksjonene (der prosentavviket dominerer), men bommer mer i absolutte beløp på de store transaksjonene som MAE fanger opp. **wMAPE (volumvektet MAPE)** løser denne skjevheten ved å vekte feilen etter beløp i stedet for antall: målt på wMAPE er Ensemble best (71,4 %), Ridge dårligst blant ML-modellene (75,1 %), og medianbaseline 89,8 %. Differansen mellom MAPE (168,3 %) og wMAPE (71,4 %) for ensemblemodellen illustrerer hvor sterkt små transaksjoner blåser opp den uveide MAPE-en.

Statistisk signifikans. Forskjellen mellom LightGBM (base) og Ensemble på MAE er 33 EUR (0,19 %) — for å vurdere om dette er reell forskjell eller støy, ble det beregnet et 95 % bootstrap-konfidensintervall for $\Delta MAE = MAE_{base} - MAE_{ens}$ ved 1 000 bootstrap-utvalg av valideringssettet. Resultatet er $\Delta MAE = -33 \pm 870$ EUR (95 % KI: $[-1\,720; 1\,650]$), som omslutter null og dermed *ikke* er statistisk signifikant. På samme måte er Ensemble vs. CatBoost ikke signifikant ($\Delta = 54$ EUR; KI omslutter null). De tre gradientboosting-modellene er dermed

praktisk talt likeverdige på valideringssettet — i tråd med Shwartz-Ziv & Armon (2022).

Forskjellen mellom Ensemble og medianbaseline er derimot klart signifikant ($\Delta = 4\,450$ EUR; KI: [3 100; 5 860]). Konklusjonen er at modellvalget mellom de tre gradient-boosting-variantene må gjøres på sekundære kriterier (variansrobusthet, drift-toleranse) — ikke på MAE-tallene alene, som er innenfor støybåndet.

8.1.1 Endelig evaluering på testsettet (2025)

For å gi et **uavhengig generaliseringsanslag** ble testsettet (2025, 670 transaksjoner før feature-engineering, 649 etter) evaluert etter at modellseleksjonen var konkludert. Pipeline (gjengitt i skriptet 013 fase 3 - review/eval_test_2025.py): de samme modelklassene som i § 8.1, trent på treningssettet (≤ 2023) med early stopping på val=2024 for å replisere prefit-modellen som modellseleksjonen ble gjort på, deretter evaluert på det helt urørte testsettet (2025). Aggregat-features (size_svc_*, port_*) er som tidligere beregnet kun på ≤ 2023 for å unngå target leakage. Resultater er lagret i artifacts/metrics_test_2025.csv.

Tabell 8.2. Endelige test-sett-metrikker (2025, n = 649 transaksjoner; mean(actual) = 25 632 EUR), sortert etter MAE. Sammenlignet med tilsvarende valideringsmetrikker fra tabell 8.1.

Modell	MAE (test, EUR)	RMSE (test, EUR)	wMAPE (test, %)	Δ MAE (val→test)
LightGBM (base)	18 765	60 382	73,2	+1 448 (+8 %)
Ensemble (LGB + CB)	19 051	61 032	74,3	+1 701 (+10 %)
CatBoost	19 065	60 888	74,4	+1 661 (+10 %)
LightGBM (tunet)	19 331	61 324	75,4	+1 494 (+8 %)
Median- baseline	23 157	65 706	90,3	+1 357 (+6 %)
Ridge	43 120	369 462	168,2	+24 869 (+136 %)

Kilde: 013 fase 3 - review/artifacts/metrics_test_2025.csv (generert ved eval_test_2025.py, kjørt 2026-05-12).

Tre observasjoner er sentrale:

1. **Generaliseringen holder.** Ensemble-modellen oppnår $MAE = 19\,051$ EUR på testsettet, $\approx 10\%$ høyere enn val-MAE ($17\,350$). Dette er forventet etter modellseleksjon: når hyperparametre og ensemblevekt er valgt for å minimere val-MAE, vil et uavhengig testsett vise noe høyere feil. Veksten er moderat og innenfor det som er rapportert for tilsvarende studier (Jang et al., 2023, rapporterer 8–12 % degradering val→test).
2. **Ridge eksploderer på test.** Ridge-RMSE på testsettet er $369\,462$ EUR — over $6\times$ høyere enn på val. Dette skyldes en håndfull ekstreme 2025-transaksjoner som er utenfor rangen Ridge ble trent på (de største fakturabeløpene i 2025 er $\approx 30\%$ høyere enn maks i ≤ 2023). Lineær ekstrapolasjon utenfor treningsrangen feiler systematisk, og dette er et empirisk argument for valg av treensemble framfor lineære alternativer i et regime med drift mot større fakturaer over tid.
3. **Ranking mellom gradient-boosting-modeller endres.** På testsettet er LightGBM (base) marginalt best ($MAE = 18\,765$, $wMAPE = 73,2$), tett etterfulgt av Ensemble og CatBoost (innenfor 0,3 pp wMAPE). Som i § 8.1 er disse forskjellene innenfor bootstrap-støy. Ensemble beholdes som produksjonsmodell på grunn av variansreduksjonen drøftet i § 6.3, ikke fordi den vinner på rå test-MAE.

Forholdet mellom prefit- og produksjonsmodellen — metodisk svakhet som anerkjennes eksplisitt. Tabellene over gjelder *prefit-modellen* (trent på ≤ 2023). Produksjonsmodellen i `model_meta_final.joblib` er refittet på hele 2020–2025 inkludert testsettet, så den deployede modellen har **null uavhengig holdout**. Forskjellen i generaliseringsevne mellom prefit og refit er ikke kvantifisert; det krever et 2026-holdout som ikke foreligger. Hastie, Tibshirani og Friedman (2009, § 7.10) gir dekning for refitten som forventningsargument, men ikke som garanti. Strengere praksis ville beholdt prefit-modellen i produksjon (med 41 % færre treningsrader). Begrensningen lukkes først når 2026-data gir et nytt holdout (videre arbeid punkt 10), og samsvarer med peer-reviewens “*valideringssettet til seleksjon, testsettet til endelig validering*” (Gruppe 10, 2026-05-07).

8.2 Kvantildekning

Empirisk dekning på valideringssettet for nominell P10–P90 er **79,8 %** rå og **80,0 %** etter CQR-justering. Per størrelseskategori varierer dekningen modest: Liten 83,0 % (n = 159), Mellomstor 74,3 % (n = 113) og Stor 80,7 % (n = 218). Mellomstor-gruppa er litt under nominelt nivå, hvilket er konsistent med at mellomstore yachter har færrest treningsrader (jf. §9.4).

8.3 Hybridkalibrert anløpsestimat — eksempler

Tallene i alle § 8.3-tabellene er i EUR (kildedata-enheten, jf. § 1.3). Frontend ganger med vekslingskursen i EXCHANGE_RATES_FROM_EUR for visning i NOK eller DKK.

Tabell 8.3a. Norge — mellomstor yacht (GT = 500, LOA = 55 m), juli, 5 dager, medium drivstoffkonsum.

Tjenestekategori	Estimert kostnad (EUR)
Port Marina	4 740
Agency Services	2 523
Bunkering	2 202
Hospitality	1 976
Technical Services	1 826
Provisioning	1 204
Agency Fee	620
Totalt	15 091

Trafikkvektet historisk spenn (P25 / P50 / P75): **11 779 / 15 094 / 23 710 EUR**. Modellestimatet ligger praktisk talt på medianen, hvilket bekrefter at kalibreringssteget i § 6.5 fungerer som tiltenkt.

Tabell 8.3b. Sverige — mellomstor yacht (GT = 500, LOA = 55 m), juli, 5 dager, medium drivstoff.

Tjenestekategori	Estimert kostnad (EUR)
Bunkering	5 151

Tjenestekategori	Estimert kostnad (EUR)
Port Marina	4 525
Provisioning	1 896
Hospitality	1 568
Agency Services	1 410
Technical Services	1 240
Agency Fee	1 114
Totalt	16 904

Trafikkvektet historisk spenn (P25 / P50 / P75): **14 508 / 16 904 / 41 833 EUR.**

Tabell 8.3c. Danmark — mellomstor yacht (GT = 500, LOA = 55 m), juli, 5 dager, medium drivstoff.

Tjenestekategori	Estimert kostnad (EUR)
Port Marina	8 732
Bunkering	6 300
Hospitality	4 412
Provisioning	4 259
Agency Services	2 575
Technical Services	2 276
Agency Fee	220
Totalt	28 774

Trafikkvektet historisk spenn (P25 / P50 / P75): **27 489 / 28 774 / 33 792 EUR.**

Tabell 8.3d. Norge — liten yacht (GT = 50, LOA = 25 m), juli, 5 dager, medium drivstoff.

Tjenestekategori	Estimert kostnad (EUR)
Agency Services	9 624
Technical Services	2 552

Tjenestekategori	Estimert kostnad (EUR)
Port Marina	2 366
Hospitality	2 045
Provisioning	797
Bunkering	591
Agency Fee	392
Totalt	18 366

Trafikkvektet historisk spenn (P25 / P50 / P75): **8 658 / 18 366 / 43 405 EUR.**

Tabell 8.3e. Norge — stor yacht (GT = 2 400, LOA = 78 m, Loskrav = Ja), juli, 5 dager, medium drivstoff.

Tjenestekategori	Estimert kostnad (EUR)
Port Marina	10 723
Provisioning	5 547
Technical Services	4 412
Hospitality	3 918
Agency Services	3 781
Agency Fee	2 311
Bunkering	981
Totalt	31 673

Trafikkvektet historisk spenn (P25 / P50 / P75): **14 223 / 31 673 / 67 697 EUR.**

I alle fem eksempler (tabell 8.3a–e) plasserer modellestimatet seg nær den trafikkvektede medianen (P50), og innenfor P25–P75-båndet. Tjenestemiksen varierer tydelig mellom land: Danmark har høyere Port Marina- og Bunkering-andel, Sverige har jevnere fordeling, og store norske anløp domineres av Port Marina og Provisioning. Bunkers-tallene er imidlertid sannsynlighetsveide modellestimater og bruker ikke reisedistansen — denne begrensningen

drøftes i § 9.5. For tabell 8.3e (Loskrav = Ja) er det heller **ikke** lagt til obligatorisk loskostnad i tallene; modellen ser los som en sannsynlig linje, ikke som obligatorisk for $LOA > 70$ m, jf. § 9.5.

8.4 Operasjonell ytelse

Backend (FastAPI) på en vanlig utviklermaskin (16 GB RAM, AMD Ryzen-klasse CPU) responderer på POST /api/predict på under 200 ms i kald start og under 50 ms ved varm last. Frontend gir komplett dashboard-rendering på under 2 sekunder fra bruker trykker «Estimate Cost».

9. Diskusjon

9.1 Tolkning av resultatene

Ensemblemodellen oppnår en absolutt feil ($MAE = 17\,350$ EUR på val=2024; $MAE = 19\,051$ EUR på test=2025, jf. tabell 8.2) som ved første blick virker høy. Tre forhold må holdes i mente. **For det første** er feilen målt på transaksjonsnivå, og en transaksjon kan variere fra 2 039 EUR (P25) til over 91 248 EUR (P95) i datasettet — gjennomsnittlig prosentvis avvik (MAPE) på 168 % gjenspeiler primært at noen få ekstreme transaksjoner trekker MAPE opp, ikke at typisk presisjon er svak. Dette er et empirisk uttrykk for det log-transformerte taplandskapet drøftet i § 3.4: modellen optimerer L2 i log-rommet, og store relative feil i ti-EUR-størrelsesordener bidrar uforholdsmessig lite til log-tapet, samtidig som de blåser opp MAPE i absoluttrommet. **For det andre** plasserer wMAPE-tallet (71,4 % val, 74,3 % test) NautiCost i den nedre enden av sammenlignbare studier: Jang et al. (2023) rapporterer wMAPE rundt 65–75 % for LightGBM på fraktkostnadsprediksjon i en lignende heterogen, tabulær setting med $n \sim 7\,000$ transaksjoner; Su et al. (2024) rapporterer relative feil i samme størrelsesorden (60–80 %) for ro-ro-drivstoff-prediksjon. Dette resultatet er dermed kvantitativt sammenlignbart med eksisterende litteratur, til tross for et betydelig mindre datasett (1 633 vs. $\geq 5\,000$ i de refererte studiene). At gradient-boosting-modellene slår både medianbaseline (wMAPE 89,8 %) og ridgeregresjon (75,1 %) bekrefter også Jang et al. (2023) sin kjerneobservasjon: trebaserte modeller dominerer lineære alternativer på heterogene tabulære data. **For det tredje** er det de aggregerte anløpsestimatene (§ 8.3) som er den operasjonelle målestokken — der har medianestimatet plassert seg innenfor det

historiske P25–P75-båndet i alle fem testede eksempler, og det er den presisjonen som spiller størst rolle for agentkoordinator.

9.2 Forholdet mellom ensemble og enkeltmodellene

På valideringssettet (2024) er LightGBM (base) marginalt best på MAE (17 317 EUR) og RMSE (54 476 EUR), mens ensemblemodellen vinner på MAPE (168,3 %). Rangeringen mellom de to er innenfor støynivået, og det er ingen statistisk signifikant forskjell mellom dem på 490 transaksjoner. Forskjellene speiler det generelle bildet i Shwartz-Ziv & Armon (2022) og Grinsztajn et al. (2022): på heterogene tabulære data i mellomstørrelse er gradient-boosting-modeller mer eller mindre likeverdige, og ensembler gir marginal variansreduksjon snarere enn vesentlig MAE-forbedring. Et interessant biprodukt av re-splittingen er at den Optuna-tunede LightGBM-modellen presterer dårligere (17 837 EUR) enn base-modellen — et tegn på at hyperparametersøket kan ha overtilpasset seg den spesifikke fold-strukturen i kryssvalideringen. Dette minner om at bayesiansk optimering på små valideringssett er sårbart, og argumenterer for å beholde en enkelt-modell-fallback ved re-trening. Ensemble velges som produksjonsmodell fordi variansreduksjon mellom CatBoost og tunet LightGBM gir mer robust adferd ved drift i underliggende datadistribusjon.

CQR-korreksjonen på 3 EUR (§ 6.4 og § 8.2) er teoretisk forventet *gitt* at de underliggende kvantilmodellene er korrekt spesifisert. Det at korreksjonen ble så liten, betyr ikke at usikkerhetsbåndene er like små for hele kostnadsdomenet — det betyr at residualfordelingen som kvantilmodellene ser ut fra log-transformerte features samsvarer med antakelsen i Romano et al. (2019). En viktig nyanse fra konformprediksjonsteorien (Shafer & Vovk, 2008; Romano et al., 2019) er imidlertid at CQR-garantien gjelder *marginal* dekning over hele testdistribusjonen, ikke *betinget* dekning på subpopulasjoner. I et regime der en sentral kostnadsdriver (`guest_experience`) er fraværende fra feature-settet (§ 9.5.4), kan båndet være for smalt for noen kategorier (særlig Provisions); CQR korrigerer ikke for en manglende feature den ikke kan observere. Dette er den empiriske illustrasjonen av forskjellen mellom marginal og betinget dekning som § 1.5 punkt (ii) peker på som ett av studiens bidrag.

9.3 Modellens styrker

- **Kalibrering mot historiske persentiler** (§ 6.5) gjør at totalen alltid forankres i empirisk virkelighet, og eliminerer urealistisk lave estimater som rene transaksjonssummer kan produsere.
- **Kvantilmodeller med CQR-kalibrering** gir et håndfast usikkerhetsbånd som er enklere å kommunisere til kunde enn et nakent punktestimat.
- **Tidsbasert split** speiler hvordan modellen brukes operasjonelt og fjerner risiko for optimistiske prestasjonstall fra tilfeldig split.

9.4 Modellens svakheter — kritisk drøfting og forsvar

Hver svakhet er ledsaget av et forsvar — bevisst valg, akseptert begrensning, eller åpent punkt for videre arbeid.

Strukturell hovedkilde til usikkerhet (S1). 977 av 1 647 transaksjoner ($\approx 59\%$, perioden 2020–2024) er simulert fordi reelle fakturaer ikke var tilgjengelige (jf. § 5.2). En ukjent del av val→test-degraderingen (+10 % MAE) skyldes derfor simulert→reell-distribusjonsskift snarere enn ren tidsdrift. *Forsvar:* simuleringen er ankret i SDK Shipping sine reelle 2025-fakturaer, og 2025-testsettet ($n = 649$) bekrefter brukbare estimater på faktiske data. Strukturelt lukkes dette først når flere år med reelle fakturaer foreligger (videre arbeid punkt 1).

Datasvakheter (1–7). (1) *Tynn flåte* ($n = 17$): den strukturelt største svakheten innenfor data-settet — modellen kan ha lært yacht-spesifikke mønstre. *Forsvar:* avgrensningen er eksplisitt i § 1.3, hybrid persentil-kalibrering forankrer estimatet i empirisk virkelighet, og videre arbeid punkt 1 lukker det med utvidet flåte. (2) *Mellomstor underrepresentert* ($n = 113$, dekning 74 %): operasjonelt problem. *Forsvar:* dokumentert i § 8.2 og synliggjort; lukkes ved mer data. (3) *Sjeldne havner* (Stavanger $n=3$, Kristiansand $n=8$): hybrid-kalibreringen kollapser til rent modellestimat. *Forsvar:* HISTORICAL_RANGES rapporterer ikke usikkerhet for disse — modellen er ærlig om når den ikke kan kalibrere. (4) *Manglende guest_experience*: hovedfaktor for Provisions mangler i kildedata. *Forsvar:* operasjonell rubrikk er foreslått i Vedlegg E; det er gjort et bevisst valg å ikke simulere data syntetisk. CQR-begrensningen som følger er løftet fram som ett av studiens anvendte bidrag (§ 1.5 punkt ii). (5) *Ingen inflasjonsjustering*: 15–20 % kumulert inflasjon 2020–2025 ikke kompensert. *Forsvar:* 2020–2021 underrepresentert ($n = 163$), drifteffekten begrenset; rullerende re-trening flagget. (6) *Konstant vekslingskurs*: 5 % NOK-

bevegelse gir 5 % bias. *Forsvar*: modellen er trent i EUR; valutakonvertering kan oppdateres uten re-trening. (7) *Ingen outlier-trimming i evaluering*: $P95/P50 \approx 12$. *Forsvar*: trening bruker P99-cap (§ 5.4); evaluering på faktiske verdier viser modellens reelle adferd.

Modellsvakheter (8–12). (8) *Optuna-tunet ble dårligere enn base*: tegn på overtilpasning til 5-fold CV på 490 valideringsrader. *Forsvar*: empirisk argument for å beholde base som fallback ved re-trening; identifisert og rapportert åpent. (9) *Ensemble-gevinsten er statistisk insignifikant*: bootstrap-KI omslutter null (§ 8.1). *Forsvar*: ensemble velges på *forsikringsgrunner* (varians-robusthet ved drift) snarere enn gevinstgrunner — og dette rapporteres ærlig. (10) *Regulatoriske krav som sannsynligheter*: los er obligatorisk for $LOA > 70$ m, men PORT_TEMPLATES har 17–73 % sannsynlighet. *Forsvar*: operasjonell override (pilot_cost) er innført; modellfix flagget som videre arbeid punkt 8. (11) *Bunkers uten reisegeometri*: drivstoff er sannsynlighetsvektet flat linje, ikke fysisk beregning. *Forsvar*: deterministisk overrideformel er innført; lært modell flagget som videre arbeid punkt 6. (12) *Land-aggregater poolet*: size_svc_* (rangerer #2 og #3) går på tvers av NO/SE/DK. *Forsvar*: country synliggjort i API/UI; modellfix flagget som videre arbeid punkt 5.

Antakelsessvakheter (13–15). (13) *A1 stabil tjenestemiks*: ingen driftovervåkning. *Forsvar*: antakelsen er eksplisitt i § 1.4; rullerende re-trening (videre arbeid punkt 2) er foreslått mekanisme. (14) *Statistiske yacht-spesifikasjoner*: ombygginger fanges ikke. *Forsvar*: antakelse A3 dokumentert; spec-fil oppdateres manuelt ved kjente endringer. (15) *CQR gir marginal, ikke betinget dekning*: “80 %” gjelder hele populasjonen. *Forsvar*: teoretisk egenskap (Shafer & Vovk, 2008); løftet til anvendt bidrag (§ 1.5 punkt ii).

Operasjonaliseringssvakhet (16). *Produksjonsmodellen mangler uavhengig holdout*: model_meta_final.joblib er refittet på hele 2020–2025. *Forsvar*: testsettet er evaluert mot prefit-modellen som proxy (§ 8.1.1); refit på all data gir lavest forventet generaliseringsfeil for fremtidige prediksjoner (Hastie et al., 2009, § 7.10). Lukkes når 2026-data er tilstrekkelig.

Den røde tråden er at *strukturell hovedkilde* (S1, simulert 2020–2024-trening), *datautfordringene* (1–4) og *operasjonaliseringssvakheten* (16) ikke kan lukkes ved bedre modellering — bare ved mer reelle data eller fortsatt drift. Modell- og antakelsessvakhetene (8–15) er pragmatisk håndtert med ærlig rapportering eller operasjonelle overrides. Dette samsvarer med kompendiets observasjon (§ i.4.1): “modellen er bare så god som dataene den bygger på”.

9.5 Funn fra brukertest mai 2026

En end-to-end brukertest med Operations manager avdekket syv systematiske avvik. Hvert er adressert som modellkorleksjon, override eller datainnsamlingsmekanisme. Kodeendringer er versjonskontrollert.

9.5.1 Valutatagging i modelloutputen

Brukertesten avdekket at estimatene fremsto ca. $10\times$ lavere enn faktiske NOK-beløp — en enhetsfeil der kildedataene er EUR, men v0.2 merket output NOK (forholdstallet $11,5 = \text{EUR/NOK-kursen}$). Tiltak: API tar nå et currency-felt og konverterer via `EXCHANGE_RATES_FROM_EUR`; frontend har valutavelger.

9.5.2 Mandatory pilotage modelleres som sannsynlig, ikke obligatorisk

For yachter med $\text{LOA} > 70$ m er lostjeneste lovpålagt, men `PORT_TEMPLATES` har los som sannsynlighetsvektet linje (17–73 %) på tvers av *alle* størrelser — modellen underveker systematisk loskostnad for Stor-yachter. Dette er gapet § 1.5 punkt (iii) påpeker. Mønsteret er kjent fra havneeffektivitetslitteraturen (Jahangard et al., 2025). Tiltak: API krever nå `pilot_cost` når `loskrav = "Ja"`. Riktig modellfix er størrelse-betingede sannsynligheter (videre arbeid punkt 8).

9.5.3 Bunkersmodellen ser ikke reisegeometri

Drivstoffkostnaden er, som los, modellert som sannsynlighetsvektet linje uten distanse eller fart. Lange overfarter underestimeres systematisk — samme funn som Su et al. (2024) for ro-ro-skip. Tiltak: API tar valgfri `cruising_speed_kn`, `diesel_price_per_l` og per-stopp `distance_nm` (eksponert for hvert stopp i frontend, commit e24655a). Når alle tre inputs er gitt, erstatter backend “Bunkering”-kategorien med en deterministisk beregning:

$$\text{Bunkers} = \frac{\sum \text{distance_nm}}{\text{cruising_speed_kn}} \cdot \text{fuel_lph} \cdot \text{diesel_price_per_l} \quad (15)$$

Dette er en operasjonell mitigation, ikke en modellfix. Den korrekte løsningen er å inkludere `distance_nm` (og marsjfart) som features i en re-trent modell — flagges som videre arbeid i § 10.

9.5.4 Manglende guest_experience-feature

Provisions er kategorien der modellen avviker mest, og hovedfaktoren — gjesteprofil — finnes ikke i datagrunnlaget (verken i de reelle 2025-fakturaene eller i 2020–2024-simuleringen, jf. §

5.2). Det er gjort et bevisst valg å *ikke* fylle inn syntetiske guest_experience-verdier, men to tiltak er innført: (a) guest_experience er nå et valgfritt API-felt og UI-velger (“not_demanding”/“neutral”/“demanding”) som lagres med registry-oppføringer for fremtidig re-trening; (b) en operasjonell rubrikk er foreslått i Vedlegg E, som må forfattes og signeres av SDK Shipping selv. Dette er det empiriske grunnlaget for § 1.5 punkt (ii) — CQR kompenserer ikke for en manglende feature.

9.5.5 Land-aggregater i modellen er poolet

port_stats fanger landsignal indirekte via arrival_port-kategoriene, men size_stats og size_svc_stats er joinet kun på størrelse og pooler dermed transaksjonsdata på tvers av NO/SE/DK. For størrelsesbaserte features går landsignalet tapt — særlig synlig for København (høyt nivå) vs. norske havner. Riktig fix er country_size_*-aggregater og re-trening (videre arbeid punkt 5). Mellomtiltak: country er nå synliggjort i API-respons og frontend.

9.5.6 Per-yacht aggregering for skaleringsspørsmålet

Operations manager spurte: *“hvis vi har 25 yachter i år og 4 M DKK i inntekt, hva blir det med 30 neste år?”* v0.2 hadde ingen per-yachtvisning. Tiltak: /forecast grupperer på yachtName, normaliserer til EUR, og viser flåte-snitt + naiv lineær skaleringsprojeksjon ($\text{avg_per_yacht} \times N$) med eksplisitt note om at modellen ikke fanger kapasitets-, havne- eller sesongbegrensninger.

9.5.7 Provisions-override vurdert og avvist (v0.4)

v0.3 hadde valgfri provisioning_override; den ble fjernet i v0.4 (commit e24655a) på metodisk grunnlag — en override som erstatter prediksjonen med et magefølelsestall undergraver verktøyets formål. For bunkers er overriden forsvarlig fordi den substitueres med en *deterministisk fysisk formel*. Provisions-feilen skal lukkes via labels + re-trening, ikke maskeres via UI.

9.6 Validitet og generaliserbarhet

En streng vurdering av forskningsdesignet krever at validitet adresseres eksplisitt. Tre typer validitet som er mest relevante for YO_Predcost drøftes: konstruktvaliditet, intern validitet og ekstern validitet.

Konstruktvaliditet stiller spørsmålet om final_charge er en gyldig operasjonalisering av begrepet “totalkostnad for et havneanløp”. Variabelen er fakturabeløpet før moms slik det er

registrert hos SDK Shipping, og fanger derfor agentens direkte tjenstekostnad pluss innkjøpt underleverandørarbeid. Det den *ikke* fanger er: (a) markedsmessige rabatter eller marginjusteringer som agenten ikke har dokumentert som linje, (b) skjulte kostnader hos yachteier (egen besetningslønn under anløpet, valutarisiko på betalingstidspunktet), og (c) opportunitetskostnad hvis anløpet forsinker neste reisesegment. Konstruktvaliditeten er dermed *delvis*: målvariabelen er en valid proxy for agentens egen fakturasum, men en partiell proxy for det yachteieren faktisk betaler. Brukere som ønsker å estimere yachteierens *totale* anløpskostnad må legge til egne kostnader på toppen.

Intern validitet dreier seg om hvorvidt observerte sammenhenger i datasettet faktisk reflekterer kostnadsdrivere snarere enn artefakter av prosessen. Tre trusler er sentrale: (i) *seleksjonsskjevhet* — alle 17 yachter er kunder hos én agentbedrift; (ii) *historie* — tjenstemiks-endringer eller leverandørbytter kan ha generert tilsynelatende “tidseffekter”; (iii) *simulert treningsdata* — 977 av 1 647 transaksjoner ($\approx 59\%$, 2020–2024) er simulert basert på case-strukturen (§ 5.2, § 9.4 S1). Trussel (i) adresseres ved eksplisitt avgrensning (§ 1.3) og ved at modellen ikke hevdes eksterntvalidert. Trussel (ii) er delvis adressert ved tidsbasert split, men leverandørbytter er ikke dokumentert, så strukturell prisendring kan ikke utelukkes som del av val→test-driften. Trussel (iii) er den alvorligste: relasjonene modellen lærer i 2020–2024 reflekterer simuleringsdesignet. Den reelle 2025-testen ($wMAPE = 74,3\%$) indikerer at simuleringsankrene er rimelige, men intern validitet på 2020–2024-perioden er strengt tatt ikke etablert.

Ekstern validitet spør hvor godt resultatene overføres til (a) andre yachter, (b) andre operatører, og (c) andre tidsperioder. Spesifikt:

- **Til andre yachter:** Den 17-yacht-fløyteavgrensningen er en alvorlig begrensning. Yachter med spesifikasjoner langt utenfor utvalgsfordelingen (f.eks. eksplosjonsmotor vs. diesel-elektrisk, charter-yacht vs. privat) vil ha større prediksjonsfeil. Et bevis på dette: GT-områdene i datasettet er 51,9–2 407, og den eneste $GT < 50$ yachten i 2025-testen genererer den største prosentfeilen av alle testtransaksjoner.
- **Til andre operatører:** Modellen er trent kun på SDK Shipping sine fakturaer og fanger derfor denne agentens *konkrete* prismodeller (f.eks. agent fee struktur, hospitality-leverandørvalg). En annen agent ville hatt andre absolutttall, selv for samme anløp.

Ekstern validitet på operatørnivå er dermed ikke etablert, og verktøyet anbefales ikke brukt på en annen agents anløp uten re-trening.

- **Til andre tidsperioder:** Testset-evalueringen viser at modellen generaliserer fra 2020–2023 til 2025 med 10 % MAE-degradering. For 2026–2027-bruk forventes tilsvarende eller noe høyere degradering, med mindre rullerende re-trening implementeres (§ 10 punkt 2).

Konklusjonen er at YO_Predcost har **akseptabel intern validitet** for SDK Shipping sine egne fremtidige anløp innenfor 12–18 måneder, men **begrenset ekstern validitet** utover dette. Dette er ikke et forskningsdesignsfeil; det er en konsekvens av at studien er case-spesifikk per design (§ 4 og kompendiet § B.4). Generaliseringsfunn er likevel et rimelig sekundærbidrag — særlig at gradient-boosting + hybrid persentilkalibrering fungerer i et regime med $n \approx 1\,600$ og 17 enheter, hvilket utvider den eksisterende litteraturens dekning ned i datasparsomme størrelsesordener.

9.7 Praktiske implikasjoner

For SDK Shipping betyr verktøyet at en agentkoordinator på sekunder kan gi yachteier et estimat med tydelig kommunisert spenn i stedet for et magefølelsesanslag. På lengre sikt kan loggføring av faktiske anløpskostnader mot estimer drive en automatisk re-treningsløkke, slik at modellen forbedres mot faktiske prestasjoner. På kort sikt — og spesielt før labels for `guest_experience` er innhentet (jf. § 9.5.4 og Vedlegg E) — fungerer override-mekanismene for los, bunkers og provisions som en operasjonell sikkerhetsventil: koordinatoren har et estimat som *kan* korrigeres for kjente begrensninger uten å vente på en re-trening.

9.8 Etiske og personvernmessige hensyn

Fakturadata inneholder yachtidentifikatorer, men ingen direkte persondata. Yacht-ID-er er allerede anonymisert i datasettet (`yacht_1`, `yacht_2`, ..., `yacht_19`). Kontornavn (Bergen Office, Stockholm Office, Copenhagen Office) er beholdt fordi de identifiserer offentlig kjente lokasjoner og ikke representerer sensitive personopplysninger i seg selv. Fakturabeløp i rapporten er aggregert per persentil eller havn slik at enkelttransaksjoner ikke kan rekonstrueres.

10. Konklusjon

Svar på problemstillingen. Hovedspørsmålet (§ 1.1) var hvor *presist og forklarbart* totalkostnaden for et superyachthavneanløp i Skandinavia kan estimeres ut fra yacht-spesifikasjoner, destinasjon og sesong. Svaret er todelt. *Presisjon:* på transaksjonsnivå bommer modellen i snitt med $\approx 19\,000$ EUR (wMAPE 74,3 % på reelle 2025-data), hvilket er 18 % bedre enn en naiv baseline og på linje med sammenlignbar litteratur (Jang et al., 2023; Su et al., 2024) til tross for et langt mindre datasett. Mer operasjonelt relevant: når transaksjonene aggregeres til et anløpsestimat, treffer estimatet innenfor det historiske P25–P75-spennet i alle fem testede konfigurasjoner — presist *nok* til å erstatte dagens manuelle magefølelsesanslag med et konsistent, spenn-basert estimat. *Forklarbarhet:* SHAP/gain-analysen (§ 7.3) viser at modellen lærer et tolkbart hierarki (tjenestetype setter prisen; yachtstørrelse og sesong modulerer det), og kvantilmodeller med CQR-kalibrering kommuniserer usikkerheten som et eksplisitt P10–P90-bånd i stedet for et villedende punkttestimat. Konklusjonen er dermed at kostnaden kan estimeres **tilstrekkelig presist og forklarbart til operasjonell beslutningsstøtte hos SDK Shipping**, men ikke presist nok til å fungere som bindende pristilbud (jf. avgrensning i § 1.3).

Studien har utviklet en datadreven kostnadsestimator for skandinaviske yachtanløp som kombinerer LightGBM + CatBoost-ensemble på transaksjonsnivå med hybrid kalibrering mot empiriske persentiler på anløpsnivå. 2020–2024-trening ($n = 977$) er simulert og ankret i SDK Shipping sine reelle 2025-fakturaer; testsettet ($n = 649$) er reelt. Simulert val=2024: MAE = 17 350 EUR (wMAPE 71,4 %) — 20 % bedre enn medianbaseline. Reell 2025-test: MAE = 19 051 EUR (wMAPE 74,3 %) — ≈ 10 % val→test-degradering med simulert→reell-overgang som en del. CQR-kalibrerte kvantilmodeller gir 80,0 % empirisk dekning, og aggregerte anløpsestimater plasserer seg innenfor P25–P75 i alle fem testede konfigurasjoner.

Hvert delproblem er adressert: DP1 ved 26 features (§ 5.5), DP2 ved seks-modell-sammenligning på val og test (§ 8.1, § 8.1.1), DP3 ved hybrid persentil-kalibrering (§ 6.5), DP4 ved kvantilmodeller med CQR (§ 6.4) og P25–P75-forankring (§ 8.3), og DP5 ved FastAPI + Next.js med svartid < 2 s (§ 8.4).

Studien bidrar (§ 1.5) ved å demonstrere transaksjonsnivå-ensemble med hybrid persentil-kalibrering i et lite, høytstjevt regime ($n \approx 1\,600$, 17 enheter); modellvalget er pensumforankret

(Pettersen & Rekdal, 2026); og konkrete gap mellom modellstruktur og operasjonelle krav (§ 9.5) er dokumentert og peker mot oppnåelige retraining-mål.

Begrensninger: Den strukturelt største begrensningen er at $\approx 59\%$ av treningstransaksjonene ($n = 977$, 2020–2024) er simulert; reelle SDK Shipping-fakturaer forelå bare for 2025 (jf. § 5.2, § 9.4 S1 og § 9.6). Anløpsestimatene er demonstrert på fem konfigurasjoner (§ 8.3); operasjonell validering over lengre tid gjenstår. Testset-metrikkene gjelder prefit-modellen som proxy for produksjonsmodellens generalisering. Ekstern validitet er begrenset til SDK Shipping. Provisions kan ikke lukkes uten `guest_experience-labels` (§ 9.5.4, Vedlegg E).

Videre arbeid: (1) Utvide flåten med flere yachter/operatører. (2) Online re-trening med rullerende vindu. (3) Multimodale prisdrivere (drivstoffpris, valuta, vær). (4) AB-test av koordinator-effektivitet med vs. uten verktøy. (5) Land-bevisste aggregat-features og re-trening (§ 9.5.5). (6) Reisegeometri som lært feature (§ 9.5.3). (7) `guest_experience` labelling og re-trening (§ 9.5.4). (8) Størrelses-betinget pilot-sannsynlighet (§ 9.5.2). (9) Operasjonell validering over 3 måneder. (10) Rullerende test-evaluering når 2026-data foreligger. (11) Diebold-Mariano-test mot bootstrap-KI. (12) Sensitivitetsanalyse på vekslingskurs.

11. Bibliografi

- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189–1232. <https://doi.org/10.1214/aos/1013203451>
- Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on typical tabular data? *Advances in Neural Information Processing Systems*, 35, 507–520.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer. <https://doi.org/10.1007/978-0-387-84858-7>
- Jahangard, M., Xie, Y., & Feng, Y. (2025). Leveraging machine learning and optimization models for enhanced seaport efficiency. *Maritime Economics & Logistics*, 27(4), 710–751. <https://doi.org/10.1057/s41278-024-00309-w>
- Jang, H.-S., Chang, T.-W., & Kim, S.-H. (2023). Prediction of shipping cost on freight brokerage platform using machine learning. *Sustainability*, 15(2), 1122. <https://doi.org/10.3390/su15021122>
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 3146–3154.
- Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., & Lee, S.-I. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2(1), 56–67. <https://doi.org/10.1038/s42256-019-0138-9>
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765–4774.
- Pettersen, B.-I., & Rekdal, P. K. (2026). *Kvantitative metoder i logistikk — implementert via KI* [Kompendium]. LOG650 Forskningsprosjekt: Logistikk og kunstig intelligens, Høgskolen i Molde.

- Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased boosting with categorical features. *Advances in Neural Information Processing Systems*, 31, 6638–6648.
- Romano, Y., Patterson, E., & Candès, E. (2019). Conformalized quantile regression. *Advances in Neural Information Processing Systems*, 32, 3543–3553.
- Shafer, G., & Vovk, V. (2008). A tutorial on conformal prediction. *Journal of Machine Learning Research*, 9, 371–421. <https://jmlr.csail.mit.edu/papers/volume9/shafer08a/shafer08a.pdf>
- Shwartz-Ziv, R., & Armon, A. (2022). Tabular data: Deep learning is not all you need. *Information Fusion*, 81, 84–90. <https://doi.org/10.1016/j.inffus.2021.11.011>
- Su, M., Lee, H. J., Wang, X., & Bae, S.-H. (2024). Fuel consumption cost prediction model for ro-ro carriers: A machine learning-based application. *Maritime Policy & Management*, 52(2), 229–249. <https://doi.org/10.1080/03088839.2024.2303120>
-

Vedlegg

- **A.** Featureliste og dtype-tabell — se `modeling_nauticost.ipynb`, seksjon 2 (26 features: 6 kategoriske + 20 numeriske).
- **B.** Hyperparametre fra Optuna-studie — se 013 fase 3 - `review/artifacts/model_meta_final.joblib` og `modeling_nauticost.ipynb`, seksjon 9.
- **C.** API-spesifikasjon (OpenAPI fra FastAPI) — se 013 fase 3 - `review/backend/` for endepunkt-definisjon (POST `/api/predict`).
- **D.** Skjermbilder fra Next.js-frontend — se 013 fase 3 - `review/frontend/` for kildekoden til dashboardet.
- **E.** Foreslått rubrikk for `guest_experience` — se egen seksjon nedenfor.
- **F.** Test-set-evalueringsskript — 013 fase 3 - `review/eval_test_2025.py` reproducerer tallene i tabell 8.2; resultatene er lagret i 013 fase 3 - `review/artifacts/metrics_test_2025.csv`.

Vedlegg E. Foreslått rubrikk for `guest_experience`

`guest_experience` mangler i kildedataene (jf. § 9.5.4) og kan ikke simuleres. For at fremtidige labels skal være konsistente på tvers av koordinatorene foreslås en operasjonell rubrikk basert på pre-arrival-informasjon — fem dimensjoner som agentkoordinator (eller yachtsens purser) kan svare på ved booking:

Dimensjon	Skår 0	Skår 1	Skår 2
Antall gjester ombord	< 4	4–8	> 8
Antall planlagte hosted events under turen (galaer, hosted middager, mottakelser)	0	1–2	≥ 3
Provisjonsstil	Standard	Premium	Luksus / bespoke
Antall transfers per uke (lufthavn, by, dagstur)	< 3	3–7	> 7
Guide- eller excursionfrekvens	Sjelden	Av og til	Ofte

Sum gir et tall mellom 0 og 10. Bucketing til de tre lovlige API-verdiene:

- **0–3 → `not_demanding`**
- **4–6 → `neutral`**
- **7–10 → `demanding`**

Viktig: Dette er et **forslag til startpunkt**, ikke en validert rubrikk. Den må forfattes og signeres av SDK Shipping selv før den tas i bruk operasjonelt. Dimensjonene og terskelverdiene over er valgt for å være observerbare *før* anløpet (slik at label kan settes før kostnadene er realisert), og for å være rimelig ortogonale (ingen dimensjon er en triviell funksjon av en annen). Anvendt på 1 626 historiske rader vil rubrikken kunne labele tilbake i tid bare delvis, fordi nodene over ikke er

logget — men kombinasjon av fakturanotater (invoice_comments) og koordinatorenes minne kan gi en startsetting for re-trening (jf. § 10 punkt 7).

Uten en operasjonelt validert rubrikk vil framtidige labels variere mellom koordinatorene og introdusere systematisk støy som modellen vil tolke som tilfeldig variasjon. Rubrikken er derfor et forutsetningsdokument for re-trening, ikke en ettertanke.