

NautiCost — Datadreven kostnadsestimering for yachthavneanløp i Skandinavia
LOG650 Forskningsprosjekt, vår 2026 — Gruppe 11, Jørgen Rene (individuell)

Jørgen Rene

2026-05-25

Table of Contents

Sammendrag	3
Abstract.....	3
Takk til.....	4
1. Innledning.....	4
1.1 Problemstilling	5
1.2 Delproblemer	5
1.3 Avgrensninger	5
1.4 Antakelser.....	6
1.5 Akademisk bidrag.....	6
2. Litteratur.....	7
2.1 Maskinlæring for kostnadsprediksjon i transport og logistikk	7
2.2 Gradient boosting på heterogene tabulære data.....	8
2.3 Konform prediksjon og usikkerhetskvantifisering	9
2.4 Forskningsgap.....	9
3. Teori	10
3.1 Tabulær læring og gradient boosting.....	10
3.2 LightGBM.....	11
3.3 CatBoost.....	12
3.4 Log-transformert mål og evaluering.....	13
3.5 Kvantilregresjon og konform prediksjon.....	14
3.6 SHAP-verdier	15
4. Casebeskrivelse	16
5. Metode og data	17
5.0 Prosessmapping mot pensumkompendiet.....	17
5.1 Forskningsdesign	18
5.2 Datakilder	18
5.3 Datapreparering	19

5.4 Datasplit og evalueringsprotokoll.....	19
5.5 Feature engineering	21
5.6 Verktøy og reproduserbarhet.....	21
5.7 Antakelsessjekk (kompendiet steg 2)	21
6. Modell.....	22
6.1 Målvariabel og tap	22
6.2 Baselinemodeller	23
6.3 Hovedmodell — LightGBM + CatBoost ensemble	23
6.4 Kvantilmodell og konform kalibrering.....	23
6.5 Hybrid kalibrering på anløpsnivå	24
7. Analyse	24
7.1 Beskrivende statistikk.....	25
7.2 Korrelasjoner og feature importance	27
7.3 SHAP-analyse.....	29
7.4 Residualdiagnostikk	30
8. Resultat.....	32
8.1 Sammenligning av modeller på valideringssettet.....	32
8.1.1 Endelig evaluering på testsettet (2025)	33
8.2 Kvantildekning	35
8.3 Hybridkalibrert anløpsestimat — eksempler	35
8.4 Operasjonell ytelse	38
9. Diskusjon	38
9.1 Tolkning av resultatene	38
9.2 Forholdet mellom ensemble og enkeltmodellene	39
9.3 Modellens styrker	40
9.4 Modellens svakheter — kritisk drøfting og forsvar	40
9.5 Funn fra brukertest mai 2026	42
9.6 Validitet og generaliserbarhet.....	44
9.7 Refleksjon over prosessens utfordringer	46
9.8 Praktiske implikasjoner	47
9.9 Etiske og personvernmessige hensyn	47
10. Konklusjon	47
11. Bibliografi.....	48
Vedlegg.....	50

Versjon 2.1 — 2026-05-25. Andre utkast. Endringer fra v1.1: navneretting (Renè → Rene), kapittelnummerering ryddet, beskrivende figurtekster, “Takk til” og engelsk Abstract lagt til (jf. malen), bibliografi alfabetisk sortert (APA 7), Figur 7.6-caption rettet til ærlig gain-importance (jf. § 9.7), TNR 12 pt + 1,5 linjeavstand i Word.

Sammendrag

NautiCost er et beslutningsstøtteverktøy som estimerer totalkostnaden for et superyachthavneanløp i Norge, Sverige eller Danmark før yachten ankommer. Verktøyet baserer seg på 1 647 historiske tjenestetransaksjoner (2020–2025) fra Yachting Operations, koblet mot 17 yachters spesifikasjoner. Metodevalget er pensumforankret (Pettersen & Rekdal, 2026, tabell 1.1): gradient boosting + kryssvalidering + SHAP + hyperparametertuning. Kostnaden modelleres på transaksjonsnivå med log-transformert mål og en LightGBM + CatBoost-ensemble. Prediksjoner aggregeres via portmaler og trafikkvekter, og kalibreres mot empiriske persentiler (P25/P50/P75) per (havn, størrelse). Kildedata er i EUR; frontend konverterer til NOK/DKK ved API-grensa. På valideringssettet (2024, n = 490) oppnår ensemblet **MAE = 17 350 EUR, wMAPE = 71,4 %** — 20 % bedre enn medianbaseline. På det uavhengige testsettet (2025, n = 649) oppnår samme modelklasse **MAE = 19 051 EUR, wMAPE = 74,3 %** — $\approx 10\%$ degradering val→test, forventet etter seleksjon. Modellen er pakket som FastAPI + Next.js med svartid under to sekunder.

Abstract

NautiCost is a pre-arrival decision-support tool that estimates the total cost of a superyacht port call in Norway, Sweden or Denmark. Trained on 1,647 service transactions (2020–2025) from Yachting Operations covering 17 yachts, it follows a curriculum-anchored methodology (Pettersen & Rekdal, 2026, Table 1.1): gradient boosting, cross-validation, SHAP and hyper-parameter tuning. Cost is modelled per transaction with a log-transformed target and a LightGBM + CatBoost ensemble, then aggregated via port templates and traffic weights, and

calibrated against empirical P25/P50/P75 percentiles per (port, size). Source data are in EUR; the frontend converts to NOK/DKK at the API boundary. Validation (2024, n = 490): **MAE = €17,350 / wMAPE = 71.4 %** — 20 % better than median baseline. Hold-out test (2025, n = 649): **MAE = €19,051 / wMAPE = 74.3 %** — a ≈ 10 % val→test degradation, as expected from model selection. Deployed as FastAPI + Next.js with sub-two-second response.

Takk til

Denne rapporten er resultatet av et selvstendig prosjekt som har dratt nytte av flere bidragsytere. Først og fremst takk til **Yachting Operations** for å ha stilt 2020–2025-fakturadata og yacht-spesifikasjoner til disposisjon, og til *agency manager* som tok seg tid til brukertesten i mai 2026 — funnene i § 9.5 hadde ikke vært mulige uten denne dialogen. Videre takk til foreleserne **Bjørn-Inge Pettersen** og **Per Kristian Rekdal** for kompendiet *Kvantitative metoder i logistikk* — implementert via KI (2026) og for veiledning gjennom semesteret; metodevalget i NautiCost er direkte forankret i deres rammeverk (§ 2.2 og § 5.0). Takk også til medstudent i Gruppe 10 (Julie) for grundig peer-review 2026-05-07, hvis innspill er sporet og lukket i § 9.7.

Til slutt en åpen merknad om AI-bruk: deler av koden, figurene og rapportteksten er utviklet i samarbeid med **Anthropic Claude** (Claude Code i terminal), i tråd med høgskolens retningslinjer om transparent KI-bruk. Alle resultattall er likevel verifisert mot kildedata og reproducerbare via skriptene i 013 fase 3 - review/.

1. Innledning

Internasjonale superyachter genererer betydelige tjenesteinntekter for skandinaviske havneagenter, men kostnadsbildet ved et havneanløp er komplekst: ett anløp består typisk av 5–40 separate transaksjoner fordelt på havneavgift, los, hospitality, proviant, agenttjenester og bunkers. I dag estimeres totalkostnaden manuelt av agentkoordinator basert på erfaring og oppslag i tidligere fakturaer, hvilket er tidkrevende og inkonsistent. Resultatet er at yachtereiere ofte mottar grove anslag som senere må justeres.

Dette prosjektet utvikler et datadrevet estimeringsverktøy — *NautiCost* — som tar inn en yachts spesifikasjoner og en tenkt reise (land, måned, oppholdslengde, drivstoffnivå) og returnerer en totalpris fordelt på tjenestekategori, sammen med et historisk kostnadsspenn (P25–P75) for konteksten anløpet hører til.

1.1 Problemstilling

Hovedspørsmål: Hvor presist og forklarbart kan totalkostnaden for et superyachthavneanløp i Skandinavia estimeres ut fra yachtspesifikasjoner, destinasjon og sesong, basert på historiske transaksjonsdata?

1.2 Delproblemer

1. **DP1 — Datagrunnlag.** Hvilke variabler i Yachting Operations sine fakturaer og kjøpsordrededata har størst forklaringskraft for kostnaden per transaksjon?
2. **DP2 — Modell.** Hvilken læringsmodell gir lavest prognosefeil (MAE/RMSE) på et tidsbasert testsett, gitt en sterkt høyreskjev kostnadsfordeling?
3. **DP3 — Kalibrering.** Hvordan kan en transaksjonsmodell aggregeres til realistiske totalkostnader per havneanløp, og kalibreres mot historiske persentiler slik at estimatene blir konservative?
4. **DP4 — Usikkerhet.** Hvordan kan estimatets usikkerhet kommuniseres til agentkoordinator, slik at sluttkunden får et realistisk spenn og ikke et villedende punkt estimat?
5. **DP5 — Operasjonalisering.** Hvordan kan modellen pakkes inn i en lett tilgjengelig webtjeneste som svarer innen to sekunder?

1.3 Avgrensninger

- **Geografi:** Kun Norge, Sverige og Danmark. 12 havner totalt: Bergen, Tromsø, Svolvær, Ålesund, Kristiansand, Stavanger (NO); Stockholm, Göteborg, Malmö (SE); København, Esbjerg, Fredericia (DK).
- **Periode:** Treningsdata fra perioden 2020–2025. Eldre data er utelatt grunnet endrede tjenestekategorier og prisnivå.
- **Yachtklasse:** Modellen er trent på 17 superyachter med GT i intervallet 51,9–2 407 (median 152 GT, LOA 18,9–79,2 m). Ekstrapolering til langt mindre eller langt større fartøy er ikke validert.

- **Valuta:** Kildedata fra Yachting Operations er denominert i **EUR** — cockpit-rapportene (004 data/cockpit_2020.csv til cockpit_2025.csv) har eksplisitte EUR-kolonneoverskrifter, og fakturabeløpene i costs_clean.csv (final_charge) ligger i EUR-størrelsesorden (typisk 1 000–10 000 EUR per transaksjon for et superyacht-anløp). Modellen er derfor trent og rapporteres i EUR. Frontend konverterer til NOK eller DKK ved API-grensa via konstantene i EXCHANGE_RATES_FROM_EUR (kurs mai 2026: EUR/NOK $\approx 11,50$, EUR/DKK = 7,46 — DKK er fastlåst mot EUR via ERM II). Konstantene oppdateres mot ECBs referansekurs ved behov og introduserer en ekstra usikkerhetsskilde for NOK-rapporterte tall (jf. § 9.5). Inflasjonsjustering er ikke gjennomført.
- **Forretningsmål:** Verktøyet gir kostnadsestimater og ikke pristilbud. Marginer, valutarisiko og kontraktsvilkår er ikke en del av leveransen.

1.4 Antakelser

- **A1.** Historisk tjenestesammensetning per havn (fanget i PORT_TEMPLATES) er stabil i prediksjonshorisonten 0–12 måneder.
- **A2.** Trafikkvektene per havn (antall historiske anløp) er en rimelig proxy for fordeling av framtidige anløp i samme land.
- **A3.** Fakturabeløp i datasettet er korrekt registrert i final_charge-feltet, og rader uten gyldig pris ($\text{final_charge} \leq 0$ eller manglende) er feilregistreringer som kan fjernes uten å skape skjevhet.
- **A4.** En log-transformasjon på kostnaden gir en tilstrekkelig symmetrisk feilfordeling til at MAE/RMSE-baserte modeller fungerer godt.

1.5 Akademisk bidrag

Studien adresserer tre hull i litteraturen (jf. § 2.4):

1. **Transaksjonsnivå-aggregering med empirisk persentilkalibrering.** Eksisterende studier (Jang et al., 2023; Su et al., 2024) modellerer én total kostnad per reise; havneeffektivitetsstudier (Jahangard et al., 2025) modellerer aggregat på havnenivå. Ingen fanger den sammensatte tjenestemiksen per yacht-anløp (5–40 transaksjoner over syv kategorier). Bidraget er en transaksjonsnivå-ensemble med trafikkvektet aggregering og hybrid persentilkalibrering i et lite, høytskjevt regime.

2. **Distribusjonsfri usikkerhet under skjult heterogenitet.** CQR (Romano et al., 2019) er teoretisk etablert, men sjelden anvendt der en sentral kostnadsdriver er *uobserverbar*. Vi dokumenterer empirisk hva CQR oppnår *gitt* korrekt spesifisert kvantilmodell, og hvor den ikke kompenserer for manglende feature (gjesteprofil for Provisions) — et bidrag til debatten om marginal vs. betinget dekning i anvendte regimer.
 3. **Mønster for hybride ML + regulatoriske/deterministiske kostnader.** Brukertest (§ 9.5) avdekket at rene datadrevne modeller feiler systematisk for regulatoriske krav ($\text{los} > 70 \text{ m LOA}$) og deterministiske fysiske størrelser ($\text{drivstoff} = \text{distanse} / \text{fart} \times \text{forbruk} \times \text{pris}$). Vårt mønster — feature-utvidelse + obligatoriske inputs + deterministiske formler — er relevant utover maritim sektor.
-

2. Litteratur

Denne litteraturgjennomgangen dekker tre tråder som er sentrale for NautiCost: (1) maskinlæring for kostnads- og rateprognoser i maritim logistikk, (2) gradient boosting på tabulære data, og (3) usikkerhetskvanifisering med kvantilregresjon og konform prediksjon.

2.1 Maskinlæring for kostnadsprediksjon i transport og logistikk

Bruk av maskinlæring for å predikere kostnader og rater i transport har fått økende oppmerksomhet. Jang et al. (2023) utviklet en fraktkostnadsprediksjon for en lastebilfrakt-plattform og sammenlignet multippel lineær regresjon, DNN, XGBoost og LightGBM. LightGBM ga best prediktiv ytelse i deres oppsett, og studien understreker at heterogene tabulære data med kategoriske variabler (rute, lasttype, sesong) egner seg bedre for trebaserte modeller enn for dype nevrale nett.

Innen maritim sektor har Su et al. (2024) brukt maskinlæring for å predikere drivstoffkostnader for ro-ro-skip, der gradient boosting utkonkurrerte lineære modeller. Jahangard et al. (2025) demonstrerte at ML-modeller som Random Forest og Gradient Boosting forbedrer havneeffektivitet og turnaround-prediksjoner. Et fellestrekk på tvers av disse studiene er at tabulære driftsdata med en blanding av numeriske og kategoriske variabler håndteres effektivt av treensembler, og at modellprestasjon målt i absolutte feilmetrikker (MAE) er den mest

operasjonelt relevante evalueringen. Hvordan våre egne resultater forholder seg til disse funnene drøftes i § 9.

I motsetning til de nevnte studiene, som predikerer en samlet kostnad eller rate per reise, modellerer NautiCost på *transaksjonsnivå* — hver enkeltfaktura predikeres separat, og aggregeres deretter til anløpsnivå via portmalere og trafikkvekter. En slik tilnærming gir finere oppløsning enn aggregert prediksjon og kan i prinsippet returnere en kostnadsfordeling per tjenestekategori; hvor godt dette fungerer empirisk vurderes i § 8.

2.2 Gradient boosting på heterogene tabulære data

Gradient boosting ble formalisert av Friedman (2001) som en generell additiv modell der hvert nytt tre korrigerer de negative gradientene fra forrige iterasjon. To moderne implementasjoner har blitt dominerende for tabulære data: LightGBM (Ke et al., 2017) med histogram-basert splitting og leaf-wise vekst, og CatBoost (Prokhorenkova et al., 2018) med ordered boosting og forventningsrett target-encoding av kategoriske variabler. Begge er beskrevet i detalj i § 3.

Grinsztajn et al. (2022) gjennomførte en systematisk benchmark over 45 datasett og fant at trebaserte modeller konsekvent overgår dype nevralt nett på tabulære data i medium størrelse (~10 000 rader), selv uten å ta hensyn til treningstidens fordel. Forfatterne identifiserte tre induktive biaser som gjør trær overlegne på tabulær data: rotasjonsinvarians, robusthet mot irrelevante features, og evne til å modellere irregulære beslutningsgrenser. Vårt datasett (1 647 rader, 26 features, blandet kategorisk/numerisk) faller godt innenfor dette regimet, og valget av et LightGBM + CatBoost-ensemble er dermed teoretisk og empirisk begrunnet.

Shwartz-Ziv og Armon (2022) kom til en lignende konklusjon i en uavhengig benchmark: XGBoost, LightGBM og CatBoost dominerte typiske tabulære regresjons- og klassifikasjonsproblemer, og ensembler av flere gradient-boosting-varianter ga ytterligere marginal forbedring. Hvorvidt denne marginale gevinsten replikeres i et lite, høyt-skjevt regime som NautiCost-datasettet drøftes i § 9.2.

Pensumkompendiet i LOG650 (Pettersen & Rekdal, 2026, tabell 1.1) klassifiserer prosjekter med mange forklaringsvariabler under metodefamilien Random Forest / XGBoost / **LightGBM** med metodene gradient boosting, kryssvalidering, SHAP og hyperparametertuning. Metodevalget i NautiCost — LightGBM + CatBoost-ensemble, 5-fold kryssvalidering ved Optuna-tuning,

TreeSHAP for forklarbarhet — er nøyaktig denne kombinasjonen, og er dermed direkte pensum-forankret. Det skiller seg fra kompendiets standardeksempel ved at vi modellerer på transaksjonsnivå snarere enn aggregert nivå, og legger til konform kalibrering (§ 2.3) for usikkerhetsbånd.

2.3 Konform prediksjon og usikkerhetskvanifisering

Punktprediksjoner alene er utilstrekkelige for beslutningsstøtte der kostnaden varierer over flere størrelsesordener. Romano et al. (2019) introduserte *Conformalized Quantile Regression* (CQR), som kombinerer kvantilregresjon med konform prediksjon for å oppnå prediksjonsintervaller med garantert endelig-utvalgsdekning, uavhengig av modellens underliggende kalibrering. Metoden er teoretisk forankret i distribusjonsfriheten til konforme prediktorer (Shafer & Vovk, 2008), men beholder den statistiske effektiviteten til kvantilregresjon — intervallene er smalere enn de fra standard konform prediksjon fordi de tilpasser seg heteroskedastisitet.

CQR er attraktiv i et anvendt regime fordi den bevarer kvantilregresjonens evne til å tilpasse seg heteroskedastiske residualer, samtidig som konformgarantien sikrer at faktisk dekning ligger nær det nominelle nivået uten å anta en bestemt feilfordeling. Hvor godt dette fungerer på vårt datasett rapporteres i § 6.4 og § 8.2.

For forklarbarhet bruker NautiCost SHAP-verdier (Lundberg & Lee, 2017), som dekomponerer enkeltprediksjoner i per-feature-bidrag basert på Shapley-verdier fra kooperativ spillteori. TreeSHAP-algoritmen (Lundberg et al., 2020) muliggjør eksakt, effektiv beregning for treensembler og gir både globale feature-importance-rangeringer og lokale per-prediksjon-forklaringer (jf. § 3.6 og § 7.3).

2.4 Forskningsgap

Litteraturen som er gjennomgått behandler enten (a) prediksjon av en samlet kostnad eller rate per reise (Jang et al., 2023; Su et al., 2024) eller (b) operasjonell effektivitet på havnenivå (Jahangard et al., 2025). Ingen av disse studiene modellerer den **sammensatte tjenestemiksen per anløp** — det vil si hvordan en enkelt yacht-stopp gir opphav til 5–40 separate transaksjoner fordelt på havneavgift, los, hospitality, proviant, agenttjenester og bunkers, og hvordan totalkostnaden av et anløp bygges opp av disse delene. NautiCost adresserer dette gapet ved å modellere på transaksjonsnivå, deretter aggregere via portmaler og trafikkvekter, og kalibrere

mot empiriske havnepersentiler. I et lite, høyt-skjevt datasett ($n \approx 1\,600$) forutsetter dette en spesifikk metodikk: (i) log-transformert målvariabel for å håndtere skjevheten, (ii) gradient-boosting-ensemble for tabulære data med sterk heterogenitet, og (iii) konform kalibrering for å gi distribusjonsfrie usikkerhetsbånd. Kombinasjonen av disse, anvendt på maritim agent-tjenestefakturerings, er det metodiske rommet vi opererer i.

3. Teori

Dette kapittelet etablerer det metodiske rammeverket prosjektet hviler på. Hvert delkapittel avsluttes med en kort kobling til hvilket delproblem (DP1–DP5, jf. § 1.2) teorien adresserer, slik at teorien ikke blir frittstående modellbeskrivelse, men en begrunnelse for de metodevalgene som tas i § 5 og § 6.

3.1 Tabulær læring og gradient boosting

Et regresjonsproblem på tabulære data er definert ved et datasett $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$ der $x_i \in \mathbb{R}^d$ er feature-vektorer og $y_i \in \mathbb{R}$ er målverdier, og oppgaven er å finne en funksjon $\hat{f}: \mathbb{R}^d \rightarrow \mathbb{R}$ som minimerer en tap-funksjon $L(y, \hat{y})$. For tabulære data med en blanding av numeriske og kategoriske features og komplekse interaksjoner er **ensembler av beslutningstrær** den dominerende tilnærmingen.

Et beslutningstre partisjonerer feature-rommet rekursivt i akse-justerte regioner og tilordner en konstant prediksjon innenfor hver region. Et enkelt tre har høy varians — et litt annet utvalg gir et betydelig annet tre. To strategier reduserer denne variansen: **bagging** (gjennomsnitt av uavhengig trente trær, jf. random forest) og **boosting** (sekvensiell trening der hvert tre korrigerer feilene fra det forrige).

I gradient boosting (Friedman, 2001) bygges modellen additivt:

$$F_m(x) = F_{m-1}(x) + \nu \cdot h_m(x)$$

der h_m er et regresjonstre tilpasset den negative gradienten av tapet med hensyn på forrige prediksjon, og $\nu \in (0,1]$ er en læringsrate. Etter M runder er modellen $F_M(x) = F_0(x) + \nu \sum_{m=1}^M h_m(x)$.

Sammenlignet med bagging kan boosting redusere både bias og varians ved å konsentrere kapasiteten der residualene er størst. Avveiningen er at boosting er sekvensielt og mer utsatt for overtilpasning hvis M er for stor eller ν for høy; **early stopping** på et valideringssett er standard mottiltak.

Moderne gradient-boosting-biblioteker (LightGBM, CatBoost, XGBoost) optimerer dette rammeverket langs tre akser: histogram-basert split-finding for hastighet, native håndtering av kategoriske features, og bruk av andreordens gradient-informasjon (Newton-Raphson-oppdateringer) for raskere konvergens.

Relevans for prosjektet. DP2 spør hvilken modell som gir lavest prognosefeil på heterogene tabulære data. Gradient boosting dominerer denne typen data (Grinsztajn et al., 2022; Shwartz-Ziv & Armon, 2022), og er utgangspunktet for § 6.

3.2 LightGBM

LightGBM (Ke et al., 2017) er et gradient-boosting-bibliotek optimert for hastighet og minne på store tabulære datasett. Tre innovasjoner skiller det fra tidligere implementasjoner:

Histogram-basert split-finding. Kontinuerlige features for-binnes i k histogrammer (typisk $k = 255$). Å finne det optimale split-punktet reduseres fra å skanne alle unike feature-verdier ($\mathcal{O}(n \cdot d)$ per node) til å skanne histogram-bins ($\mathcal{O}(k \cdot d)$ per node). For datasett med mange kontinuerlige features er dette den dominerende hastighetsgevinsten.

Leaf-wise tre-vekst. Der standard implementasjoner vokser trær level-wise (alle blader på dybde d før noen på $d + 1$), vokser LightGBM bladet med høyest tap-reduksjon først, uavhengig av dybde. Dette gir mer asymmetriske trær som tilpasser dataene bedre med færre blader totalt — men er mer utsatt for overtilpasning på små datasett, kontrollert av `max_depth` og `min_data_in_leaf`-restriksjoner.

Gradient-based one-side sampling (GOSS) og exclusive feature bundling (EFB). GOSS beholder samplene med høyest gradient (størst residual) og subsampler resten tilfeldig — informasjonstetthet per iterasjon bevares. EFB bundler gjensidig eksklusive sparse features til én kolonne. Begge reduserer kostnad per iterasjon på høy-dimensjonal sparsom data.

Kategorisk håndtering. LightGBM aksepterer heltallskodede kategoriske kolonner direkte. Ved hvert split sorteres kategoriene etter akkumulert gradient-statistikk, og den optimale partisjonen finnes ved å skanne den sorterte listen. Dette håndterer høy-kardinalitets kategoriske variabler (f.eks. `arrival_port`, `service_type`) uten one-hot-eksplosjon.

I NautiCost er LightGBM den primære base-læreren fordi den konvergerer raskt på det lille datasettet (~1 600 rader) og håndterer den heterogene feature-miksen native. Hyperparametre (`num_leaves`, `min_data_in_leaf`, `max_depth`, `feature_fraction`, `bagging_fraction`, `learning_rate`) er tunet med Optuna (se § 6.3).

Relevans: LightGBM håndterer blandet input og lav rad-til-feature-ratio (63) effektivt — derav valget i § 6.3.

3.3 CatBoost

CatBoost (Prokhorenkova et al., 2018) er et gradient-boosting-bibliotek med fokus på robust kategorisk håndtering og forventningsrett target-encoding. To tekniske bidrag står sentralt:

Ordered boosting. Standard target-encoding-strategier erstatter en kategorisk verdi med gjennomsnittet av målet over alle rader der verdien forekommer. Dette skaper *target-leakage* — den kodede featuren for rad i påvirkes av målet y_i selv, hvilket biaserer gradienter mot over-tilpasning. CatBoosts ordered boosting opprettholder en tilfeldig permutasjon av treningsradene; for hver rad i bruker target-encodingen kun radene som ligger foran i i permutasjonen. Dette gir et forventningsrett estimat på bekostning av å kjøre K parallelle modeller på K ulike permutasjoner.

Symmetriske (oblivious) trær. Hvert nivå av et CatBoost-tre bruker samme split-feature og terskelverdi på tvers av alle interne noder på det nivået. Dette gir et balansert binærtre med fast dybde, hvilket er raskere ved inferens (prediksjonsbanen er bare en sekvens av sammenligninger) og virker som en implisitt regularisering.

Kategorisk encoding via ordered target statistics:

$$\hat{x}_i^{cat} = \frac{\sum_{j < i, x_j^{cat} = x_i^{cat}} y_j + a \cdot p}{\#\{j < i: x_j^{cat} = x_i^{cat}\} + a}$$

der a er en glattingsprior og p er en global prior (f.eks. globalt målgjennomsnitt). Glattingen håndterer lav-frekvente kategorier robust.

I NautiCost er CatBoost paret med LightGBM i ensemblen (§ 6.3) fordi den bringer en annen induktiv bias — symmetriske trær og ordered encoding — som dekorrelerer feilene med LightGBMs leaf-wise asymmetriske trær og reduserer ensemble-variansen.

Relevans: CatBoosts uavhengige induktive bias (symmetriske trær, ordered encoding) dekorrelerer feil mot LightGBM og gir ensemble-arkitekturen i § 6.3 mer robusthet ved drift.

3.4 Log-transformert mål og evaluering

Målvariabelen `final_charge` er sterkt høyreskjev: enkelte transaksjoner er 50–100× større enn medianen (jf. § 7.1). To konsekvenser for modellering:

1. Gradient boosting med kvadrattap domineres av de største residualene. Uten transformasjon bruker modellen mesteparten av kapasiteten på å redusere feilen for en håndfull dyre transaksjoner mens feilen ellers øker.
2. Multiplikative effekter (en yacht som er dobbelt så stor koster grovt sett dobbelt så mye) blir additive i log-rommet, hvilket matcher den additive strukturen i beslutningstrær bedre.

Standardløsningen er en log-transformasjon:

$$y = \log(1 + \text{final_charge})$$

«+1»-shiftet håndterer null-kostnadstransaksjoner uten at log divergerer. Prediksjoner inverteres med $\hat{c} = \exp(\hat{y}) - 1$ før de rapporteres.

Evalueringemetriker på opprinnelig EUR-skala (jf. § 1.3 om valutaen i kildedataene):

- **Mean Absolute Error (MAE):** $\text{MAE} = \frac{1}{n} \sum_i |y_i - \hat{y}_i|$. Rapporterer absolutt avvik i EUR; robust mot outliers.
- **Root Mean Squared Error (RMSE):** $\text{RMSE} = \sqrt{\frac{1}{n} \sum_i (y_i - \hat{y}_i)^2}$. Straffer store feil hardere; sensitiv mot outliers.

- **Mean Absolute Percentage Error (MAPE):** $MAPE = \frac{100}{n} \sum_i \left| \frac{y_i - \hat{y}_i}{y_i} \right|$. Rapporterer relativ feil i prosent; sensitiv mot små nevner — små y_i blåser opp MAPE.
- **Weighted MAPE (wMAPE):** $wMAPE = 100 \cdot \frac{\sum_i |y_i - \hat{y}_i|}{\sum_i |y_i|}$. Volumvektet versjon av MAPE der hver feil vektes etter fakturabeløpet; ikke sårbar for små nevner. Ekvivalent med $MAE/\bar{y}$.

I et høyreskjev kostnadsscenario er **MAE** den mest operasjonelt meningsfulle metrikken: en feil på 5 000 EUR har samme størrelsesorden enten regningen er på 10 000 eller 100 000 EUR.

wMAPE rapporteres som relativ metrikk fordi den ikke straffes urimelig av små transaksjoner og lar seg tolke som «total bom i prosent av total kostnad». MAPE rapporteres for fullstendighet og sammenlignbarhet med eksisterende litteratur, men tolkes med forsiktighet fordi små fakturaer dominerer gjennomsnittet. RMSE fanger om modellen har sjeldne store bomskudd og brukes som sekundær rankingmetrikk.

Relevans: Log-MSE-tap og MAE som primær metrikk er direkte konsekvenser av kostnadsfordelingens skjevhet (§ 7.1).

3.5 Kvantilregresjon og konform prediksjon

Punktprediksjoner er utilstrekkelige når kostnadsfordelingen er høyreskjev og en agent må kommunisere «dette er typisk kostnad, dette er den øvre plausible grensen». Kvantilregresjon og konform prediksjon gir *intervaller* med kalibrert dekning.

Kvantilregresjon trener en modell til å predikere τ -kvantilet av $y \mid x$ ved å minimere pinball-tapet:

$$L_{\tau}(y, \hat{y}) = \begin{cases} \tau(y - \hat{y}) & \text{hvis } y \geq \hat{y} \\ (1 - \tau)(\hat{y} - y) & \text{hvis } y < \hat{y} \end{cases}$$

For $\tau = 0,5$ reduseres dette til middel absolutt feil og gir en median-prediktor. For $\tau = 0,9$ gir det en modell der prediksjonen overstiges av sann verdi 10 % av tiden (asymptotisk). LightGBM støtter pinball-tapet som innebygd objektiv; vi trener tre separate modeller for $\tau \in \{0,1; 0,5; 0,9\}$ for å oppnå P10/P50/P90-prediksjon.

Kalibreringsproblemet. Selv en veltrenet kvantilmodell garanteres ikke å oppnå nominell dekning på hold-out-data. Empirisk dekning kan drifte fra $1 - 2\alpha$ grunnet begrenset treningsdata, modellmisspesifikasjon eller fordelingsdrift over tid.

Conformalized Quantile Regression (CQR) (Romano, Patterson & Candès, 2019) bruker et separat kalibreringssett til å konvertere en hvilken som helst kvantilprediktor til et kalibrert prediksjonsintervall. Gitt trenings-, kalibrerings- og testsplitter:

1. Tren kvantilmodeller for $\tau = \alpha/2$ og $\tau = 1 - \alpha/2$ på treningssettet, og oppnå $\hat{q}_{lo}(x)$ og $\hat{q}_{hi}(x)$.
2. På kalibreringssettet, beregn ikke-konformitetsscore:

$$E_i = \max\{\hat{q}_{lo}(x_i) - y_i, y_i - \hat{q}_{hi}(x_i)\}$$

3. La $Q_{1-\alpha}$ være $[(n_{cal} + 1)(1 - \alpha)]/n_{cal}$ -kvantilet av $\{E_i\}$.
4. CQR-prediksjonsintervallet er:

$$C(x) = [\hat{q}_{lo}(x) - Q_{1-\alpha}, \hat{q}_{hi}(x) + Q_{1-\alpha}]$$

CQR-justeringen $Q_{1-\alpha}$ garanterer endelig-utvalgs dekning $\Pr(y \in C(x)) \geq 1 - \alpha$ under utbytbarhet av (kalibrering, test)-data, uavhengig av hvor dårlig kalibrert de underliggende kvantilmodellene er. Hvor stor justering CQR faktisk gir på vårt datasett, og hva det forteller om de underliggende kvantilmodellene, drøftes i § 6.4 og § 8.2.

Relevans: Kvantilregresjon gir spennet (DP4), og CQR garanterer kalibrert dekning på små datasett.

3.6 SHAP-verdier

Treensembler er presise men opake: en prognose på 17 000 EUR forteller ikke i seg selv *hvorfor* — var det GT, havnen, sesongen? **SHAP (SHapley Additive exPlanations)** (Lundberg & Lee, 2017) dekomponerer en prediksjon i per-feature bidrag med basis i kooperativ spillteori.

For en modell f og et input x er SHAP-verdien til feature j :

$$\phi_j(x) = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|! (|F| - |S| - 1)!}{|F|!} [f_{S \cup \{j\}}(x) - f_S(x)]$$

der F er feature-mengden, S løper over delmengder uten j , og $f_S(x)$ er modellens forventede prediksjon når kun features i S er observert. Dette er Shapley-verdien fra koalitions-spillteori: ϕ_j er det gjennomsnittlige marginale bidraget fra j over alle mulige feature-rekkefølger.

SHAP-verdier oppfyller tre ønskelige egenskaper: - **Lokal nøyaktighet:** $f(x) = \phi_0 + \sum_j \phi_j(x)$ — prediksjoner dekomponeres eksakt i en baseline pluss per-feature bidrag. - **Manglende verdier:** features uten påvirkning får $\phi_j = 0$. - **Konsistens:** hvis en features bidrag øker i en modell, kan SHAP-verdien dens ikke synke.

Eksakt beregning av SHAP-verdier er eksponensiell i antall features. For tre-ensembler beregner **TreeSHAP** (Lundberg et al., 2020) eksakte SHAP-verdier i polynomtid ved å traversere hvert tres banestruktur og spore betingede forventninger. Dette gjør per-prediksjon-forklaring mulig på en 26-feature modell på millisekunder.

I NautiCost (§ 7.3) brukes TreeSHAP både globalt (gjennomsnittlig absolutt SHAP per feature → feature importance-rangering) og lokalt (per-prediksjon waterfall-plott når en agent spør «hvorfør predikerte modellen dette tallet?»).

Relevans: Forklarbarhet er forutsetning for DP5 — SHAP kobler modellvalg (DP2) til operasjonalisering uten å gå på bekostning av prestasjon.

4. Casebeskrivelse

Yachting Operations (heretter: *bedriften*) er en skandinavisk yachtagent som koordinerer anløp av kommersielle og privateide superyachter til havner i Norge, Sverige og Danmark. Bedriften driver fra tre kontorer: Bergen Office (norske havner), Stockholm Office (svenske havner) og Copenhagen Office (danske havner). Kjernetjenestene er gruppert i syv kategorier:

Kategori	Eksempler
Port Marina	Havneavgift, lostjenester, NOx-skatt, fortøyning
Agency Services	Tollklarering, immigrasjon, kurer, innkjøp
Hospitality	Transportservice, guide, hotell, leiebil

Kategori	Eksempler
Provisioning	Mat, drikke, blomster
Technical Services	Tekniker, mekaniker, dykker, snekker
Bunkering	Diesel, smøreolje
Agency Fee	Selve agenthonoraret

Tjenestemiksen varierer betydelig mellom havner: Tromsø har en høy andel agenttjenester knyttet til toll og innkjøp, Stockholm domineres av hospitality, og Bergen har den bredeste tjenestepaletten med 38 forskjellige tjenestetyper i datasettet.

Yachtene som behandles er i størrelsesspennt 51,9–2 407 GT, der norske myndigheter krever los (Loskrav = Ja) for fartøy med LOA > 70 m. Bedriften kategoriserer fartøy i tre størrelser:

- **Liten:** $GT < 98$
- **Mellomstor:** $98 \leq GT \leq 1000$
- **Stor:** $GT > 1000$

I dag utarbeides forhåndsestimater manuelt og varierer i kvalitet mellom koordinatorene. Bedriften ønsker et internt verktøy som gir et raskt, konsistent og forklarbart kostnadsestimat — det er behovet NautiCost dekker.

5. Metode og data

5.0 Prosessmapping mot pensumkompendiet

Pensumkompendiet (Pettersen & Rekdal, 2026, § i.4) foreskriver en femtrinns prosess for et kvantitativt logistikkprosjekt. NautiCost følger denne prosessen, og tabellen under viser hvilke kapitler som realiserer hvert steg:

Prosesssteg (kompendiet § i.4)	Realisert i NautiCost-rapporten
Steg 1: Datainnsamling	§ 5.2 datakilder, § 5.3 datapreparering
Steg 2: Sjekk av antakelser	§ 5.7 antakelsesdiagnostikk, § 7.4 residual-

Prosesssteg (kompendiet § i.4)	Realisert i NautiCost-rapporten
	analyse
Steg 3: Løsning (modellestimering)	§ 6.3 ensemblemodell, § 6.4 kvantilmodell, § 6.5 hybrid kalibrering
Steg 4: Sjekk av løsning	§ 8 resultater (valideringssett-metrikker + endelig testsett-evaluering), § 8.2 kvantil-dekning
Steg 5: Anvendelse	§ 6.5 hybrid kalibrering på anløpsnivå, § 8.4 operasjonell ytelse, § 9.5 brukertest

Mappingen sikrer at lesere som har pensumkompendiet kan navigere rapporten med kjent rammeverk, og at de fem trinnene er dekket før vi konkluderer i § 10.

5.1 Forskningsdesign

Prosjektet følger et anvendt-prediktivt forskningsdesign: vi formulerer kostnadsestimering som et supervised regresjonsproblem på transaksjonsnivå, med tidsbasert split for å unngå datalekkasje, og evaluerer modellen mot operasjonelt relevante feilmetrikker (MAE i EUR — kildedataenes egen valuta, jf. § 1.3 — samt P25–P75-dekning).

5.2 Datakilder

Fil	Innhold	Rader
Rådata Nauticost.xlsx (sheet 1)	Originale faktura-transaksjoner 2020–2025	932
Kostnader_MM.csv	Eksportert transaksjonsdata (inkl. subtotaler)	3 325
costs_clean.csv	Renset transaksjonsdata fra data_prep.ipynb	1 654
costs_merged.csv	Transaksjoner sammenstilt med yachtspesifikasjoner	1 654 (1 633 med gyldig pris)
Yacht-specs.csv /	17 unike yachter (19 spec-	19

Fil	Innhold	Rader
specs_clean.csv	rader, noen revideres over tid)	
cockpit_clean.csv	Aggregerte cockpit-tall 2020–2025	6

5.3 Datapreparering

Datapreparering er gjennomført i data_prep.ipynb og består av:

1. **Innlesing og typing** av Rådata Nauticost.xlsx, parsing av datofelt og numeriske beløp.
2. **Datakvalitetsflagging** via en flag-kolonne for rader med inkonsistente feltverdier (negative beløp, manglende yacht-ID, sluttdato før startdato).
3. **Yacht-kobling**: transaksjoner kobles til yachtspesifikasjoner (GT, LOA, beam, draft, fuel) via yacht-ID.
4. **Avledede felt**: size_category, loskrav, samt tidsvariabler (måned, kvartal, dag-i-uka).
5. **Filtrering**: rader med manglende eller ikke-positiv final_charge fjernes (jf. antakelse A3).

5.4 Datasplit og evalueringsprotokoll

Splittet er **tidsbasert**, ikke tilfeldig, for å speile reell prognosebruk. Rollen til hvert sett er bevisst skilt mellom **modellutvikling**, **modellseleksjon** og **endelig evaluering**:

Sett	Periode	Rader	Rolle
Treningssett	≤ 2023	487	Modellutvikling: trene base-modellene, lære feature-engineering-statistikker (aggregatfeatures beregnet kun her, jf. § 5.5).
Valideringssett	2024	490	Modellseleksjon:

Sett	Periode	Rader	Rolle
			velge hyperparametre (Optuna), ensemble- vekt w , kvantil- objektivterskler og CQR- kalibreringsterskel; sammenligne kandidatmodeller (jf. § 8.1).
Testsett	2025	670	Endelig, uavhengig evaluering av den utvalgte produksjons- modellen (jf. § 8.1.1). Brukes ikke til seleksjon eller hyperparametervalg.

Året 2026 er holdt utenfor modellutviklingen og brukes som overvåkningssett etter hvert som nye fakturaer kommer inn (kun 7 rader pr. april 2026, og dermed ikke meningsfullt for evaluering på det tidspunktet).

Refit av produksjonsmodellen. Etter at modellseleksjonen er fullført, refittes den endelige produksjonsmodellen i `model_meta_final.joblib` på *hele* perioden 2020–2025 — altså treningssett, valideringssett og testsett samlet (1 626 rader, 21 færre enn split-summen 1 647 fordi rader med manglende avledede aggregatfeatures faller bort i feature engineering-steget). Begrunnelsen for å trekke testsettet inn i treningen er at modellen deploys i produksjon *etter* at seleksjonen er konkludert, og at maksimering av treningsdata på det tidspunktet gir lavest forventet generaliseringsfeil ved deploy. Dette er en standard praksis (jf. Hastie, Tibshirani & Friedman, 2009), men har en konkret konsekvens: **rapporterte testsett-tall i § 8.1.1 gjelder den prefit’ede**

modellen (ensemble trent på ≤ 2024), ikke den refit'ede produksjonsmodellen. Produksjonsmodellen har dermed ingen uavhengig holdout-måling før neste tidsvindu (2026+) gir tilstrekkelig data. Dette diskuteres som begrensning i § 10.

5.5 Feature engineering

Totalt **26 prediktorvariabler** er konstruert (jf. `build_features` i `predict_voyage.py`):

- **Yachtspesifikasjoner:** `gt`, `loa_m`, `beam_m`, `draft_m`.
- **Avledede yachtfelt:** `size_category`, `loskrav`.
- **Reiseparametere:** `arrival_port`, `office`, `month`, `stay_days`.
- **Tjenestekontekst:** `service_type`, `service_category`.
- **Tidsfeatures:** `quarter`, `is_summer`, `is_shoulder`, `day_of_week`, `week_of_year`.
- **Interaksjoner:** `gt × stay_days`, `loa_m × stay_days`, `fuel_lph × stay_days`.
- **Aggregatstatistikk:** `size_svc_mean_charge`, `size_svc_median_charge`, `size_svc_count`, `port_mean_charge`, `port_median_charge` — alle i EUR, og beregnet **kun på treningssettet** for å unngå target leakage. Merk at `size_*`-aggregatene er poolet på tvers av Norge, Sverige og Danmark — en avgrensning vi kommer tilbake til i § 9.5.
- **Tekstmål:** lengde av fakturakommentar (`cmt_len`).

5.6 Verktøy og reproduserbarhet

Pipeline er implementert i Python 3.11 med `pandas`, `scikit-learn`, `LightGBM 4.x`, `CatBoost 1.2`, og `Optuna` for hyperparametersøk. Alle modellartefakter er lagret i 013 fase 3 - review/artifacts/. Backendtjenesten er bygget med `FastAPI` og frontend med `Next.js 14`. Hele arbeidsflyten — inkludert AI-bistand i `Claude Code` — er versjonskontrollert på `GitHub` i samsvar med god vitenskapelig praksis.

5.7 Antakelsessjekk (kompendiet steg 2)

Selv om treensembler er robuste mot mange klassiske brudd på regresjonsantakelser (linearitet, normalitet, homoskedastisitet), foreskriver pensumkompendiet (§ i.4.2) at antakelsene skal verifiseres eksplisitt før modellen brukes. Vi rapporterer tre sjekker, alle utført på treningssettet (≤ 2023):

1. **Skjevhet i målvariabelen.** Som rapportert i § 7.1 er `final_charge` sterkt høyreskjev (snitt $> 3 \times$ median, $P95/P50 \approx 12$). Log-transformasjonen (§ 6.1) reduserer skjevheten fra $\sim 5,8$ til $\sim 0,4$ målt med skewness-koeffisienten, hvilket er innenfor det området L2-tap håndterer godt. Antakelse om at log-skala gir tilnærmet symmetrisk feilfordeling holder dermed empirisk (jf. residualplottet i § 7.4).
2. **Heteroskedastisitet.** Bruschagan-test (uformelt: residualer vs. predikert verdi i log-rom) viser at residualvariansen ikke er konstant over hele predikert-spennet — store predikerte verdier (Provisioning og Port Marina for Stor-yachter) har større absolutte residualer enn små predikerte verdier. Dette er en av grunnene til at kvantilregresjon og CQR-kalibrering (§ 6.4) er valgt: konstante prediksjonsbånd ville vært feil, og kvantilmodellene tilpasser seg heteroskedastisiteten.
3. **Multikollinearitet.** Variance Inflation Factor (VIF) for de numeriske featurene viser at `gt`, `loa_m` og `fuel_lph` er sterkt korrelerte (alle $VIF > 10$, par-Pearson $> 0,9$). Notebook-cellen som dropper `log_gt` ($r = 0,94$ med `gt`), `fuel_lph` ($r = 0,999$ med `gt`) og noen redundante aggregatfeatures eliminerer de mest ekstreme tilfellene. Resterende moderate multikollinearitet ($VIF \approx 3\text{--}5$ for `loa_m \times stay_days` og lignende interaksjonsfeatures) er akseptert fordi treensemblen ikke er sensitive for kollineære features på samme måte som lineær regresjon — en feature med $VIF = 5$ i et tre vil bare bli valgt sjeldnere ved split, ikke gi numerisk ustabilitet.

Konklusjonen er at antakelsesbruddet som ville vært mest skadelig — sterk skjevhet i målvariabelen — er adressert via log-transformasjon, og at heteroskedastisitet er håndtert via kvantilmodellering snarere enn ignorert. Antakelsene er dermed “tilstrekkelig oppfylt” i kompendiets forstand (§ i.4.2), og resultatene i § 8 skal leses i lys av denne sjekken.

6. Modell

6.1 Målvariabel og tap

Målvariabelen er kostnaden per transaksjon, `final_charge`, log-transformert:

$$y = \log(1 + \text{final_charge})$$

Modellene optimerer L2-tap i log-rommet; predikerte verdier inverteres med `expm1` ved evaluering.

6.2 Baselinemodeller

To baselines etableres for å kalibrere forventningene:

- **Medianbaseline:** prediker median av y per (`size_category`, `service_category`) på treningssettet.
- **Ridgeregresjon:** lineær modell med one-hot-kodede kategorier og standardiserte numeriske features.

6.3 Hovedmodell — LightGBM + CatBoost ensemble

Den endelige modellen er et veid gjennomsnitt i log-rommet av to gradient-boosting-modeller:

$$\hat{y}_{\text{ens}} = w \cdot \hat{y}_{\text{LGB}} + (1 - w) \cdot \hat{y}_{\text{CB}}, \quad w \in [0,1]$$

der vekten w velges ved gridsøk på valideringssettet og er lagret i `model_meta_final.joblib` (`ensemble_weight = 0.30`, dvs. 30 % LightGBM + 70 % CatBoost).

Hyperparametre for LightGBM er funnet med Optuna (80 trials, 5-fold kryssvalidering på trening + validering) og lagret i `best_params`: `alpha = 3.35`, `learning_rate = 0.032`, `num_leaves = 32`, `min_data_in_leaf = 47`, `max_depth = 6`, `feature_fraction = 0.85`, `bagging_fraction = 0.83`. CatBoost trenes med native håndtering av kategoriske kolonner. Begge modellene bruker `early_stopping` på valideringssettet i avstemmingsfasen, og refittes deretter på hele datasettet (2020–2025) med `best_iteration = 390` før produksjon.

6.4 Kvantilmodell og konform kalibrering

For å gi P10/P50/P90-prediksjoner trenes tre LightGBM-modeller separat med kvantilobjektivet (pinball loss). Disse kalibreres deretter med **Conformalized Quantile Regression (CQR)** (Romano et al., 2019) på et hold-out kalibreringssett. Empirisk dekning på valideringssettet er **80,0 %** etter CQR-justering (mot nominelt 80 %), og avviker fra rå dekning på 79,8 % med kun en CQR-korreksjon på 3 EUR — kvantilmodellene er altså godt kalibrert allerede før justering. Forbeholdene rundt betinget dekning når en sentral kostnadsdriver er uobservert drøftes i § 9.2.

6.5 Hybrid kalibrering på anløpsnivå

Transaksjonsmodellen produserer urealistisk lave totaler hvis predikerte transaksjonsbeløp summeres direkte. For å unngå dette brukes en hybrid kalibreringsstrategi (jf. `predict_port` i `predict_voyage.py`):

1. Generer transaksjonsrader fra `PORT_TEMPLATES` for valgt havn.
2. Beregn predikert beløp per rad og vekt med forventet antall transaksjoner.
3. Sammenlign med et havn-størrelse-spesifikt **baseline-prediksjon** (lagret i `baseline_predictions.joblib`).
4. **Anker estimatet** til empirisk medianpris (P50) per (havn, size_category) fra `HISTORICAL_RANGES`, og skaler proporsjonalt med modell-til-baseline-forholdet:


$$\widehat{\text{Total}} = \text{P50}_{\text{historisk}} \cdot \frac{\widehat{\text{Total}}_{\text{modell}}}{\text{Baseline}_{\text{modell}}}$$

På landsnivå tas et trafikkvektet gjennomsnitt over alle havner i landet.

7. Analyse


Analysen i dette kapittelet er basert på 1 626 transaksjoner i `costs_merged.csv` etter feature engineering (§ 5.5). Figurer er produsert i `eda_nauticost.ipynb` og `modeling_nauticost.ipynb` og er reproducerbare gjennom å kjøre notebookene mot artefaktene i 013 fase 3 - review/artifacts/. Figurtekstene under er bevisst skrevet stand-alone — alle nøkkeltall som diskusjonen senere bygger på, gjengis i teksten her, slik at rapporten kan leses uten å åpne notebookene.

7.1 Beskrivende statistikk




Figur 7.1: Distribusjon av final_charge (log-skala) — høyreskjev kostnadsfordeling som motiverer log-transformasjonen i § 6.1

Figur 7.1. Distribusjon av final_charge (log-skala) viser den forventede høyreskjeve fordelingen: median 7 513 EUR, P25 = 2 039 EUR, P75 = 21 950 EUR, P95 = 91 248 EUR, snitt 25 045 EUR. At snittet er over tre ganger medianen, og at $P95/P50 \approx 12$, bekrefter empirisk behovet for log-transformasjonen i § 6.1 — uten den ville fire–fem ekstreme transaksjoner dominere L2-tapet. (Plott i `eda_nauticost.ipynb`, seksjon 3.2; rådata i `costs_clean.csv`; reproduisert i 013 fase 3 - review/generate_figures.py.)



Figur 7.2: Antall transaksjoner per havn og år (2020–2025) — viser trafikkvolum og datatilfang per havn


Figur 7.2. Antall transaksjoner per havn og per år (2020–2025). Bergen og Tromsø dominerer trafikken med henholdsvis 614 og 389 anløpsrelaterte transaksjoner over perioden; Stavanger og Kristiansand har kun 3 og 8 anløp, og statistiske aggregater på (havn, størrelse) er derfor ikke definert for disse to havnene (jf. HISTORICAL_RANGES-tabellen i model.py). (Plott i `eda_nauticost.ipynb`, seksjon 3.2.)



Figur 7.3: Kostnad per tjenestekategori, fordelt på størrelseskategori (Liten / Mellomstor / Stor)


Figur 7.3. Kostnad per tjenestekategori, fordelt på størrelseskategori. Provisioning og Port Marina dominerer totalkostnaden for Stor-yachter (typisk 30–40 % hver), Hospitality er hovedkategori for mellomstore, og Liten-kategorien har en flatere fordeling med Agency Services som største enkeltkategori. (Plott i `eda_nauticost.ipynb`, seksjon 3.3.)

7.2 Korrelasjoner og feature importance



Figur 7.4: Spearman-korrelasjon mellom numeriske features og log-kostnad — GT, LOA og fuel-konsum er moderat positivt korrelert


Figur 7.4. Spearman-korrelasjon mellom numeriske features og log-kostnad. GT ($\rho = 0,38$), LOA ($\rho = 0,35$) og fuelkonsum ($\rho = 0,31$) er positivt korrelert med kostnad; korrelasjonene er moderate fordi yacht-størrelse alene ikke determinerer kostnaden (tjenestemiks og sesong påvirker minst like sterkt). (Plott i `eda_nauticost.ipynb`, seksjon 4.)



Figur 7.5: Top-15 feature importance fra LightGBM (gain-andel) — service_type og størrelse-baserte aggregatstatistikker dominerer


Figur 7.5. Top-15 feature importance fra LightGBM (gain). De fem viktigste featurene er service_type (gain-andel ≈ 32 %), size_svc_median_charge (≈ 18 %), size_svc_mean_charge (≈ 11 %), cmt_len (≈ 6 %) og week_of_year (≈ 5 %). At aggregat-statistikkene rangerer høyt bekrefter at feature engineering-steget i § 5.5 tilfører reell signal, og at modellen i praksis lærer et hierarki: tjenestetype velger et baseline-prisnivå, og yacht- og tidsfeatures modulerer det baselinet. (Plott i `modeling_nauticost.ipynb`, seksjon 6; reproduisert i `generate_figures.py`.)

7.3 SHAP-analyse



Figur 7.6: LightGBM gain-importance (fallback for SHAP, jf. § 9.7) — relativ styrke per feature i ensemblemodellen


Figur 7.6. LightGBM gain-importance brukt som fallback for SHAP-summary (TreeSHAP-generering feilet på et categorical_feature-mismatch, jf. § 9.7). Figuren viser relativ styrke (ikke effektretning) per feature. service_type og aggregatstatistikkene (size_svc_median_charge, size_svc_mean_charge) dominerer, med gt og stay_days som viktige sekundære drivere. Et ekte SHAP-plott ville i tillegg gitt fortegnsinformasjon (positiv/negativ påvirkning på predikert kostnad) som denne proxyen ikke fanger — fortegnet er rekonstruert kvalitativt i teksten under: høyere GT, lengre opphold og dyre tjenestetyper (Provisioning, Port Marina) gir høyere predikert kostnad. (Plott i modeling_nauticost.ipynb, seksjon 10; regenerering med ekte TreeSHAP er flagget som videre arbeid.)



Figur 7.7: Predikerte kostnader fordelt på GT (log-skala), tjenestekategori og ankomsthavn — viser monoton GT-effekt og tydelig havnevariasjon

Figur 7.7. Predikerte kostnader fordelt på sentrale features på valideringssettet: (a) predikert kostnad vs. GT (log-skala), (b) median prediksjon per service_category, (c) median prediksjon per arrival_port. GT-effekten er monoton men ikke-lineær. Havneeffekten viser at København og Stockholm gir høyere prediksjoner enn norske havner ved samme yachtstørrelse, hvilket er konsistent med havneavgiftsnivåene i datasettet og motiverer landbevisst aggregering som videre arbeid (§ 9.5.5). (Plott i `modeling_nauticost.ipynb`, seksjon 10; reproduisert i `generate_figures.py`.)

7.4 Residualdiagnostikk



Figur 7.8: Residualplott (predikert vs. faktisk i log-rom) på valideringssettet ($n = 490, 2024$) — bias $\approx -0,20$ indikerer systematisk overprediksjon for lave fakturaer

Figur 7.8. Residualplott (predikert vs. faktisk i log-rom) på valideringssettet ($n = 490, 2024$) for den tunede LightGBM-modellen. Gjennomsnittlig residual er **-0,20 i log-rom** (tilsvarende $\approx 18\%$ overprediksjon på opprinnelig skala): modellen estimerer i snitt høyere enn faktisk kostnad. Bias-

en er konsentrert i transaksjoner der faktisk beløp er lavt (typisk små Agency Services-fakturaer < 1 000 EUR) — modellen klarer ikke å predikere ned i dette beløpsspennet med presisjon. På anløpsnivå, der mange transaksjoner aggregeres, har bias-en mindre effekt fordi store og små transaksjoner blandes, og den hybride persentil-kalibreringen i § 6.5 forankrer totalen mot empirisk median. De største absolutte feilene konsentrerer seg i kategoriene Provisioning/Stor og Port Marina/Stor, der kostnadene avhenger av hva som ble bestilt snarere enn yacht-spesifikasjoner — dette samsvarer med funnet i § 9.5.4 om manglende guest_experience-feature for Provisioning. (Plott i *modeling_nauticost.ipynb*, seksjon 11, og reprodusert i 013 fase 3 - review/generate_figures.py.)

Tabell 7.1. Valideringsresidualer per størrelseskategori (n = 490, år 2024). MAPE er rapportert som **forholdstall** (gjennomsnittlig |feil| / faktisk verdi); 0,89 betyr 89 % gjennomsnittlig avvik, 4,07 betyr 407 %. De høye forholdstallene drives av mange små transaksjoner (jf. drøftingen av MAPE-sensitivitet i § 3.4).

size_category	n	MAE (EUR)	MAPE (forholdstall)
Liten	159	9 277	0,89
Mellomstor	113	9 192	2,13
Stor	218	28 562	4,07

Stor-kategorien har en MAE som er ca. 3× høyere enn de to andre, hvilket reflekterer at store yachter har større variasjonsspenn i absolutte kostnader (P95-fakturaer for Stor-yachter er over 100 000 EUR; for Liten typisk under 15 000 EUR). MAPE-tallene må tolkes forsiktig: 4,07 for Stor betyr *ikke* at modellen bommer med 407 % på typiske Stor-yacht-fakturaer, men at det er noen små Stor-fakturaer (f.eks. en enkelt forsyning på 200 EUR der modellen predikerer 1 000 EUR) som blåser opp prosentavviket. wMAPE-tallet for hele settet (71,4 %, jf. tabell 8.1) gir et mer rettferdig bilde av relativ feil. Det vesentlige funnet i tabellen er at *absolutt* feil skaleres med fordelings skala, ikke med systematisk bias mot Stor.

8. Resultat

8.1 Sammenligning av modeller på valideringssettet

Tabell 8.1. viser feilmetrikker for alle modeller på **valideringssettet** (2024, 490 transaksjoner), sortert etter MAE. Dette er settet vi bruker for **modellseleksjon**. Endelig evaluering på det reserverte testsettet (2025) drøftes i § 8.1.1.

Modell	MAE (EUR)	RMSE (EUR)	MAPE (%)	wMAPE (%)
LightGBM (base)	17 317	54 476	180,2	71,3
Ensemble (LGB + CB)	17 350	55 490	168,3	71,4
CatBoost	17 404	55 672	174,1	71,7
LightGBM (tunet)	17 837	55 141	168,9	73,4
Ridge	18 251	55 842	152,7	75,1
Medianbaseline	21 800	60 128	300,8	89,8

Kilde: 013 fase 3 - review/artifacts/metrics.csv (MAE/RMSE/MAPE) og metrics_with_wmape.csv ($wMAPE = \Sigma|err|/\Sigma actual = MAE/\text{mean}(actual)$, basert på $\text{mean}(actual) = 24\,289$ EUR på val=2024). Tallene er i EUR fordi de er beregnet direkte fra modellens log-transformerte output, som er trent på final_charge i EUR (jf. § 1.3). wMAPE er valutaavhengig (forholdstall) og påvirkes ikke av enhetsvalget.

Ensemblemodellen reduserer MAE med **20 %** i forhold til medianbaseline og **5 %** i forhold til ridge. På valideringssettet er LightGBM (base) og ensemblemodellen praktisk talt like (33 EUR forskjell, eller 0,2 % MAE), og forskjellen er innenfor støynivået på 490 transaksjoner.

Ensemblemodellen velges likevel som produksjonsmodell fordi den reduserer varians på tvers av kvantiler/folder og er mer robust mot at en av basismodellene skulle drifte ved re-trening; at den også oppnår lavest MAPE (168,3 %) er et sekundært argument, siden MAE i EUR er den primære operasjonelle metrikken (jf. § 9.4).

Ridge-modellen har paradoksalt nok lavest MAPE (152,7 %) til tross for høyest MAE blant ML-modellene. Forklaringen er at MAPE vekter relative feil: Ridge underestimerer mindre på de mange små transaksjonene (der prosentavviket dominerer), men bommer mer i absolutte beløp på

de store transaksjonene som MAE fanger opp. **wMAPE (volumvektet MAPE)** løser denne skjevheten ved å vekte feilen etter beløp i stedet for antall: målt på wMAPE er Ensemble best (71,4 %), Ridge dårligst blant ML-modellene (75,1 %), og medianbaseline 89,8 %. Differansen mellom MAPE (168,3 %) og wMAPE (71,4 %) for ensemblemodellen illustrerer hvor sterkt små transaksjoner blåser opp den uveide MAPE-en.

Statistisk signifikans. Forskjellen mellom LightGBM (base) og Ensemble på MAE er 33 EUR (0,19 %) — for å vurdere om dette er reell forskjell eller støy, ble det beregnet et 95 % bootstrap-konfidensintervall for $\Delta\text{MAE} = \text{MAE}_{\text{base}} - \text{MAE}_{\text{ens}}$ ved 1 000 bootstrap-utvalg av valideringssettet. Resultatet er $\Delta\text{MAE} = -33 \pm 870$ EUR (95 % KI: $[-1\,720; 1\,650]$), som omslutter null og dermed *ikke* er statistisk signifikant. På samme måte er Ensemble vs. CatBoost ikke signifikant ($\Delta = 54$ EUR; KI omslutter null). De tre gradientboosting-modellene er dermed praktisk talt likeverdige på valideringssettet — i tråd med Shwartz-Ziv & Armon (2022). Forskjellen mellom Ensemble og medianbaseline er derimot klart signifikant ($\Delta = 4\,450$ EUR; KI: $[3\,100; 5\,860]$). Konklusjonen er at modellvalget mellom de tre gradient-boosting-variantene må gjøres på sekundære kriterier (variansrobusthet, drift-toleranse) — ikke på MAE-tallene alene, som er innenfor støybåndet.

8.1.1 Endelig evaluering på testsettet (2025)

For å gi et **uavhengig generaliseringsanslag** ble testsettet (2025, 670 transaksjoner før feature-engineering, 649 etter) evaluert etter at modellseleksjonen var konkludert. Pipeline (gjengitt i skriptet 013 fase 3 - review/eval_test_2025.py): de samme modelklassene som i § 8.1, trent på treningssettet (≤ 2023) med early stopping på val=2024 for å replisere prefit-modellen som modellseleksjonen ble gjort på, deretter evaluert på det helt urørte testsettet (2025). Aggregat-features (size_svc_*, port_*) er som tidligere beregnet kun på ≤ 2023 for å unngå target leakage. Resultater er lagret i artifacts/metrics_test_2025.csv.

Tabell 8.2. Endelige test-sett-metrikker (2025, n = 649 transaksjoner; mean(actual) = 25 632 EUR), sortert etter MAE. Sammenlignet med tilsvarende valideringsmetrikker fra tabell 8.1.

Modell	MAE (test, EUR)	RMSE (test, EUR)	wMAPE (test, %)	Δ MAE
				(val→test)

Modell	MAE (test, EUR)	RMSE (test, EUR)	wMAPE (test, %)	Δ MAE (val→test)
LightGBM (base)	18 765	60 382	73,2	+1 448 (+8 %)
Ensemble (LGB + CB)	19 051	61 032	74,3	+1 701 (+10 %)
CatBoost	19 065	60 888	74,4	+1 661 (+10 %)
LightGBM (tunet)	19 331	61 324	75,4	+1 494 (+8 %)
Median- baseline	23 157	65 706	90,3	+1 357 (+6 %)
Ridge	43 120	369 462	168,2	+24 869 (+136 %)

Kilde: 013 fase 3 - review/artifacts/metrics_test_2025.csv (generert ved eval_test_2025.py, kjørt 2026-05-12).

Tre observasjoner er sentrale:

1. **Generaliseringen holder.** Ensemble-modellen oppnår MAE = 19 051 EUR på testsettet, ≈ 10 % høyere enn val-MAE (17 350). Dette er forventet etter modellseleksjon: når hyperparametre og ensemblevekt er valgt for å minimere val-MAE, vil et uavhengig testsett vise noe høyere feil. Veksten er moderat og innenfor det som er rapportert for tilsvarende studier (Jang et al., 2023, rapporterer 8–12 % degradering val→test).
2. **Ridge eksploderer på test.** Ridge-RMSE på testsettet er 369 462 EUR — over $6\times$ høyere enn på val. Dette skyldes en håndfull ekstreme 2025-transaksjoner som er utenfor rangen Ridge ble trent på (de største fakturabeløpene i 2025 er ≈ 30 % høyere enn maks i ≤ 2023). Lineær ekstrapolasjon utenfor treningsrangen feiler systematisk, og dette er et empirisk argument for valg av treensemble framfor lineære alternativer i et regime med drift mot større fakturaer over tid.
3. **Ranking mellom gradient-boosting-modeller endres.** På testsettet er LightGBM (base) marginalt best (MAE = 18 765, wMAPE = 73,2), tett etterfulgt av Ensemble og CatBoost (innenfor 0,3 pp wMAPE). Som i § 8.1 er disse forskjellene innenfor bootstrap-støy. Vi

beholder Ensemble som produksjonsmodell på grunn av variansreduksjonen drøftet i § 6.3, ikke fordi den vinner på rå test-MAE.

Forholdet mellom prefit- og produksjonsmodellen. Tabellene over gjelder *prefit-modellen* (trent på treningssettet ≤ 2023). Produksjonsmodellen i `model_meta_final.joblib` er refittet på hele 2020–2025 (1 626 rader) — inkludert testsettet — fordi deployen skjer *etter* at modellseleksjon og uavhengig testevaluering er konkludert, og maksimering av treningsdata på deploytidspunktet gir lavest forventet generaliseringsfeil for fremtidige (2026+) prediksjoner (Hastie, Tibshirani & Friedman, 2009, § 7.10). Refit-modellen har dermed ingen *uavhengig* holdout-måling før neste tidsvindu genererer nok data. Test-sett-tallene i tabell 8.2 gjelder altså den underliggende modelklassen og dens generaliseringsevne — *ikke* den deployede modellen som i tillegg har 670 ekstra treningsrader. Dette samsvarer med peer-reviewens påpekning av at “*valideringssettet brukes til modellseleksjon, mens testsettet er reservert for endelig validering*” (G10/Julie, 2026-05-07).

8.2 Kvantildekning

Empirisk dekning på valideringssettet for nominell P10–P90 er **79,8 %** rå og **80,0 %** etter CQR-justering. Per størrelseskategori varierer dekningen modest: Liten 83,0 % ($n = 159$), Mellomstor 74,3 % ($n = 113$) og Stor 80,7 % ($n = 218$). Mellomstor-gruppa er litt under nominelt nivå, hvilket er konsistent med at mellomstore yachter har færrest treningsrader (jf. §9.4).

8.3 Hybridkalibrert anløpsestimat — eksempler

Tallene i alle § 8.3-tabellene er i EUR (kildedata-enheten, jf. § 1.3). Frontend ganger med vekslingskursen i `EXCHANGE_RATES_FROM_EUR` for visning i NOK eller DKK.

Tabell 8.3a. Norge — mellomstor yacht (GT = 500, LOA = 55 m), juli, 5 dager, medium drivstoffkonsum.

Tjenestekategori	Estimert kostnad (EUR)
Port Marina	4 740
Agency Services	2 523
Bunkering	2 202
Hospitality	1 976

Tjenestekategori	Estimert kostnad (EUR)
Technical Services	1 826
Provisioning	1 204
Agency Fee	620
Totalt	15 091

Trafikkvektet historisk spenn (P25 / P50 / P75): **11 779 / 15 094 / 23 710 EUR**. Modellestimatet ligger praktisk talt på medianen, hvilket bekrefter at kalibreringssteget i § 6.5 fungerer som tiltenkt.

Tabell 8.3b. Sverige — mellomstor yacht (GT = 500, LOA = 55 m), juli, 5 dager, medium drivstoff.

Tjenestekategori	Estimert kostnad (EUR)
Bunkering	5 151
Port Marina	4 525
Provisioning	1 896
Hospitality	1 568
Agency Services	1 410
Technical Services	1 240
Agency Fee	1 114
Totalt	16 904

Trafikkvektet historisk spenn (P25 / P50 / P75): **14 508 / 16 904 / 41 833 EUR**.

Tabell 8.3c. Danmark — mellomstor yacht (GT = 500, LOA = 55 m), juli, 5 dager, medium drivstoff.

Tjenestekategori	Estimert kostnad (EUR)
Port Marina	8 732
Bunkering	6 300

Tjenestekategori	Estimert kostnad (EUR)
Hospitality	4 412
Provisioning	4 259
Agency Services	2 575
Technical Services	2 276
Agency Fee	220
Totalt	28 774

Trafikkvektet historisk spenn (P25 / P50 / P75): **27 489 / 28 774 / 33 792 EUR.**

Tabell 8.3d. Norge — liten yacht (GT = 50, LOA = 25 m), juli, 5 dager, medium drivstoff.

Tjenestekategori	Estimert kostnad (EUR)
Agency Services	9 624
Technical Services	2 552
Port Marina	2 366
Hospitality	2 045
Provisioning	797
Bunkering	591
Agency Fee	392
Totalt	18 366

Trafikkvektet historisk spenn (P25 / P50 / P75): **8 658 / 18 366 / 43 405 EUR.**

Tabell 8.3e. Norge — stor yacht (GT = 2 400, LOA = 78 m, Loskrav = Ja), juli, 5 dager, medium drivstoff.

Tjenestekategori	Estimert kostnad (EUR)
Port Marina	10 723
Provisioning	5 547
Technical Services	4 412

Tjenestekategori	Estimert kostnad (EUR)
Hospitality	3 918
Agency Services	3 781
Agency Fee	2 311
Bunkering	981
Totalt	31 673

Trafikkvektet historisk spenn (P25 / P50 / P75): **14 223 / 31 673 / 67 697 EUR.**

I alle fem eksempler (tabell 8.3a–e) plasserer modellestimatet seg nær den trafikkvektede medianen (P50), og innenfor P25–P75-båndet. Tjenestemiksen varierer tydelig mellom land: Danmark har høyere Port Marina- og Bunkering-andel, Sverige har jevnere fordeling, og store norske anløp domineres av Port Marina og Provisioning. Bunkers-tallene er imidlertid sannsynlighetsveide modellestimater og bruker ikke reisedistansen — denne begrensningen drøftes i § 9.5. For tabell 8.3e (Loskrav = Ja) er det heller **ikke** lagt til obligatorisk loskostnad i tallene; modellen ser los som en sannsynlig linje, ikke som obligatorisk for LOA > 70 m, jf. § 9.5.

8.4 Operasjonell ytelse

Backend (FastAPI) på en vanlig utviklermaskin (16 GB RAM, AMD Ryzen-klasse CPU) responderer på POST /api/predict på under 200 ms i kald start og under 50 ms ved varm last. Frontend gir komplett dashbord-rendering på under 2 sekunder fra bruker trykker «Estimate Cost».

9. Diskusjon

9.1 Tolkning av resultatene

Ensemblemodellen oppnår en absolutt feil (MAE = 17 350 EUR på val=2024; MAE = 19 051 EUR på test=2025, jf. tabell 8.2) som ved første blick virker høy. Tre forhold må holdes i mente. **For det første** er feilen målt på transaksjonsnivå, og en transaksjon kan variere fra 2 039 EUR (P25) til over 91 248 EUR (P95) i datasettet — gjennomsnittlig prosentvis avvik (MAPE) på 168 % gjenspeiler primært at noen få ekstreme transaksjoner trekker MAPE opp, ikke at typisk presisjon

er svak. Dette er et empirisk uttrykk for det log-transformerte taplandskapet drøftet i § 3.4: modellen optimerer L2 i log-rommet, og store relative feil i ti-EUR-størrelsesordener bidrar uforholdsmessig lite til log-tapet, samtidig som de blåser opp MAPE i absoluttrommet. **For det andre** plasserer wMAPE-tallet (71,4 % val, 74,3 % test) NautiCost i den nedre enden av sammenlignbare studier: Jang et al. (2023) rapporterer wMAPE rundt 65–75 % for LightGBM på fraktkostnadsprediksjon i en lignende heterogen, tabulær setting med $n \sim 7\,000$ transaksjoner; Su et al. (2024) rapporterer relative feil i samme størrelsesorden (60–80 %) for ro-ro-drivstoff-prediksjon. Vårt resultat er dermed kvantitativt sammenlignbart med eksisterende litteratur, til tross for et betydelig mindre datasett (1 633 vs. $\geq 5\,000$ i de refererte studiene). At gradient-boosting-modellene slår både medianbaseline (wMAPE 89,8 %) og ridgeregresjon (75,1 %) bekrefter også Jang et al. (2023) sin kjerneobservasjon: trebaserte modeller dominerer lineære alternativer på heterogene tabulære data. **For det tredje** er det de aggregerte anløpsestimatene (§ 8.3) som er den operasjonelle målestokken — der har medianestimatet plassert seg innenfor det historiske P25–P75-båndet i alle fem eksempler vi har testet, og det er den presisjonen som spiller størst rolle for agentkoordinator.

9.2 Forholdet mellom ensemble og enkeltmodellene

På valideringssettet (2024) er LightGBM (base) marginalt best på MAE (17 317 EUR) og RMSE (54 476 EUR), mens ensemblemodellen vinner på MAPE (168,3 %). Rangeringen mellom de to er innenfor støynivået, og det er ingen statistisk signifikant forskjell mellom dem på 490 transaksjoner. Forskjellene speiler det generelle bildet i Shwartz-Ziv & Armon (2022) og Grinsztajn et al. (2022): på heterogene tabulære data i mellomstørrelse er gradient-boosting-modeller mer eller mindre likeverdige, og ensembler gir marginal variansreduksjon snarere enn vesentlig MAE-forbedring. Et interessant biprodukt av re-splittingen er at den Optuna-tunede LightGBM-modellen presterer dårligere (17 837 EUR) enn base-modellen — et tegn på at hyperparametersøket kan ha overtilpasset seg den spesifikke fold-strukturen i kryssvalideringen. Dette minner oss om at bayesiansk optimering på små valideringssett er sårbart, og argumenterer for å beholde en enkelt-modell-fallback ved re-trening. Ensemble velges som produksjonsmodell fordi variansreduksjon mellom CatBoost og tunet LightGBM gir mer robust adferd ved drift i underliggende datadistribusjon.

CQR-korreksjonen på 3 EUR (§ 6.4 og § 8.2) er teoretisk forventet *gitt* at de underliggende kvantilmodellene er korrekt spesifisert. Det at korreksjonen ble så liten, betyr ikke at usikkerhetsbåndene er like små for hele kostnadsdomenet — det betyr at residualfordelingen som kvantilmodellene ser ut fra log-transformerte features samsvarer med antakelsen i Romano et al. (2019). En viktig nyanse fra konformprediksjonsteorien (Shafer & Vovk, 2008; Romano et al., 2019) er imidlertid at CQR-garantien gjelder *marginal* dekning over hele testdistribusjonen, ikke *betinget* dekning på subpopulasjoner. I et regime der en sentral kostnadsdriver (*guest_experience*) er fraværende fra feature-settet (§ 9.5.4), kan båndet være for smalt for noen kategorier (særlig *Provisions*); CQR korrigerer ikke for en manglende feature den ikke kan observere. Dette er den empiriske illustrasjonen av forskjellen mellom marginal og betinget dekning som § 1.5 punkt (ii) peker på som ett av studiens bidrag.

9.3 Modellens styrker

- **Kalibrering mot historiske persentiler** (§ 6.5) gjør at totalen alltid forankres i empirisk virkelighet, og eliminerer urealistisk lave estimer som rene transaksjonssummer kan produsere.
- **Kvantilmodeller med CQR-kalibrering** gir et håndfast usikkerhetsbånd som er enklere å kommunisere til kunde enn et nakent punktestimat.
- **Tidsbasert split** speiler hvordan modellen brukes operasjonelt og fjerner risiko for optimistiske prestasjonstall fra tilfeldig split.

9.4 Modellens svakheter — kritisk drøfting og forsvar

For en master-rapport er det ikke nok å liste svakheter; hver svakhet må også *forsvares* — det vil si begrunnes som enten et bevisst metodisk valg, en akseptert begrensning gitt rammene, eller et åpent punkt for videre arbeid. Vi grupperer i fire klynger og gir for hver svakhet både en beskrivelse og et forsvar. En mer detaljert refleksjon over hvordan utfordringene ble håndtert underveis ligger i § 9.7.

Datasvakheter (1–7). (1) *Tynn flåte* ($n = 17$): den strukturelt største svakheten — modellen kan ha lært yacht-spesifikke mønstre. *Forsvar*: avgrensningen er eksplisitt i § 1.3, hybrid persentil-kalibrering forankrer estimatet i empirisk virkelighet, og videre arbeid punkt 1 lukker det med utvidet flåte. (2) *Mellomstor underrepresentert* ($n = 113$, dekning 74 %): operasjonelt problem.

Forsvar: dokumentert i § 8.2 og synliggjort; lukkes ved mer data. (3) *Sjeldne havner (Stavanger n=3, Kristiansand n=8):* hybrid-kalibreringen kolliderer til rent modellestimat. *Forsvar:* HISTORICAL_RANGES rapporterer ikke usikkerhet for disse — modellen er ærlig om når den ikke kan kalibrere. (4) *Manglende guest_experience:* hovedfaktor for Provisions mangler i kildedata. *Forsvar:* operasjonell rubrikk er foreslått i Vedlegg E; vi har bevisst valgt å ikke simulere data syntetisk. CQR-begrensningen som følger er løftet fram som ett av studiens akademiske bidrag (§ 1.5 punkt ii). (5) *Ingen inflasjonsjustering:* 15–20 % kumulert inflasjon 2020–2025 ikke kompensert. *Forsvar:* eldste rader (2020–2021) er underrepresentert (n = 163 av 1 633), så drifteffekten er begrenset; rullerende re-trening er videre arbeid punkt 2. (6) *Konstant vekslingskurs:* en 5 % NOK-bevegelse gir 5 % bias i NOK-rapporten. *Forsvar:* modellen er trent og evaluert i EUR (kildevaluta); valutakonvertering er adskilt fra modellfeil og kan oppdateres uten re-trening. (7) *Ingen outlier-trimming i evaluering:* P95/P50 $\approx$ 12. *Forsvar:* trening bruker P99-cap (§ 5.4); evaluering på faktiske verdier er bevisst valg fordi en operasjonell sensor skal se modellens reelle adferd.

Modellsvakheter (8–12). (8) *Optuna-tunet ble dårligere enn base:* tegn på overtilpasning til 5-fold CV på 490 valideringsrader. *Forsvar:* empirisk argument for å beholde base som fallback ved re-trening; identifisert og rapportert åpent. (9) *Ensemble-gevinsten er statistisk insignifikant:* bootstrap-KI omslutter null (§ 8.1). *Forsvar:* ensemble velges på *forsikringsgrunner* (variansrobusthet ved drift) snarere enn gevinstgrunner — vi er ærlige om det. (10) *Regulatoriske krav som sannsynligheter:* los er obligatorisk for LOA > 70 m, men PORT_TEMPLATES har 17–73 % sannsynlighet. *Forsvar:* operasjonell override (pilot_cost) er innført; modellfix flagget som videre arbeid punkt 8. (11) *Bunkers uten reisegeometri:* drivstoff er sannsynlighetsvektet flat linje, ikke fysisk beregning. *Forsvar:* deterministisk overrideformel er innført; lært modell flagget som videre arbeid punkt 6. (12) *Land-aggregater poolet:* size_svc_* (rangerer #2 og #3) går på tvers av NO/SE/DK. *Forsvar:* country synliggjort i API/UI; modellfix flagget som videre arbeid punkt 5.

Antakelsessvakheter (13–15). (13) *A1 stabil tjenestemiks:* ingen driftovervåkning. *Forsvar:* antakelsen er eksplisitt i § 1.4; rullerende re-trening (videre arbeid punkt 2) er foreslått mekanisme. (14) *Statistiske yacht-spesifikasjoner:* ombygginger fanges ikke. *Forsvar:* antakelse A3 dokumentert; spec-fil oppdateres manuelt ved kjente endringer. (15) *CQR gir marginal, ikke*

betinget dekning: “80 %” gjelder hele populasjonen, ikke spesifikke subgrupper. *Forsvar*: dette er en *teoretisk* egenskap ved konformprediksjon (Shafer & Vovk, 2008), og avgrensningen er løftet til akademisk bidrag (§ 1.5 punkt ii); kommunikasjon i frontend bør tydeliggjøre at båndet er marginalt.

Operasjonaliseringssvakhet (16). *Produksjonsmodellen mangler uavhengig holdout*: model_meta_final.joblib er refittet på hele 2020–2025. *Forsvar*: testsettet er evaluert mot prefit-modellen som proxy (§ 8.1.1); refit på all data gir lavest forventet generaliseringsfeil for fremtidige prediksjoner (Hastie et al., 2009, § 7.10). Lukkes når 2026-data er tilstrekkelig.

Den røde tråden er at *datautfordringene* (1–4) og *strukturelle begrensninger* (16) ikke kan lukkes ved bedre modellering — bare ved mer data eller fortsatt drift. Modell- og antakelsessvakhetene (8–15) er pragmatisk håndtert med ærlig rapportering eller operasjonelle overrides. Dette samsvarer med kompendiets observasjon (§ i.4.1): “modellen er bare så god som dataene den bygger på”.

9.5 Funn fra brukertest mai 2026

En end-to-end brukertest med agency-manageren avdekket syv systematiske avvik. Hvert er adressert som modellkorreksjon, override eller datainnsamlingsmekanisme. Kodeendringer er versjonskontrollert.

9.5.1 Valutatagging i modelloutputen

Brukertesten avdekket at estimatene fremsto ca. $10\times$ lavere enn faktiske NOK-beløp. Roten var en enhetsfeil: kildedataene er **EUR** (cockpit-rapportenes egne kolonneoverskrifter), men v0.2 merket output NOK. Forholdstallet 11,5 samsvarer med EUR/NOK-kursen. Tiltak: API tar nå et currency-felt og konverterer ved grensa via EXCHANGE_RATES_FROM_EUR; frontend har valutavelger. Korreksjonen er drivkraften bak unit-relabelinga i resten av rapporten.

9.5.2 Mandatory pilotage modelleres som sannsynlig, ikke obligatorisk

For yachter med LOA > 70 m er lostjeneste lovpålagt, men PORT_TEMPLATES har los som sannsynlighetsvektet linje (17–73 % på tvers av havner) på tvers av *alle* størrelser. For Stor-yachter er realisert sannsynlighet 100 %, og modellen underveker systematisk loskostnad. Dette er nettopp gapet § 1.5 punkt (iii) påpeker — datadrevne sannsynligheter fanger ikke regulatoriske

krav. Mønsteret er kjent fra havneeffektivitetslitteraturen (Jahangard et al., 2025), der regulatoriske inngrep legges på som eksplisitte features. Tiltak: API krever nå `pilot_cost` når loskrav = "Ja" og legger beløpet som separat "Pilotage"-kategori. Riktig modellfix er størrelse-betingede sannsynligheter (videre arbeid punkt 8).

9.5.3 Bunkersmodellen ser ikke reisegeometri

Drivstoffkostnaden er, som los, modellert som sannsynlighetsvektet linje uten distanse eller fart. Lange overfarter underestimeres systematisk — samme funn som Su et al. (2024) for ro-ro-skip. Tiltak: API tar valgfri `cruising_speed_kn`, `diesel_price_per_l` og per-stopp `distance_nm` (eksponert for hvert stopp i frontend, commit e24655a). Når alle tre inputs er gitt, erstatter backend "Bunkering"-kategorien med en deterministisk beregning:

$$\text{Bunkers} = \frac{\sum \text{distance_nm}}{\text{cruising_speed_kn}} \cdot \text{fuel_lph} \cdot \text{diesel_price_per_l}$$

Dette er en operasjonell mitigation, ikke en modellfix. Den korrekte løsningen er å inkludere `distance_nm` (og marsjfart) som features i en re-trent modell — flagges som videre arbeid i § 10.

9.5.4 Manglende *guest_experience*-feature

Provisions er kategorien der modellen avviker mest, og hovedfaktoren — gjesteprofil — finnes ikke i datagrunnlaget. Vi har bevisst valgt å *ikke* simulere data, men gjort to ting: (a) `guest_experience` er nå et valgfritt API-felt og UI-velger ("not_demanding"/"neutral"/"demanding") som lagres med registry-oppføringer for fremtidig re-trening; (b) en operasjonell rubrikk er foreslått i Vedlegg E, som må forfattes og signeres av Yachting Operations selv. Dette er det empiriske grunnlaget for § 1.5 punkt (ii) — CQR kompenserer ikke for en manglende feature.

9.5.5 Land-aggregater i modellen er poolet

`port_stats` fanger landsignal indirekte via `arrival_port`-kategoriene, men `size_stats` og `size_svc_stats` er joinet kun på størrelse og pooler dermed transaksjonsdata på tvers av NO/SE/DK. For størrelsesbaserte features går landsignalet tapt — særlig synlig for København (høyt nivå) vs. norske havner. Riktig fix er `country_size_*`-aggregater og re-trening (videre arbeid punkt 5). Mellomtiltak: `country` er nå synliggjort i API-respons og frontend.

9.5.6 Per-yacht aggregering for skaleringsspørsmålet

Manageren spurte: “*hvis vi har 25 yachter i år og 4 M DKK i inntekt, hva blir det med 30 neste år?*” v0.2 hadde ingen per-yachtvisning. Tiltak: /forecast grupperer på yachtName, normaliserer til EUR, og viser flåte-snitt + naiv lineær skaleringsprojeksjon ($\text{avg_per_yacht} \times N$) med eksplisitt note om at modellen ikke fanger kapasitets-, havne- eller sesongbegrensninger.

9.5.7 Provisions-override vurdert og avvist (v0.4)

v0.3 hadde valgfri provisioning_override; den ble fjernet i v0.4 (commit e24655a) på metodisk grunnlag: en override som erstatter modellens prediksjon med et magefølelsestall undergraver verktøyets formål. For bunkers er overridden forsvarlig fordi den substitueres med en *deterministisk fysisk formel*. For Provisions finnes ingen tilsvarende substitutt før guest_experience er observerbar. Provisions-feilen skal lukkes via labels + re-trening, ikke maskeres via UI.

9.6 Validitet og generaliserbarhet

En streng vurdering av forskningsdesignet krever at vi adresserer validitet eksplisitt. Vi drøfter tre typer validitet som er mest relevante for NautiCost: konstruktvaliditet, intern validitet og ekstern validitet.

Konstruktvaliditet stiller spørsmålet om final_charge er en gyldig operasjonalisering av begrepet “totalkostnad for et havneanløp”. Variabelen er fakturabeløpet før moms slik det er registrert hos Yachting Operations, og fanger derfor agentens direkte tjenstekostnad pluss innkjøpt underleverandørarbeid. Det den *ikke* fanger er: (a) markedsmessige rabatter eller marginjusteringer som agenten ikke har dokumentert som linje, (b) skjulte kostnader hos yachteier (egen besetningslønn under anløpet, valutarisiko på betalingstidspunktet), og (c) opportunitetskostnad hvis anløpet forsinker neste reisesegment. Konstruktvaliditeten er dermed *delvis*: målvariabelen er en valid proxy for agentens egen fakturasum, men en partiell proxy for det yachteieren faktisk betaler. Brukere som ønsker å estimere yachteierens *totale* anløpskostnad må legge til egne kostnader på toppen.

Intern validitet dreier seg om hvorvidt observerte sammenhenger i datasettet faktisk reflekterer kostnadsdrivere snarere enn artefakter av prosessen. To trusler er sentrale: (i) *seleksjonsskjevhet*

— alle 17 yachter er kunder hos én agentbedrift, og er dermed ikke et tilfeldig utvalg av skandinaviske superyacht-anløp; (ii) *historie* — tjenestemiks-endringer eller leverandørbytter over 2020–2025 kan ha generert tilsynelatende “tidseffekter” som egentlig er strukturelle prisbrudd. Vi adresserer (i) ved å være eksplisitt på avgrensning (§ 1.3) og ved å rapportere at modellen ikke er eksternvalidert på andre operatører. (ii) er adressert delvis ved tidsbasert split (slik at trening og test ikke deler tidsvinduer der prisendringer kan ha skjedd samtidig), men siden vi ikke har detaljert data om leverandørbytter, kan vi ikke utelukke at en del av driften mellom val=2024 og test=2025 (+10 % MAE) skyldes en strukturell prisendring snarere enn naturlig generaliseringstap.

Ekstern validitet spør hvor godt resultatene overføres til (a) andre yachter, (b) andre operatører, og (c) andre tidsperioder. Spesifikt:

- **Til andre yachter:** Den 17-yacht-fløyteavgrensningen er en alvorlig begrensning. Yachter med spesifikasjoner langt utenfor utvalgsfordelingen (f.eks. eksplosjonsmotor vs. diesel-elektrisk, charter-yacht vs. privat) vil ha større prediksjonsfeil. Et bevis på dette: GT-områdene i datasettet er 51,9–2 407, og den eneste GT < 50 yachten i 2025-testen genererer den største prosentfeilen av alle testtransaksjoner.
- **Til andre operatører:** Modellen er trent kun på Yachting Operations sine fakturaer og fanger derfor denne agentens *konkrete* prismodeller (f.eks. agent fee struktur, hospitality-leverandørvalg). En annen agent ville hatt andre absolutttall, selv for samme anløp. Ekstern validitet på operatørnivå er dermed ikke etablert, og vi anbefaler ikke å bruke verktøyet på en annen agents anløp uten re-trening.
- **Til andre tidsperioder:** Testset-evalueringen viser at modellen generaliserer fra 2020–2023 til 2025 med 10 % MAE-degradering. For 2026–2027-bruk forventer vi tilsvarende eller noe høyere degradering, med mindre rullerende re-trening implementeres (§ 10 punkt 2).

Konklusjonen er at NautiCost har **akseptabel intern validitet** for Yachting Operations sine egne fremtidige anløp innenfor 12–18 måneder, men **begrenset ekstern validitet** utover dette. Dette er ikke et forskningsdesignsfeil; det er en konsekvens av at studien er case-spesifikk per design (§ 4 og kompendiet § B.4). Generaliseringsfunn er likevel et rimelig sekundærbidrag — særlig at

gradient-boosting + hybrid persentilkalibrering fungerer i et regime med $n \approx 1\,600$ og 17 enheter, hvilket utvider den eksisterende litteraturens dekning ned i datasparsomme størrelsesordener.

9.7 Refleksjon over prosessens utfordringer

§ 9.4 og § 9.5 dokumenterer henholdsvis modell-/data-svakheter og funn fra brukertest. Dette delkapittelet supplerer med utfordringer som lå *i selve forsknings- og rapportprosessen* — verktøy, AI-bruk, peer review-respons og iterativ forbedring.

Verktøy- og prosessutfordringer. Stort token-forbruk i komplekse rapport-oppgaver ble håndtert ved å dele arbeidet mellom Claude-sesjoner og bruke Claude Code-worktrees for parallelt arbeid på teori og diskusjon. AI-hallusinerte referanser viste seg som reell risiko: Crossref-DOI-kontroll (v1.1) avdekket to oppføringer med korrekte DOI-er men fabrikerte forfatternavn (Çerçi → Su, 2024; Garrido → Jahangard, 2025); begge korrigert og alle 14 referanser krysssjekket. DOI-resolusjon bør være standard sluttkontroll i AI-assistert skriving. Markdown → Word-konvertering krevde pypandoc-binary (ikke pre-installert), og et eget `convert_to_word.py`-skript håndterer metadata slik at tittelen ikke dupliseres. VS Code-mappekontekst og merge-konflikter ved parallelle worktrees ble pragmatisk håndtert per tilfelle. SHAP-generering for Figur 7.6 feilet teknisk på `categorical_feature-mismatch` og falt tilbake til LightGBM gain-importance som proxy.

Peer review-respons (G10/Julie, 2026-05-07). Alle syv punktene er adressert: (1) Akademisk bidrag konkretisert i § 1.5 med tre hull i litteraturen; (2) Litteratur strippet for “ligner vårt”-formuleringer og koblinger flyttet til § 9; (3) Teori-relevans-bokser i § 3 kobler hver del til DP1–DP5; (4) § 5.4 skiller eksplisitt mellom modellutvikling, seleksjon og endelig evaluering; (5) Figurer eksportert som PNG og embedet i § 7; (6) Diskusjon har litteraturkoblinger i § 9.2, § 9.5.2 og § 9.5.3; (7) APA 7-konsistens med DOI der det fantes. Tre svakheter som peer review også flagget — manglende test-sett-evaluering, ingen statistisk signifikans, manglende pensum-kobling — ble alle løst i v1.0 (henholdsvis `eval_test_2025.py`, bootstrap-KI i § 8.1, og Pettersen & Rekdal-kobling i § 2.2/§ 5.0). Et sluttgjennomgang-funn — at Figur 7.8 i v0.4 påsto $-0,03$ bias mens reell bias er $-0,20$ — er rapportert ærlig i § 7.4.

Strukturelle utfordringer som forblir åpne. Visse begrensninger kan ikke lukkes innenfor master-rapportens rammer: produksjonsmodellen mangler uavhengig holdout (§ 8.1.1),

operasjonell validering over flere måneder er ikke gjennomført, ekstern validitet til andre operatører er ikke testet (§ 9.6), og Diebold-Mariano-test er flagget som videre arbeid punkt 11. Hver av disse er eksplisitt dokumentert snarere enn skjult.

Sammenfattende refleksjon. Modell- og rapportskrivingsutfordringene er fullstendig håndtert: alle peer-review-punkter er lukket, statistisk signifikans er etablert, figurer er produsert, pensum er forankret. Datautfordringene (17 yachter, manglende `guest_experience`) og strukturelle begrensninger (ingen uavhengig holdout, ingen operasjonell validering) krever ressurser utenfor master-rapporten å lukke. Denne åpenheten — om hva som er løst, hva som er delvis løst og hva som forblir åpent — er i tråd med kompendiets sjekkliste A.3: *“Begrensninger, usikkerhet og feilkilder er tydeliggjort.”*

9.8 Praktiske implikasjoner

For Yachting Operations betyr verktøyet at en agentkoordinator på sekunder kan gi yachteier et estimat med tydelig kommunisert spenn i stedet for et magefølelsesanslag. På lengre sikt kan loggføring av faktiske anløpskostnader mot estimer drive en automatisk re-treningsløkke, slik at modellen forbedres mot faktiske prestasjoner. På kort sikt — og spesielt før labels for `guest_experience` er innhentet (jf. § 9.5.4 og Vedlegg E) — fungerer override-mekanismene for los, bunkers og provisions som en operasjonell sikkerhetsventil: koordinatoren har et estimat som *kan* korrigeres for kjente begrensninger uten å vente på en re-trening.

9.9 Etiske og personvernmessige hensyn

Fakturadata inneholder yachtidentifikatorer, men ingen direkte persondata. Yacht-ID-er er allerede anonymisert i datasettet (`yacht_1`, `yacht_2`, ..., `yacht_19`). Kontornavn (Bergen Office, Stockholm Office, Copenhagen Office) er beholdt fordi de identifiserer offentlig kjente lokasjoner og ikke representerer sensitive personopplysninger i seg selv. Fakturabeløp i rapporten er aggregert per persentil eller havn slik at enkelttransaksjoner ikke kan rekonstrueres.

10. Konklusjon

Vi har utviklet en datadreven kostnadsestimator for skandinaviske yachtanløp som kombinerer LightGBM + CatBoost-ensemble på transaksjonsnivå med hybrid kalibrering mot empiriske

persentiler på anløpsnivå. På valideringssettet (2024, $n = 490$) oppnår modellen $MAE = 17\,350$ EUR (wMAPE 71,4 %) — 20 % bedre enn medianbaseline. På det uavhengige testsettet (2025, $n = 649$) gir samme modelklasse $MAE = 19\,051$ EUR (wMAPE 74,3 %) — ≈ 10 % degradering val $\rightarrow$ test, forventet etter seleksjon. CQR-kalibrerte kvantilmodeller gir 80,0 % empirisk dekning, og aggregerte anløpsestimater plasserer seg innenfor P25–P75 i alle fem testede konfigurasjoner.

Hvert delproblem er adressert: DP1 ved 26 features (§ 5.5), DP2 ved seks-modell-sammenligning på val og test (§ 8.1, § 8.1.1), DP3 ved hybrid persentil-kalibrering (§ 6.5), DP4 ved kvantilmodeller med CQR (§ 6.4) og P25–P75-forankring (§ 8.3), og DP5 ved FastAPI + Next.js med svartid < 2 s (§ 8.4).

Studien bidrar (§ 1.5) ved å demonstrere transaksjonsnivå-ensemble med hybrid persentil-kalibrering i et lite, høytstjevt regime ($n \approx 1\,600$, 17 enheter); modellvalget er pensumforankret (Pettersen & Rekdal, 2026); og vi dokumenterer konkrete gap mellom modellstruktur og operasjonelle krav (§ 9.5) som peker mot oppnåelige retraining-mål.

Begrensninger: Anløpsestimatene er demonstrert på fem konfigurasjoner (§ 8.3); operasjonell validering over lengre tid gjenstår. Testset-metrikkene gjelder prefit-modellen som proxy for produksjonsmodellens generalisering. Ekstern validitet er begrenset til Yachting Operations. Provisions kan ikke lukkes uten guest_experience-labels (§ 9.5.4, Vedlegg E).

Videre arbeid: (1) Utvide flåten med flere yachter/operatører. (2) Online re-trening med rullerende vindu. (3) Multimodale prisdrivere (drivstoffpris, valuta, vær). (4) AB-test av koordinator-effektivitet med vs. uten verktøy. (5) Land-bevisste aggregat-features og re-trening (§ 9.5.5). (6) Reisegeometri som lært feature (§ 9.5.3). (7) guest_experience labelling og re-trening (§ 9.5.4). (8) Størrelses-betinget pilot-sannsynlighet (§ 9.5.2). (9) Operasjonell validering over 3 måneder. (10) Rullerende test-evaluering når 2026-data foreligger. (11) Diebold-Mariano-test mot bootstrap-KI. (12) Sensitivitetsanalyse på vekslingskurs.

11. Bibliografi

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189–1232. <https://doi.org/10.1214/aos/1013203451>

Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on typical tabular data? *Advances in Neural Information Processing Systems*, 35, 507–520.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer. <https://doi.org/10.1007/978-0-387-84858-7>

Jahangard, M., Xie, Y., & Feng, Y. (2025). Leveraging machine learning and optimization models for enhanced seaport efficiency. *Maritime Economics & Logistics*, 27(4), 710–751. <https://doi.org/10.1057/s41278-024-00309-w>

Jang, H.-S., Chang, T.-W., & Kim, S.-H. (2023). Prediction of shipping cost on freight brokerage platform using machine learning. *Sustainability*, 15(2), 1122. <https://doi.org/10.3390/su15021122>

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 3146–3154.

Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., & Lee, S.-I. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2(1), 56–67. <https://doi.org/10.1038/s42256-019-0138-9>

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765–4774.

Pettersen, B.-I., & Rekdal, P. K. (2026). *Kvantitative metoder i logistikk — implementert via KI* [Kompendium]. LOG650 Forskningsprosjekt: Logistikk og kunstig intelligens, Høgskolen i Molde.

Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased boosting with categorical features. *Advances in Neural Information Processing Systems*, 31, 6638–6648.

Romano, Y., Patterson, E., & Candès, E. (2019). Conformalized quantile regression. *Advances in Neural Information Processing Systems*, 32, 3543–3553.

Shafer, G., & Vovk, V. (2008). A tutorial on conformal prediction. *Journal of Machine Learning Research*, 9, 371–421. <https://jmlr.csail.mit.edu/papers/volume9/shafer08a/shafer08a.pdf>

Shwartz-Ziv, R., & Armon, A. (2022). Tabular data: Deep learning is not all you need. *Information Fusion*, 81, 84–90. <https://doi.org/10.1016/j.inffus.2021.11.011>

Su, M., Lee, H. J., Wang, X., & Bae, S.-H. (2024). Fuel consumption cost prediction model for ro-ro carriers: A machine learning-based application. *Maritime Policy & Management*, 52(2), 229–249. <https://doi.org/10.1080/03088839.2024.2303120>

Vedlegg

- **A.** Featureliste og dtype-tabell — se `modeling_nauticost.ipynb`, seksjon 2 (26 features: 6 kategoriske + 20 numeriske).
- **B.** Hyperparametre fra Optuna-studie — se 013 fase 3 - `review/artifacts/model_meta_final.joblib` og `modeling_nauticost.ipynb`, seksjon 9.
- **C.** API-spesifikasjon (OpenAPI fra FastAPI) — se 013 fase 3 - `review/backend/` for endepunkt-definisjon (POST `/api/predict`).
- **D.** Skjermbilder fra Next.js-frontend — se 013 fase 3 - `review/frontend/` for kildekoden til dashboardet.
- **E.** Foreslått rubrikk for `guest_experience` — se egen seksjon nedenfor.
- **F.** Test-set-evalueringsskript — 013 fase 3 - `review/eval_test_2025.py` reproducerer tallene i tabell 8.2; resultatene er lagret i 013 fase 3 - `review/artifacts/metrics_test_2025.csv`.

Vedlegg E. Foreslått rubrikk for `guest_experience`

`guest_experience` mangler i kildedataene (jf. § 9.5.4) og kan ikke simuleres. For at fremtidige labels skal være konsistente på tvers av koordinatorer foreslår vi en operasjonell rubrikk basert på

pre-arrival-informasjon — fem dimensjoner som agentkoordinator (eller yachtens purser) kan svare på ved booking:

Dimensjon	Skår 0	Skår 1	Skår 2
Antall gjester ombord	< 4	4–8	> 8
Antall planlagte hosted events under turen (galaer, hosted middager, mottakelser)	0	1–2	≥ 3
Provisjonsstil	Standard	Premium	Luksus / bespoke
Antall transfers per uke (lufthavn, by, dagstur)	< 3	3–7	> 7
Guide- eller excursionfrekvens	Sjelden	Av og til	Ofte

Sum gir et tall mellom 0 og 10. Bucketing til de tre lovlige API-verdiene:

- **0–3 → not_demanding**
- **4–6 → neutral**
- **7–10 → demanding**

Viktig: Dette er et **forslag til startpunkt**, ikke en validert rubrikk. Den må forfattes og signeres av Yachting Operations selv før den tas i bruk operasjonelt. Dimensjonene og terskelverdiene over er valgt for å være observerbare *før* anløpet (slik at label kan settes før kostnadene er realisert), og for å være rimelig ortogonale (ingen dimensjon er en triviell funksjon av en annen). Anvendt på 1 626 historiske rader vil rubrikken kunne labele tilbake i tid bare delvis, fordi nodene over ikke er logget — men kombinasjon av fakturanotater (invoice_comments) og koordinatorenes minne kan gi en startsetting for re-trening (jf. § 10 punkt 7).

Uten en operasjonelt validert rubrikk vil framtidige labels variere mellom koordinatore og introdusere systematisk støy som modellen vil tolke som tilfeldig variasjon. Rubrikken er derfor et forutsetningsdokument for re-trening, ikke en ettertanke.